

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Nguyễn Hoàng Thanh

MÔ HÌNH HỎI ĐÁP VỀ LỊCH SỬ BẰNG
PHƯƠNG PHÁP TẠO SINH TĂNG
CƯỜNG TRUY XUẤT ĐỒ THỊ

LUẬN VĂN THẠC SĨ

TP. Hồ Chí Minh - Năm 2025

ĐẠI HỌC QUỐC GIA TP,HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Nguyễn Hoàng Thanh

MÔ HÌNH HỎI ĐÁP VỀ LỊCH SỬ BẰNG
PHƯƠNG PHÁP TẠO SINH TĂNG
CƯỜNG TRUY XUẤT ĐỒ THỊ

Ngành: KHOA HỌC MÁY TÍNH

Mã số ngành: 8480101

NGƯỜI HƯỚNG DẪN KHOA HỌC

TS. Nguyễn Tiến Huy

TP. Hồ Chí Minh - Năm 2025

Lời cam đoan

Tôi cam đoan luận văn thạc sĩ ngành **Khoa học máy tính** với đề tài **Mô hình hỏi đáp về lịch sử bằng phương pháp tạo sinh tăng cường truy xuất đồ thị** là công trình khoa học do Tôi thực hiện dưới sự hướng dẫn của TS. Nguyễn Tiến Huy.

Những kết quả nghiên cứu của luận văn hoàn toàn trung thực và chính xác.

Học viên cao học

Nguyễn Hoàng Thanh

Lời cảm ơn

Luận văn được hoàn thành tại Khoa Công nghệ thông tin - Trường Đại học Khoa học Tự nhiên - Đại học Quốc gia Thành phố Hồ Chí Minh dưới sự hướng dẫn của TS. Nguyễn Tiến Huy.

Đầu tiên, tôi xin tỏ lòng biết ơn chân thành đến hai thầy vì đã đồng ý hướng dẫn tôi hoàn thành luận văn này. Cảm ơn thầy vì đã kiên nhẫn và tận tình với em trong suốt quá trình từ lúc bắt đầu đến lúc kết thúc luận văn, và còn nhiều hơn nữa.

Cảm ơn cô Đỗ Thị Kim Hương và các thầy, cô thuộc Văn phòng khoa Công nghệ Thông tin đã nhiệt tình hỗ trợ các vấn đề liên quan đến hồ sơ và thủ tục của luận văn này.

Tp. Hồ Chí Minh 30/12/2025

Nguyễn Hoàng Thanh

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Danh mục các hình vẽ, đồ thị	v
Danh mục các bảng số liệu	vii
Danh mục các từ viết tắt, khái niệm và thuật ngữ	viii
Danh mục các từ viết tắt, khái niệm và thuật ngữ	ix
Trang thông tin luận văn tiếng Việt	x
Trang thông tin luận văn tiếng Anh	xiii
1 Giới thiệu	1
1.1 Đặt vấn đề	1
1.2 Động lực nghiên cứu	2
1.2.1 Động lực khoa học	2
1.2.2 Động lực ứng dụng	3
1.3 Mục đích nghiên cứu	4
1.4 Một số nghiên cứu liên quan	5
1.4.1 Các phương pháp cải thiện NaiveRAG	5
1.4.2 GraphRAG (Microsoft)	6

1.4.3	Các phương pháp ứng dụng LLM trên đồ thị tri thức: GNN - RAG và RoG	8
1.5	Nội dung và phạm vi thực hiện đề tài	9
1.5.1	Nội dung nghiên cứu	9
1.5.2	Phạm vi nghiên cứu	9
1.6	Đóng góp của luận văn	10
2	Tổng quan	12
2.1	Học sâu	12
2.2	RAG	14
2.3	GraphRAG	15
2.3.1	Xây dựng đồ thị tri thức	17
2.3.2	Truy xuất dựa trên đồ thị tri thức	17
2.4	Hạn chế khi ứng dụng GraphRAG vào bài toán hỏi đáp lịch sử	18
2.4.1	Kiến trúc nội tại của LLM	19
2.4.2	Sự trùng lặp thực thể	19
2.4.3	Thiếu ràng buộc thời gian xuyên suốt	21
2.4.4	Nhiều do phương án MCQ	21
3	Phương pháp tiếp cận	23
3.1	Doc Chunking	24
3.2	Entities and Relationships Extraction	25
3.3	Entity Alignment	27
3.4	Answer Candidates Filtering	28
3.5	Graph & Temporal Retrieval	29
3.6	Reranking	31
4	Thực nghiệm	32
4.1	Dữ liệu	32
4.2	Cấu hình thực nghiệm	33
4.3	Kết quả	34

4.3.1	Kết quả lập chỉ mục (Indexing)	35
4.3.2	Kết quả truy vấn (Querying)	35
4.4	Phân tích lỗi	36
5	Áp dụng mô hình vào ứng dụng thực tế	39
5.1	Kết quả đánh giá ứng dụng mô hình vào ứng dụng di động	39
5.2	Kết quả đánh giá ứng dụng	42
6	Kết luận	49
6.1	Đóng góp của luận văn	49
6.2	Hạn chế	50
6.3	Hướng phát triển trong tương lai	51
7	Các công trình nghiên cứu	53
	Tài liệu tham khảo	54

Danh mục các hình vẽ, đồ thị

2.1	Pipeline RAG cơ bản gồm hai bước: (1) lập chỉ mục dữ liệu; (2) truy xuất và sinh đáp án.	14
2.2	Tư duy từ cục bộ đến toàn cục: từ thực thể trong truy vấn và tài liệu → tóm tắt thực thể → quan hệ → tóm tắt cộng đồng; dùng cho tìm kiếm toàn cục và cục bộ.	16
2.3	Dòng xử lý của GraphRAG theo bài báo của Microsoft: giai đoạn lập chỉ mục (trái) và giai đoạn truy vấn (phải). . . .	18
2.4	Tỉ lệ đúng sai giữa mô hình thuần LLM và GraphRAG với bộ câu hỏi lịch sử 120 câu ngẫu nhiên từ bộ đề ôn tập lịch sử.	20
3.1	Tổng quan HisGraphRAG: từ lập chỉ mục (indexing) đến truy vấn (querying).	24
3.2	Luồng xử lý dữ liệu thô.	25
3.3	Luồng trích xuất, chuẩn hoá và lưu trữ thực thể–quan hệ trước khi nạp vào đồ thị và kho thời gian.	27
5.1	Kiến trúc triển khai ứng dụng HisGraphRAG (số đánh dấu 1–4 tương ứng với các luồng chính).	40
5.2	Dữ liệu lịch sử được embedding.	42
5.3	Giao diện công cụ tự động.	43
5.4	Giao diện người dùng.	44
5.5	Nội dung các sự kiện theo thời gian.	45

5.6	Kết quả truy vấn các thực thể.	46
5.7	Kết quả truy vấn trên đồ thị.	47
5.8	Kết quả mô hình hỏi đáp.	48

Danh mục các bảng số liệu

2.1	Số lượng thực thể và quan hệ sau khi gộp trùng lặp trên bộ dữ liệu lịch sử lớp 12.	21
4.1	Thống kê bộ đề đánh giá (mỗi câu gồm 4 lựa chọn A/B/C/D).	33
4.2	Tiêu thụ LLM trong pha lập chỉ mục (indexing).	35
4.3	Kết quả độ chính xác, token và thời gian trên VUEE-2017 và VUEE-2018.	36
4.4	Tác động của từng thành phần trong HisGraphRAG trên ví dụ minh họa.	37

Danh mục các từ viết tắt, khái niệm và thuật ngữ

Từ viết tắt	Từ đầy đủ	Tiếng Việt
LLM	Large Language Model	Mô hình ngôn ngữ lớn
MCQ	Multiple-choice question	Dạng câu hỏi chọn đáp án
RAG	Retrieval-Augmented Generation	Tạo sinh tăng cường truy vấn
VUEE	Vietnamese University Entrance Exams	Bộ đề thi tuyển sinh đại học Việt Nam
NaiveRAG	Naive Retrieval-Augmented Generation	Tạo sinh tăng cường truy vấn cổ điển
KG	Knowledge Graph	Đồ thị tri thức
CI/CD	Continuous Integration/Continuous Development	Tích hợp liên tục/ Phân phối liên tục
CNN	Convolutional neural networks	Mạng neuron tích chập
LSTM	Long short-term memory	Tmột loại mạng nơ-ron hồi quy
GAN	Generative Adversarial Networks	Mạng đối kháng tạo sinh
GRU	Gated Recurrent Unit	Là mọi loại mạng neuron hồi quy

TRANG THÔNG TIN LUẬN VĂN

Tên đề tài luận văn: Mô hình hỏi đáp về lịch sử bằng phương pháp tạo sinh tăng cường truy xuất đồ thị.
Ngành: Khoa học Máy tính
Mã số ngành: 8480101
Họ và tên HVCH: Nguyễn Hoàng Thanh
Khóa đào tạo: 33
GVHD: TS. Nguyễn Tiến Huy, TS. Lê Thanh Tùng
Cơ sở đào tạo: Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM

1. TÓM TẮT NỘI DUNG LUẬN VĂN:

Các mô hình ngôn ngữ lớn (LLM) gặp khó khăn về tính chuẩn xác trong quá trình suy luận về lĩnh vực lịch sử, nơi các thực thể bị trùng lặp, ngữ cảnh thời gian thiếu vắng và truy xuất nhiều có thể làm sai lệch kết quả sinh. Luận văn đề xuất **HisGraphRAG**, một khung GraphRAG dành riêng cho hỏi đáp các câu hỏi lịch sử tiếng Việt. Hệ thống gồm ba thành phần chính: (i) *căn chỉnh thực thể* trong giai đoạn xây dựng đồ thị để hợp nhất các nút tương đương về ngữ nghĩa, (ii) *truy xuất và xếp hạng có nhận thức thời gian* nhằm khớp bằng chứng với cửa sổ thời gian của câu hỏi, và (iii) *lọc phương án trả lời gây nhiễu* để giữ sự tập trung cho LLM. Đánh giá trên các bộ câu hỏi Lịch sử của Kỳ thi Tuyển sinh Đại học (VUEE), HisGraphRAG cải thiện độ chính xác so với LLM thuần, NaiveRAG và GraphRAG cơ sở, cung cấp một quy trình tăng cường đồ thị đáng tin cậy hơn cho truy vấn lịch sử.

- **Về mặt lý thuyết:** Luận văn chỉ ra ba hạn chế cốt lõi của GraphRAG thông thường trong chủ đề lịch sử bao gồm: trùng lặp thực thể, mất mốc thời gian và bị nhiễu bởi bằng chứng không liên quan và khắc phục bằng ba đóng góp tương ứng: *căn chỉnh thực thể* để gộp các nút tương đương, *truy xuất & xếp hạng theo*

thời gian để khớp bằng chứng với khung thời gian của câu hỏi, và *lọc phương án* để loại bỏ lựa chọn kém khả dĩ trước khi truy xuất. Kết hợp với *xếp hạng do LLM dẫn dắt*, hệ thống tạo các tiêu đề thị sạch và ngữ cảnh gọn, giàu thông tin.

- **Về mặt ứng dụng:** Triển khai hệ thống HisGraphRAG: chia đoạn theo cấu trúc sách (giữ nguyên cấu trúc chương–mục), trích xuất thực thể/quan hệ vào Neo4j cùng kho thời gian (SQL), truy xuất đặc dày bằng Milvus, xếp hạng bằng LLM và suy luận MCQ. Trên VUEE-2017 và VUEE-2018 (tổng 120 câu), hệ thống đạt **81.7%** và **70.8%** độ chính xác, vượt các đường cơ sở.

Trình diễn hệ thống 3 triển khai: Ngoài thí nghiệm trong bài báo, tôi xây dựng chatbot dựa trên Streamlit cho hỏi–đáp lịch sử và tích hợp các luồng Jenkins tự động xây dựng đồ thị tri thức, đóng gói và lưu trữ toàn bộ trên hạ tầng đám mây (CI/CD).

2. NHỮNG KẾT QUẢ MỚI CỦA LUẬN VĂN:

- **Gộp thực thể cho đồ thị lịch sử:** Bước gộp dựa trên LLM hợp nhất các biến thể tên (ví dụ “Liên Xô”/“Xô viết”), giảm phân mảnh đồ thị và nâng độ chính xác truy xuất.
- **Thêm yếu tố thời gian vào dữ liệu đồ thị:** Trích xuất biểu thức thời gian trong truy vấn để xác định cửa sổ truy xuất (ví dụ ± 1 năm) và xếp hạng bằng chứng theo trình tự thời gian của câu hỏi.
- **Lọc phương án cho dạng câu hỏi MCQ:** Sàng lọc các lựa chọn ít khả thi trước truy xuất để tránh lôi kéo bằng chứng không liên quan, giúp mô hình tập trung suy luận.
- **Xếp hạng ngữ cảnh :** LLM chọn top- k ngữ cảnh hữu ích nhất, tạo prompt ngắn gọn nhưng giàu tín hiệu cho bước suy luận cuối.
- **Hiệu quả đầu–cuối trên bài toán lịch sử tiếng Việt:** Trên các bộ VUEE, HisGraphRAG vượt LLM thuần, NaiveRAG và

GraphRAG cơ sở; ví dụ 81.7% (2017) và 70.8% (2018), khẳng định một quy trình GraphRAG chuyên biệt, đã kiểm chứng thực nghiệm cho miền lịch sử nguồn lực thấp.

CÁN BỘ HƯỚNG DẪN

(Ký tên, họ tên)

HỌC VIÊN CAO HỌC

(Ký tên, họ tên)

**XÁC NHẬN CỦA CƠ SỞ ĐÀO TẠO
HIỆU TRƯỞNG**

THESIS INFORMATION

Thesis title: HisGraphRAG: GraphRAG for Vietnamese Historical question answering.
Speciality: Computer Science
Code: 8480101
Name: Nguyen Hoang Thanh
Academic year: 33
Supervisor: Dr. Nguyen Tien Huy, Dr. Le Thanh Tung
At: VNUHCM - University of Science

1. SUMMARY:

Large Language Models (LLMs) struggle with factual grounding and temporal reasoning in history, where duplicated entities, missing timeline context, and noisy retrieval can mislead generation. This thesis proposes **HisGraphRAG**—a GraphRAG framework tailored for Vietnamese historical question answering—that (i) aligns duplicated entities during graph construction, (ii) injects temporal awareness into retrieval and reranking, and (iii) filters distractor answer candidates to keep the LLM focused. Evaluated on Vietnamese University Entrance Exam (VUEE) history sets, HisGraphRAG boosts accuracy across models, offering a more reliable graph-augmented pipeline for historical inquiry.

- **Theoretically:** The thesis identifies three core limitations of vanilla GraphRAG in history—duplicated entities, loss of temporal grounding, and distraction from irrelevant evidence—and addresses them with three targeted contributions: *entity alignment* to merge semantically equivalent nodes, *temporal retrieval & reranking* to match evidence with the question’s time window, and *answer-candidate filtering* to discard implausible options before retrieval. Together with LLM-guided reranking, these modules produce cleaner subgraphs and tighter prompts.

- **Application:** I implemented HisGraphRAG end-to-end: section-aware chunking (to preserve textbook structure), entity/relationship extraction into a Neo4j graph plus a temporal SQL store, dense retrieval with Milvus embeddings, LLM-based reranking, and MCQ reasoning. On VUEE-2017 and VUEE-2018 (120 questions total), HisGraphRAG achieved **81.7%** and **70.8%** accuracy respectively, outperforming LLM-only, NaiveRAG, and baseline GraphRAG variants.

System demo and deployment: Beyond the paper’s experiments, I built a Streamlit-based chatbox for historical QA and integrated a Jenkins automation pipeline to (re)build the knowledge graph and host all components on cloud infrastructure (CI/CD).

2. NOVELTY OF THESIS:

- **Entity alignment for history KGs:** A pragmatic LLM-driven merge step consolidates duplicated or variant nodes (e.g., “Soviet Union” vs. “Soviet”), reducing graph fragmentation and improving retrieval precision (Table 1 shows 11.09% fewer nodes and 25.11% fewer relations after alignment on the textbook graph).
- **Temporal-aware GraphRAG:** Time expressions in queries are extracted to define a retrieval window (e.g., ± 1 year), and evidence is reranked to fit the question’s chronology—crucial for causal/sequence reasoning in history.
- **Answer-candidate filtering for MCQ:** Before retrieval, low-likelihood choices are pruned to avoid injecting irrelevant evidence, aligning with human test-taking strategies and improving downstream reasoning focus.
- **LLM-guided reranking:** Instead of static scorers, the LLM selects the top- k most helpful context items, yielding compact, high-signal prompts for final generation.

- **End-to-end gains on Vietnamese history QA:** Across VUEE benchmarks, HisGraphRAG surpasses LLM-only, NaiveRAG, and baseline GraphRAG; e.g., 81.7% (2017) and 70.8% (2018), establishing a tailored, empirically validated GraphRAG pipeline for low-resource historical QA.

SUPERVISOR

MASTER STUDENT

**CERTIFICATION
UNIVERSITY OF SCIENCE
PRESIDENT**

Chương 1

Giới thiệu

1.1 Đặt vấn đề

Trong vài năm gần đây, các mô hình ngôn ngữ lớn (LLM) cho thấy năng lực nổi bật trong sinh văn bản và trả lời câu hỏi. Khi chuyển sang miền lịch sử, đặc biệt là lịch sử Việt Nam, những giới hạn cốt lõi của LLM và các hệ thống Retrieval-Augmented Generation (RAG) bộc lộ rõ: thiếu đối chiếu sự kiện đáng tin cậy dễ dẫn tới ảo tưởng thông tin, khó suy luận theo trật tự thời gian, và dễ bị nhiễu do truy xuất dựa trên tương đồng ngữ nghĩa thuần túy [1, 2]. Đồ thị tri thức và hướng GraphRAG mang lại cách biểu diễn có cấu trúc để liên kết thực thể, quan hệ và mốc thời gian, qua đó hỗ trợ lập luận dựa trên các dẫn chứng đi kèm [3].

Với chủ đề lịch sử, tri thức thường đan xen nhiều tên gọi khác nhau của cùng một thực thể như nhân vật, địa danh, triều đại và tổ chức; đi kèm các mốc thời gian liên tiếp hoặc phụ thuộc, và quan hệ nhân quả giữa sự kiện. Nếu không có cơ chế chuẩn hoá và căn chỉnh thực thể, đồ thị dễ bị phân mảnh với nhiều nút trùng nghĩa; đồng thời, truy xuất không có ràng buộc thời gian có thể đưa vào ngữ cảnh tư liệu sai giai đoạn hoặc sai trình tự, khiến mô hình sinh lập luận trên bằng chứng lệch và cho đáp án kém tin cậy. Cách tiếp cận dựa trên đồ thị cho phép duyệt theo lân cận có ý nghĩa, ưu tiên đường đi phù hợp chủ đề và gắn mốc thời gian vào cả

truy xuất lần tổng hợp [3, 4].

Trong ngữ cảnh tiếng Việt, một ngôn ngữ ít tài nguyên so với tiếng Anh, thách thức còn tăng do nguồn tư liệu lịch sử phân tán theo nhiều định dạng, công cụ chuẩn hoá thời gian và căn chỉnh thực thể còn hạn chế, và dữ liệu đánh giá chuẩn hoá (ví dụ trắc nghiệm nhiều lựa chọn theo chương trình phổ thông) chưa phong phú. Trong khi đó, nhu cầu ứng dụng lại rất rõ ràng: học sinh, sinh viên, giáo viên và độc giả cần hệ thống hỏi–đáp lịch sử chính xác, có căn cứ và tôn trọng trình tự thời gian để ôn luyện, tra cứu và học tập [4].

Từ các khoảng trống nêu trên, luận văn xác lập bài toán xây dựng một khung GraphRAG chuyên biệt cho lịch sử Việt Nam với ba năng lực cốt lõi. Thứ nhất, hợp nhất và căn chỉnh thực thể nhằm giảm phân mảnh đồ thị và xử lý trường hợp tên gọi khác. Thứ hai, đưa ràng buộc thời gian vào cả giai đoạn truy xuất và xếp hạng bằng chứng để bảo đảm tính trước–sau và quan hệ nhân quả của sự kiện. Thứ ba, lọc nhiễu trong bối cảnh câu hỏi trắc nghiệm nhiều lựa chọn và tái xếp hạng theo bằng chứng, giúp mô hình tập trung suy luận vào các phương án có cơ sở [1, 4]. Khung này kỳ vọng nâng cao độ chính xác, tính nhất quán theo thời gian và khả năng truy vết nguồn dẫn, từ đó đáp ứng nhu cầu ứng dụng trong giáo dục và tra cứu lịch sử tiếng Việt.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Trong hệ RAG và đặc biệt là GraphRAG, tôi đang hướng vào ba mũi nhọn: giảm nhiễu ngữ cảnh, tăng tính căn cứ của bằng chứng và cải thiện đồ thị tri thức được xây dựng. Ở tầng truy xuất, các hướng kết hợp tín hiệu thừa–đặc cho thấy hiệu quả thực tế: kết hợp BM25 với mô hình biểu diễn dày giúp bao phủ cả trùng khớp từ khoá và ngữ nghĩa gần [5, 6]. Bên cạnh đó, viết lại hoặc mở rộng truy vấn theo ý định, chẳng hạn tạo tư

liệu giả định (hypothetical document) để neo truy vấn vào không gian nội dung, giúp hệ thống đặt câu hỏi gần với ngôn ngữ của nguồn liệu hơn [7]. Với miền lịch sử, nơi thông tin xoay quanh sự kiện, truy xuất theo đơn vị sự kiện thay vì cụm từ khoá đơn lẻ càng trở nên quan trọng; các bộ truy xuất đa vector với tương tác muộn cho phép lưu giữ nhiều khía cạnh nội dung của cùng một đoạn, từ đó nâng độ bao phủ khi có nhiều cách diễn đạt [8].

Sau truy xuất, kiểm soát ngữ cảnh là bước then chốt để giảm nhiễu. Các kỹ thuật rút gọn ngữ cảnh có hướng dẫn giúp cắt bỏ phần không mang giá trị suy luận, giữ lại chứng cứ trọng yếu mà không làm tổn hại chất lượng trả lời; điều này đặc biệt hữu ích khi cửa sổ ngữ cảnh có hạn và câu hỏi đòi hỏi chuỗi bằng chứng chất lượng [9]. Đồng thời, chuẩn hoá và căn chỉnh thực thể khi xây dựng đồ thị giúp thống nhất các tên gọi khác nhau của cùng một thực thể, giảm phân mảnh và nâng độ chính xác truy xuất; các hệ liên kết thực thể quy mô lớn cung cấp nền tảng kỹ thuật đáng tin cậy cho bước này [10].

Từ các định hướng đó, luận văn lựa chọn cấu hình phù hợp lịch sử tiếng Việt: căn chỉnh thực thể sớm để hạn chế trùng lặp nút và quan hệ; truy xuất và xếp hạng có nhận thức thời gian nhằm khớp bằng chứng với mốc được hỏi; lọc phương án trong câu hỏi nhiều lựa chọn để giảm nhiễu đi kèm; và chọn nhóm ngữ cảnh hữu ích nhất trước khi sinh đáp án. Cách tiếp cận này hướng tới việc cải thiện độ chính xác tối đa cho mô hình GraphRAG.

1.2.2 Động lực ứng dụng

RAG và GraphRAG đã được khai thác rộng trong các lĩnh vực có nhu cầu cao về kiểm chứng và an toàn như y tế, pháp lý, dịch vụ khách hàng hay vận tải logistics. Tiêu biểu trong y tế, các biến thể GraphRAG hướng tới sinh đáp án có căn cứ, kiểm soát nguồn dẫn và thuật ngữ để tăng độ tin cậy của hệ thống hỗ trợ chuyên gia [11]. Trái lại, chủ đề lịch sử, đặc

biệt là lịch sử Việt Nam vẫn còn khoảng trống nghiên cứu so với tiềm năng ứng dụng. Cấu trúc dữ liệu lịch sử vốn giàu thực thể, quan hệ, sự kiện, mốc thời gian và chuỗi nhân quả, rất phù hợp để biểu diễn dưới dạng đồ thị tri thức và tận dụng các kỹ thuật của GraphRAG.

Nhu cầu thực tiễn thể hiện rõ ở ba kịch bản. Thứ nhất, trong giáo dục và ôn luyện, người học và giáo viên cần hệ thống hỏi đáp có căn cứ, tập trung vào trình tự thời gian, hỗ trợ hình thức trắc nghiệm nhiều lựa chọn (như các bộ đề chuẩn hoá). Thứ hai, trong tra cứu học thuật và phổ thông, độc giả mong chờ câu trả lời gọn nhưng đúng mốc sự kiện, đi kèm tuyến suy luận minh bạch có thể lần theo qua các đường dẫn trên đồ thị, thay vì câu trả lời trôi nổi khó kiểm chứng. Thứ ba, xét đến đặc thù ngôn ngữ ít tài nguyên, tiếng Việt còn thiếu công cụ chuẩn hoá thực thể và hiểu thời gian so với tiếng Anh; vì vậy, một khung GraphRAG chuyên biệt cho lịch sử Việt Nam vừa lấp khoảng trống công nghệ, vừa tạo nền cho các môn khoa học xã hội khác.

Từ các yêu cầu đó, luận văn hướng tới một giải pháp có thể triển khai trong thực tiễn: xây dựng và bảo trì tự động đồ thị tri thức lịch sử Việt Nam; truy xuất có ràng buộc thời gian để khớp bằng chứng với mốc được hỏi; giảm nhiễu gắn với câu hỏi nhiều lựa chọn; và tích hợp toàn bộ quy trình vào ứng dụng hỏi–đáp phục vụ học tập, đào tạo và tra cứu.

1.3 Mục đích nghiên cứu

Nhận thức rõ ý nghĩa khoa học và thực tiễn của hỏi đáp lịch sử tiếng Việt, luận văn hướng tới mục tiêu xây dựng và hiện thực hoá **His-GraphRAG** một khung GraphRAG chuyên biệt nhằm giảm trùng lặp thực thể, tích hợp ràng buộc thời gian, và hạn chế nhiễu trong bài toán MCQ. Cụ thể, luận văn đặt mục tiêu: thiết kế cơ chế căn chỉnh thực thể trong lúc xây dựng đồ thị tri thức lịch sử Việt Nam; phát triển truy xuất và reranking có nhận thức thời gian; tích hợp lọc phương án và xếp hạng để tạo ngữ cảnh gọn, đúng mốc; đánh giá thực nghiệm trên các bộ VUEE;

và triển khai nguyên mẫu ứng dụng hỏi đáp phục vụ học tập/tra cứu.

1.4 Một số nghiên cứu liên quan

1.4.1 Các phương pháp cải thiện NaiveRAG

NaiveRAG kết hợp một tầng truy xuất tài liệu với bước sinh câu trả lời có điều kiện trên bằng chứng. Cách làm này dễ triển khai và hoạt động ổn trong bối cảnh tri thức phẳng, tuy nhiên mô hình thường nhận nhiều ngữ cảnh thừa, khó kiểm soát chất lượng bằng chứng và ít nắm được quan hệ cũng như trật tự thời gian giữa các thực thể. Vì vậy, các nghiên cứu gần đây tập trung vào ba hướng: nâng chất lượng truy xuất, kiểm soát ngữ cảnh trước khi sinh, và điều chỉnh truy vấn để khớp hơn với cách thông tin được ghi chép trong kho tri thức.

Về truy xuất theo từ khóa, BM25 là đại diện tiêu biểu của nhóm dựa trên chỉ mục đảo, tận dụng tần suất nghịch tài liệu để xếp hạng các đoạn theo mức độ trùng khớp từ vựng. Phương pháp này đặc biệt hữu ích với thuật ngữ hiếm, tên riêng, danh xưng, địa danh lịch sử vì các đơn vị này có sức phân biệt cao [5]. Tuy nhiên, chỉ dựa vào trùng khớp bề mặt có thể bỏ sót các diễn đạt tương đương và chú giải thường gặp trong tư liệu lịch sử.

Để khắc phục, truy xuất đặc dựa trên biểu diễn bằng vector được dùng rộng rãi. Các mô hình bi-encoder học không gian biểu diễn chung cho truy vấn và tài liệu, từ đó tìm các đoạn phù hợp ngay cả khi không trùng từ khóa bề mặt [6].

Một hướng khác là truy xuất đa vector với cơ chế tương tác muộn, tiêu biểu như ColBERT. Thay vì nén toàn bộ đoạn văn vào một vector duy nhất, mô hình giữ nhiều điểm đại diện ở mức token và đối sánh chi tiết với truy vấn. Với dữ liệu lịch sử có nhiều khía cạnh xoay quanh sự kiện, nhân vật và mối liên hệ, cách làm này giúp bảo toàn chi tiết nội dung trong khi vẫn hỗ trợ tìm kiếm hiệu quả [8].

Sau truy xuất thô, tái xếp hạng giữ vai trò then chốt. Các mô hình chấm điểm mạnh như cross-encoder đánh giá mức phù hợp ở mức tương tác sâu giữa truy vấn và đoạn văn, nhờ vậy giảm đáng kể nhiễu trước khi chuyển sang bước sinh. Khi cửa sổ ngữ cảnh có hạn, kỹ thuật rút gọn ngữ cảnh có hướng dẫn được dùng để loại bỏ phần ít hữu ích mà vẫn giữ mạch suy luận, vừa giảm chi phí, vừa hạn chế lan truyền sai sót [9].

Điều chỉnh truy vấn cũng cho thấy hiệu quả. Viết lại hoặc mở rộng truy vấn theo ý định giúp thu hẹp khoảng cách giữa cách người dùng đặt câu hỏi và cách tài liệu trình bày thông tin. Cách tạo tài liệu giả định để neo truy vấn vào không gian nội dung là một ví dụ, thường cải thiện khả năng tìm thấy bằng chứng với các câu hỏi giàu bối cảnh [7]. Với miền lịch sử, đưa ràng buộc về thời gian, thực thể và quan hệ ngay từ truy vấn giúp giảm lác đề, nhất là khi nhiều sự kiện có tên gần nhau nhưng thuộc các giai đoạn khác nhau.

Nhờ các cải tiến trên, NaiveRAG tiến bộ rõ rệt về độ chính xác và khả năng kiểm soát ngữ cảnh. Dù vậy, hạn chế cốt lõi vẫn còn, cơ chế chủ yếu tối ưu ở cấp đoạn văn đơn lẻ, trong khi nhiều câu hỏi lịch sử đòi hỏi ghép nối quan hệ giữa nhiều thực thể, lần theo đường dẫn suy luận và tôn trọng trình tự sự kiện. Điều này gợi ý cần đưa cấu trúc tri thức vào vòng lặp RAG để truy xuất và lập luận theo đồ thị, làm tiền đề cho các phương pháp dựa trên đồ thị tri thức và GraphRAG được trình bày ở các mục tiếp theo.

1.4.2 GraphRAG (Microsoft)

GraphRAG đưa đồ thị tri thức vào vòng lặp RAG để truy xuất ngữ cảnh có cấu trúc thay vì chỉ dựa vào các đoạn văn rời rạc. Cách làm gốc do Microsoft đề xuất gồm hai pha gắn kết chặt chẽ với nhau [12]. Ở pha lập chỉ mục, hệ thống trích xuất thực thể, quan hệ và sự kiện từ nguồn liệu; chuẩn hoá và liên kết thực thể; sau đó phát hiện cộng đồng trên đồ thị để nhóm các vùng tri thức gần nhau. Với mỗi cộng đồng, một bản tóm

tất được tạo nhằm mô tả các thực thể trọng tâm, quan hệ nổi bật và chủ đề bao trùm. Các bản tóm tắt này hoạt động như chỉ mục cấp cao, giúp điều hướng tới khu vực liên quan của đồ thị nhanh và có kiểm soát [3].

Ở pha truy vấn, từ câu hỏi đầu vào, hệ thống trước hết đối sánh với tập tóm tắt cộng đồng để chọn các khu vực phù hợp; tiếp theo, truy xuất tiểu đồ thị chi tiết trong những cộng đồng đã chọn, có thể kèm mở rộng theo đường dẫn nhiều bước với ràng buộc về chủ đề hoặc thời gian. Kết quả trả về cho mô hình sinh gồm phần tóm tắt định hướng và tập bằng chứng ở dạng nút–cạnh của đồ thị, cho phép tổng hợp câu trả lời kèm đường dẫn lập luận và nguồn dẫn rõ ràng [4]. Cơ chế này giảm đáng kể nhiều so với truy xuất thuần văn bản vì bối cảnh đã được cấu trúc theo thực thể, quan hệ và mốc thời gian.

Hiệu quả của GraphRAG phụ thuộc mạnh vào chất lượng đồ thị. Nếu tồn tại trùng lặp tên gọi, liên kết thực thể chưa thống nhất hoặc thiếu nhãn thời gian, tiểu đồ thị truy xuất có thể nhiều và dễ dẫn đến suy luận lệch mốc. Ngoài ra, tóm tắt cộng đồng chất lượng thấp có thể làm sai hướng điều phối truy vấn, còn việc mở rộng đường dẫn không kiểm soát có nguy cơ đưa quá nhiều bối cảnh. Do đó, khi áp dụng cho lịch sử Việt Nam, cần nhấn mạnh ba điểm bổ sung: căn chỉnh thực thể ngay ở bước xây đồ thị để hạn chế phân mảnh; gắn và kiểm tra ràng buộc thời gian trong cả hai pha để bảo đảm tính trước sau; và tái xếp hạng dựa trên bằng chứng nhằm giữ nhóm ngữ cảnh ngắn gọn, hữu ích trước khi sinh câu trả lời [1, 3, 4]. Những điều chỉnh này giúp GraphRAG phát huy ưu thế lập luận theo cấu trúc, đồng thời phù hợp hơn với yêu cầu kiểm chứng và tính mạch lạc theo thời gian của bài toán lịch sử. Phần này sẽ được trình bày chi tiết hơn tại 2.4.1 và 2.4.

1.4.3 Các phương pháp ứng dụng LLM trên đồ thị tri thức: GNN - RAG và RoG

Hai hướng mở rộng đáng chú ý của GraphRAG là GNN – RAG và RoG (Reasoning over Graphs). Với GNN – RAG, ý tưởng trung tâm là dùng mạng nơ-ron đồ thị để truyền và khuếch tán tín hiệu liên quan trên đồ thị tri thức trước khi đưa bối cảnh vào mô hình sinh. Quá trình này thường gồm điểm hóa nút và cạnh theo mức độ liên quan tới câu hỏi, chọn các đường đi quan trọng và trích xuất tiểu đồ thị cô đọng. Cách làm giúp bao phủ tốt hơn các quan hệ nhiều bước, đặc biệt khi câu trả lời phụ thuộc chuỗi liên kết giữa các thực thể. Hạn chế là chi phí huấn luyện và suy luận tăng theo kích thước đồ thị và độ sâu lan truyền, đồng thời hiệu quả phụ thuộc mạnh vào chất lượng đồ thị đã được chuẩn hóa và căn chỉnh thực thể [3, 4].

RoG tập trung vào việc tách bạch lập kế hoạch, truy xuất và suy luận. Hệ thống trước hết sinh một kế hoạch suy luận ở dạng chuỗi thực thể và quan hệ cần đi qua, tiếp theo truy xuất tiểu đồ thị khớp với kế hoạch đó và cuối cùng tổng hợp bằng chứng để trả lời. Cách tiếp cận này giúp kiểm soát hướng lập luận, giảm lệch mạch và làm rõ quan hệ nhân quả nhiều bước. Đổi lại, độ trễ có thể tăng do thêm pha lập kế hoạch, và toàn bộ quy trình trở nên nhạy với lỗi trong bước lập kế hoạch cũng như với chất lượng tiểu đồ thị thu được [4].

Tổng quan, cả GNN – RAG lẫn RoG đều tăng mức độ cấu trúc và khả năng giải thích của RAG dựa trên đồ thị. Chúng cho phép hệ thống tiếp cận truy vấn lịch sử bằng các đường dẫn có kiểm soát thay vì chỉ dựa vào đoạn văn rời rạc. Tuy vậy, các thách thức vẫn giữ nguyên: yêu cầu đồ thị sạch và nhất quán, nhu cầu gắn nhãn thời gian cho sự kiện để tôn trọng trật tự trước sau, và chi phí triển khai phải chấp nhận được trong bối cảnh ứng dụng thực tế [1, 3, 4].

1.5 Nội dung và phạm vi thực hiện đề tài

1.5.1 Nội dung nghiên cứu

- Khảo sát các thuật toán, phương pháp, và các kiến trúc mạng học sâu để xây dựng mô hình trả lời cho các câu hỏi lịch sử Việt Nam.
- Khảo sát các kỹ thuật và luồng xử lý cho mô hình GraphRAG. Từ đó đề xuất các phương án cải thiện độ chính xác cho bài toán hỏi đáp câu hỏi lịch sử.
- Khảo sát các kỹ thuật giúp xây dựng đồ thị tri thức. Từ đó xây dựng đồ thị tri thức phù hợp cho bài toán lịch sử.
- Thu thập và xử lý dữ liệu để xây dựng đồ thị tri thức.
- Xây dựng, thử nghiệm và đánh giá trên bộ dữ liệu tự thu thập (các câu hỏi trong đề thi đại học Việt Nam qua các năm).
- Xây dựng ứng dụng để trực quan hoá các kết quả đầu ra của mô hình GraphRAG đã đề xuất ở trên.

1.5.2 Phạm vi nghiên cứu

Về phương pháp, luận văn tập trung vào việc cải tiến hiệu quả phương pháp tối ưu hiệu quả của mô hình GraphRAG cho bài toán hỏi đáp lịch sử.

Về thực nghiệm, các nghiên cứu và mô hình được đánh giá trên bộ dữ liệu tự xây dựng về các câu hỏi thi đại học môn lịch sử tài Việt Nam VUEE (Vietnamese University Entrance Exams). Ngoài ra dữ liệu để xây dựng đồ thị tri thức sẽ là sách lịch sử lớp 12 do bộ giáo dục Việt Nam phát hành và một số nguồn ngữ liệu từ wikipedia.

Về thời gian, luận văn này sẽ áp dụng những công nghệ được đưa ra trong vòng 5 năm gần đây, đảm bảo sự thiết thực của dữ liệu cũng như bắt kịp xu hướng công nghệ.

Về giới hạn, luận văn này sẽ ở mức độ luận văn tốt nghiệp Cao học, đề tài đánh mạnh vào ngành xử lý ngôn ngữ tự nhiên. Tập trung vào giải quyết các bài toán trên mô hình học máy, mô hình học sâu và có sự hỗ trợ đặc lực của phương pháp truyền thống trong việc xử lý dữ liệu chữ.

1.6 Đóng góp của luận văn

Luận văn tập trung vào bài toán hỏi–đáp lịch sử tiếng Việt dựa trên RAG kết hợp đồ thị tri thức, hướng tới nâng độ chính xác, khả năng kiểm chứng và tính nhất quán theo thời gian. Bốn nhóm đóng góp chính gồm lý thuyết, phương pháp–hệ thống, thực nghiệm và ứng dụng.

Thứ nhất về lý thuyết, luận văn đề xuất khung HisGraphRAG chuyên biệt cho lịch sử Việt Nam, nhấn mạnh ba thành phần cốt lõi để khắc phục hạn chế phổ biến của RAG/GraphRAG. Thành phần (i) là căn chỉnh thực thể ngay khi xây dựng đồ thị tri thức để hợp nhất các biến thể tên gọi và giảm phân mảnh nút, cạnh, nhờ đó cải thiện chất lượng truy xuất nền tảng. Thành phần (ii) là truy xuất và xếp hạng có nhận thức thời gian: trích thời gian từ câu hỏi, gán nhãn thời gian cho sự kiện và đưa ràng buộc thời gian xuyên suốt từ retriever tới reranker, nhằm tôn trọng trật tự trước–sau và quan hệ nhân quả trong dữ kiện lịch sử. Thành phần (iii) là lọc phương án gây nhiễu trong MCQ trước truy xuất để tránh kéo bối cảnh sai lệch, kết hợp tái xếp hạng do mô hình lớn dẫn dắt để chọn nhóm ngữ cảnh gọn mà hữu ích.

Thứ hai về phương pháp và hệ thống, luận văn xây dựng quy trình end-to-end phù hợp triển khai. Tài liệu được chia đoạn theo cấu trúc (giữ chương, mục) nhằm hạn chế đứt mạch ngữ nghĩa; các thực thể và quan hệ được trích xuất và nạp vào Neo4j, đồng thời mốc thời gian được quản lý trong kho dữ liệu quan hệ để tiện ràng buộc và truy vấn. Tầng truy xuất bao gồm việc tái xếp hạng do mô hình lớn dẫn dắt, còn tầng suy luận MCQ nhận biết và loại bỏ phương án gây nhiễu trước khi tổng hợp. Chuỗi bước này nhằm tối đa hoá độ chính xác của mô hình, đồng thời làm rõ

đường dẫn lý giải dựa trên tiêu đề thị.

Thứ ba về thực nghiệm, luận văn thiết lập đánh giá trên các bộ câu hỏi Lịch sử dạng trắc nghiệm VUEE (2017, 2018; tổng 120 câu). Kết quả cho thấy HisGraphRAG vượt các đường cơ sở gồm LLM thuần, NaiveRAG và một cấu hình GraphRAG cơ sở, đạt 81.7% trên VUEE-2017 và 70.8% trên VUEE-2018. Phân tích ablation xác nhận đóng góp của ba thành phần chính: căn chỉnh thực thể, ràng buộc thời gian trong truy xuất–xếp hạng và lọc phương án nhiễu trước suy luận.

Thứ tư về ứng dụng, luận văn triển khai một chatbot dựa trên Streamlit cho hỏi–đáp lịch sử và một pipeline Jenkins tự động hoá các bước xây dựng lại đồ thị tri thức, đóng gói và triển khai hệ thống (CI/CD). Hệ thống minh chứng tính khả thi triển khai trong thực tế lớp học và tự học, đồng thời cung cấp nền tảng để mở rộng sang các chủ đề khoa học xã hội khác.

Công bố. Nội dung của luận văn đã được công bố trong bài báo “*His-GraphRAG: GraphRAG for Vietnamese Historical Question Answering*” tại **PACLIC 2025**.

Chương 2

Tổng quan

Chương này trình bày các kiến thức nền tảng và tiền đề kỹ thuật phục vụ cho đề tài. Mục tiêu là thiết lập khung khái niệm thống nhất để:

- Giới thiệu các nền tảng của các ứng dụng của học sâu và sự chuyển dịch sang Transformer/LLM — hạ tầng mô hình trung tâm của các hệ thống hỏi đáp hiện đại;
- Trình bày cơ chế Retrieval-Augmented Generation (RAG) và mở rộng *GraphRAG* dựa trên đồ thị tri thức;
- Làm rõ các hạn chế khi áp dụng GraphRAG vào bài toán hỏi–đáp lịch sử tiếng Việt (kiến thức nội tại LLM, trùng lặp thực thể, ràng buộc thời gian, v.v.).

Trên cơ sở đó, chương tạo nền tảng lý thuyết để định vị và triển khai khung HisGraphRAG trong các phần tiếp theo.

2.1 Học sâu

Học sâu là một nhánh của học máy tập trung vào mạng nơ-ron nhiều tầng để tự động học biểu diễn từ dữ liệu thô. Khả năng học đặc trưng trực tiếp từ dữ liệu quy mô lớn giúp học sâu vượt trội hơn nhiều phương pháp truyền thống trong các tác vụ dự báo và hiểu nội dung. Nhìn lại tiến trình

phát triển, ba họ kiến trúc có ảnh hưởng rộng rãi đã đóng vai trò nền tảng cho các hệ thống AI thực tế.

Thứ nhất, mạng tích chập (CNN) thể hiện năng lực mạnh trên dữ liệu có cấu trúc không gian như ảnh. Cơ chế tích chập và gom cụm cho phép mô hình học các bộ lọc theo cấp bậc, từ cạnh và góc tới hình dạng phức tạp, góp phần tạo nên các mốc quan trọng trong thị giác máy tính [13]. Thứ hai, mạng tuần tự như RNN và các biến thể LSTM, GRU được thiết kế để xử lý dữ liệu theo chuỗi, lưu giữ thông tin ngữ cảnh qua thời gian nhằm mô hình hóa phụ thuộc ngắn và trung bình; trong đó LSTM khắc phục tình trạng tiêu biến đạo hàm khi học phụ thuộc dài hơn [14]. Thứ ba, mô hình tạo sinh đối kháng (GAN) đưa ra khung học hai thành phần gồm bộ sinh và bộ phân biệt, thúc đẩy mạnh mẽ các ứng dụng tổng hợp ảnh và phương thức học không giám sát [15].


Từ học sâu đến Transformer/LLM

Hạn chế cố hữu của RNN trong việc mô hình hóa phụ thuộc dài hạn và nhu cầu huấn luyện song song trên chuỗi dài đã dẫn tới sự xuất hiện của Transformer với cơ chế tự chú ý. Tự chú ý cho phép mô hình ước lượng quan hệ xa gần giữa các token mà không phụ thuộc trực tiếp vào khoảng cách vị trí, đồng thời tận dụng tốt hạ tầng tính toán song song để mở rộng quy mô tham số. Nhờ đó, Transformer nhanh chóng trở thành kiến trúc mặc định cho xử lý ngôn ngữ tự nhiên hiện đại và là nền tảng để huấn luyện các mô hình ngôn ngữ lớn phục vụ tóm tắt, suy luận và hỏi đáp [16].

Các mô hình ngôn ngữ lớn được tiền huấn luyện trên kho dữ liệu văn bản rất lớn, sau đó tinh chỉnh theo chỉ dẫn cho các tình huống sử dụng cụ thể. Dù đạt chất lượng biểu diễn và khả năng tổng hợp tốt, chúng không đảm bảo tính cập nhật và kiểm chứng nguồn, dễ phát sinh lỗi bịa đặt thông tin khi không có bằng chứng hỗ trợ. Đây là động lực cho RAG, cơ chế đưa bước truy xuất tài liệu vào trước khi sinh câu trả lời để neo suy luận vào nguồn tham chiếu, và cũng là nền để phát triển GraphRAG nhằm

tận dụng cấu trúc đồ thị tri thức cho truy xuất và lập luận theo quan hệ, sự kiện và thời gian [1, 3, 4, 12].

2.2 RAG



Hình 2.1: Pipeline RAG cơ bản gồm hai bước: (1) lập chỉ mục dữ liệu; (2) truy xuất và sinh đáp án.

Retrieval-Augmented Generation (RAG) là cơ chế neo quá trình sinh của mô hình ngôn ngữ vào bằng chứng bên ngoài có kiểm chứng. Thay vì để mô hình trả lời chỉ dựa trên kiến thức nội tại (dễ lỗi thời hoặc thiếu chính xác), RAG bổ sung một lớp truy xuất: hệ thống tìm các mảnh thông tin liên quan trong kho tri thức và cung cấp chúng làm ngữ cảnh cho mô hình ở thời điểm suy luận. Cách tiếp cận này giúp giảm ảo tưởng thông tin, cải thiện tính cập nhật và cho phép kiểm soát phạm vi tri thức thông qua chỉ mục do hệ thống quản lý [1, 4].

Như minh hoạ ở Hình 2.1, pipeline cơ bản gồm hai bước. Ở bước lập chỉ mục, tài liệu thô được chuẩn hoá và chia thành các đoạn kích thước vừa kèm siêu dữ liệu (nguồn, thời gian, chủ đề). Mỗi đoạn được mã hoá thành vector ngữ nghĩa rồi nạp vào cơ sở dữ liệu vector (FAISS, Milvus,

v.v.). Ở bước truy xuất và sinh, truy vấn của người dùng được mã hoá, hệ thống tìm top- k đoạn gần nhất trong chỉ mục, có thể tái xếp hạng và rút gọn để hình thành ngữ cảnh, sau đó mô hình sinh câu trả lời có điều kiện trên ngữ cảnh này.

RAG mang lại ba lợi ích rõ rệt. Thứ nhất, giảm phụ thuộc hoàn toàn vào kiến thức nội tại nên hạn chế ảo tưởng thông tin. Thứ hai, cho phép cập nhật tri thức bằng cách thay đổi chỉ mục mà không cần huấn luyện lại mô hình. Thứ ba, giúp kiểm soát nguồn và phạm vi nội dung để phục vụ yêu cầu tuân thủ hoặc các miền chuyên biệt [1].


Tuy vậy, khi áp dụng cho bài toán lịch sử, RAG cơ bản còn bộc lộ hạn chế. Tìm kiếm theo độ giống vector dễ trả về bằng chứng đúng chủ đề nhưng sai mốc hoặc sai chuỗi trước-sau vì thiếu ràng buộc thời gian. Các đoạn văn rời rạc không bộc lộ rõ cấu trúc thực thể, quan hệ và sự kiện, khiến suy luận nhiều bước và truy vết đường dẫn lý giải kém minh bạch. Cửa sổ ngữ cảnh hạn chế cũng buộc phải loại bớt bằng chứng, dẫn tới nguy cơ mất mát thông tin quan trọng. Cuối cùng, việc trình bày mạch suy luận giữa các thực thể và sự kiện còn bị giới hạn do không có cấu trúc dẫn dắt [4].

Những hạn chế này là động lực trực tiếp dẫn tới GraphRAG. Thay vì chỉ truy xuất đoạn văn, hệ thống lập chỉ mục đồ thị tri thức để biểu diễn rõ thực thể, quan hệ và sự kiện; từ đó truy xuất tiểu đồ thị cùng các bản tóm tắt cộng đồng làm ngữ cảnh có cấu trúc, giúp mô hình suy luận theo đường dẫn minh bạch và tôn trọng mốc thời gian. Nội dung này được trình bày ở mục tiếp theo.

2.3 GraphRAG

GraphRAG mở rộng RAG để giải quyết hai hạn chế quan trọng: thiếu cấu trúc quan hệ giữa các mảnh văn bản và khó trả lời các câu hỏi toàn cục đòi hỏi tổng hợp chủ đề của cả kho liệu. Ý tưởng trung tâm là chuyển kho văn bản thành đồ thị tri thức thực thể-quan hệ và tạo các bản tóm

tất theo cộng đồng; khi truy vấn, hệ thống có thể dùng các tóm tắt này để tổng hợp câu trả lời ở quy mô toàn cục, hoặc lần theo lân cận thực thể để trả lời cục bộ. Cách tiếp cận kết hợp truy xuất theo đồ thị với tóm tắt theo truy vấn (query-focused summarization), cho phép trả lời vừa cụ thể theo thực thể vừa bao quát theo chủ đề ở quy mô lớn [12, 3, 4].



Hình 2.2: Tư duy từ cục bộ đến toàn cục: từ thực thể trong truy vấn và tài liệu → tóm tắt thực thể → quan hệ → tóm tắt cộng đồng; dùng cho tìm kiếm toàn cục và cục bộ.

So với NaiveRAG, GraphRAG bổ sung một chỉ mục có cấu trúc gồm đồ thị tri thức và các bản tóm tắt cộng đồng, đồng thời hỗ trợ hai chiến lược truy vấn bổ sung cho nhau: tìm kiếm toàn cục (hỏi qua các cộng đồng rồi rút-gộp theo kiểu map-reduce) và tìm kiếm cục bộ (bám theo thực thể, quan hệ, lân cận). Nhờ đó, dòng suy luận trở nên minh bạch hơn thông qua đường dẫn trên đồ thị và các tóm tắt trung gian [12].


2.3.1 Xây dựng đồ thị tri thức

Quy trình lập chỉ mục của GraphRAG thường gồm năm bước nối tiếp. (i) Tách văn bản và chia đoạn: trích nội dung từ tài liệu nguồn, chia thành các đoạn kích thước vừa và gắn siêu dữ liệu như mốc thời gian, nguồn, mục. Kết quả là tập đoạn đã chuẩn hoá để truy xuất sau này. (ii) Trích xuất tri thức: sinh tóm tắt theo miền cho từng đoạn nhằm làm rõ ngữ cảnh, sau đó rút ra thực thể và quan hệ ở dạng có cấu trúc, kèm liên kết ngược về nguồn. (iii) Dựng đồ thị tri thức: hợp nhất các thực thể và quan hệ thành đồ thị thực thể–quan hệ, đồng thời làm sạch và căn chỉnh thực thể khi cần để giảm phân mảnh. (iv) Phát hiện cộng đồng: phân cụm đồ thị theo cấu trúc (ví dụ các họ thuật toán kiểu Leiden theo phân cấp) để thu được các cộng đồng thực thể và hệ phân cấp phục vụ điều hướng. (v) Tóm tắt cộng đồng: sinh báo cáo tóm tắt cho từng cộng đồng và từng cấp, mô tả thực thể chủ chốt, quan hệ nổi bật và chủ đề bao trùm; đây là lớp chỉ mục cấp cao giúp điều hướng nhanh tới vùng tri thức liên quan [3, 12].

2.3.2 Truy xuất dựa trên đồ thị tri thức

Tại thời điểm truy vấn, GraphRAG vận hành theo hai chế độ. Với tìm kiếm toàn cục, hệ thống đối sánh truy vấn với các bản tóm tắt cộng đồng để chọn vùng liên quan, đặt câu hỏi qua từng cộng đồng, thu về các câu trả lời từng phần và rút–gộp thành câu trả lời cuối cùng. Cách làm này bao quát rộng và tận dụng tri thức đã tóm tắt sẵn, phù hợp với câu hỏi như “các chủ đề chính của tập liệu là gì?”. Với tìm kiếm cục bộ, hệ thống nhận diện thực thể và quan hệ từ truy vấn, duyệt lân cận trong đồ thị, kết hợp bằng chứng cấu trúc (nút, cạnh, đường dẫn) với bằng chứng phi cấu trúc (đoạn văn gốc), rồi hợp thành ngữ cảnh gọn để mô hình sinh trả lời; bước tái xếp hạng có thể được dùng để ưu tiên bằng chứng hữu ích. Hai chế độ này bổ sung cho nhau và cho phép điều chỉnh mức độ bao quát–chi tiết theo nhu cầu của câu hỏi [12, 4].

Như vậy, GraphRAG đưa cấu trúc tri thức vào toàn bộ vòng lặp truy



Hình 2.3: Dòng xử lý của GraphRAG theo bài báo của Microsoft: giai đoạn lập chỉ mục (trái) và giai đoạn truy vấn (phải).

xuất-sinh, giúp neo suy luận vào đường dẫn quan hệ và mốc thời gian rõ ràng. Hiệu quả cuối cùng phụ thuộc đáng kể vào chất lượng đồ thị (chuẩn hoá, căn chỉnh, gán thời gian) và chất lượng tóm tắt cộng đồng; đây cũng là các điểm cần được chú trọng khi triển khai cho miền lịch sử tiếng Việt.

2.4 Hạn chế khi ứng dụng GraphRAG vào bài toán hỏi đáp lịch sử

Mặc dù biểu diễn tri thức dưới dạng *đồ thị* giúp bộc lộ thực thể và quan hệ tốt hơn so với văn bản rời rạc, việc áp dụng GraphRAG cho hỏi–đáp lịch sử vẫn gặp nhiều thách thức: (i) kiến thức nội tại của LLM có thể xung đột hoặc lẫn át bằng chứng từ đồ thị; (ii) trùng lặp/không chuẩn hoá thực thể làm phân mảnh đồ thị, gây nhiễu truy xuất; (iii) thiếu ràng buộc thời gian xuyên suốt khiến mô hình chọn nhầm bằng chứng; và (iv) nhiều

do distractors khi xử lý trong bài toán MCQ. Dưới đây là các điểm nghiên chính.

2.4.1 Kiến thức nội tại của LLM


LLM luôn mang theo “nền tri thức mặc định” từ tiền huấn luyện. Trong miền lịch sử, nền tri thức này có thể lỗi thời, khác hệ quy chiếu sử học, hoặc khác phiên bản tên gọi. Khi ngữ cảnh truy xuất chưa đủ mạnh (của sổ ngữ cảnh nhỏ, tóm tắt cộng đồng còn tổng quát, subgraph loãng), mô hình dễ:

- **Xung đột tri thức:** Vì chủ đề lịch sử có nhiều phiên bản khác nhau và khó để kết luận nguồn thông tin là chính xác nhất. Để đảm bảo tính minh bạch nguồn tài liệu chính xác nên chọn là nguồn tài liệu được công bố và chấp nhận rộng rãi (ví dụ như nguồn tài liệu từ sách giáo khoa Lịch Sử Việt Nam).
- **Lấn át bằng chứng:** ngữ cảnh bị thừa và tín hiệu quan trọng bị loãng do quá nhiều thông tin cần truy xuất.

Kết luận trên dựa vào đánh giá trên một bộ câu hỏi lịch sử trong quá trình ôn tập của học sinh được trình bày trong Bảng 2.4, dựa vào đó chúng ta có thể thấy số lượng GraphRAG làm tốt hơn mô hình thuần LLM là 13% trong khi đó có tới 6% câu hỏi mô hình thuần LLM không cần thêm giá trị ngữ cảnh nào đã làm tốt hơn mô hình GraphRAG.

2.4.2 Sự trùng lặp thực thể

Lịch sử Việt Nam thường xuất hiện nhiều tên gọi khác nhau cho cùng một thực thể theo thời kỳ, phiên âm hoặc biệt danh. Nếu không chuẩn hoá và căn chỉnh ngay từ khi xây đồ thị tri thức, các bản ghi sẽ bị tách rời thành nhiều nút gần như đồng nhất. Hệ quả là đồ thị bị phân mảnh, đường dẫn quan hệ bị đứt quãng; các tiểu đồ thị trả về ở bước truy xuất phải bao gồm nhiều nút tương đương để “an toàn”, khiến bối cảnh phình



Hình 2.4: Tỷ lệ đúng sai giữa mô hình thuần LLM và GraphRAG với bộ câu hỏi lịch sử 120 câu ngẫu nhiên từ bộ đề ôn tập lịch sử.

to nhưng loãng; đồng thời việc gắn mốc thời gian trở nên thiếu nhất quán vì các bản sao có thể mang các mốc khác nhau. Nguyên nhân chủ yếu đến từ trích xuất không nhất quán của mô hình, thiếu bộ từ điển chuẩn và ngưỡng hợp nhất chưa điều chỉnh theo tiếng Việt. Vì vậy, cần một quy trình căn chỉnh bán tự động kết hợp so khớp theo tên gọi khác, ngữ cảnh và nguồn tham chiếu; đây là bước vệ sinh đồ thị tối quan trọng trước khi truy xuất dựa trên cấu trúc [3, 4].

Bảng 2.1 minh họa tác động của bước căn chỉnh trên bộ dữ liệu lịch sử lớp 12: số lượng thực thể giảm khoảng 11% trong khi số lượng quan hệ giảm hơn 25%. Điều này cho thấy các nút trùng lặp thường là các thực thể xuất hiện dày và có nhiều liên kết; khi hợp nhất, mạng lưới quan hệ trở nên cô đọng và đáng tin cậy hơn cho các phép duyệt lân cận và xếp hạng theo đường đi.

	Số lượng thực thể	Số lượng mối quan hệ
Không gộp thực thể	1334	681
Gộp thực thể	1186	510
% giảm	11.09%	25.11%

Bảng 2.1: Số lượng thực thể và quan hệ sau khi gộp trùng lặp trên bộ dữ liệu lịch sử lớp 12.

2.4.3 Thiếu ràng buộc thời gian xuyên suốt

Trong câu hỏi lịch sử, tính đúng đắn phụ thuộc mạnh vào thời điểm diễn ra sự kiện, bối cảnh chính trị-xã hội và các biến cố ngoại cảnh cùng thời. Nếu chỉ dựa vào độ giống theo vector, hệ thống dễ thu về đoạn văn đúng chủ đề nhưng thuộc giai đoạn khác, từ đó dẫn tới suy luận sai chuỗi trước-sau hoặc nhầm quan hệ nhân-quả. Một cấu hình hiệu quả cần coi thời gian là thuộc tính hạng nhất: trích khung thời gian từ truy vấn, chuẩn hóa mốc trong dữ liệu (ví dụ năm dương lịch thống nhất, quy tắc nhập niên hiệu), gắn nhãn thời gian cho thực thể-sự kiện trong đồ thị, và áp dụng lọc theo cửa sổ thời gian ngay từ tầng truy xuất. Ở tầng tái xếp hạng, điểm số cần kết hợp độ phù hợp ngữ nghĩa với độ khớp mốc, ưu tiên các đường đi trên đồ thị nằm trọn trong khoảng thời gian hợp lệ. Khi sinh đáp án, mô hình nên được yêu cầu nêu mốc và nguồn dẫn để buộc sử dụng bằng chứng, giảm ảnh hưởng của kiến thức nội tại không phù hợp [1, 12, 4]. Với lịch sử Việt Nam, việc đồng bộ hoá định dạng niên đại và ràng buộc thời gian xuyên suốt pipeline đặc biệt quan trọng vì nhiều sự kiện có tên gần nhau nhưng xảy ra ở các triều hoặc thập kỷ khác nhau.

2.4.4 Nhiều do phương án MCQ

Trong trắc nghiệm nhiều lựa chọn, mỗi phương án thường gắn với một phạm trù lịch sử khác nhau (thời kỳ, vùng, nhân vật, chính sách). Nếu hệ thống gom bằng chứng cho tất cả phương án ngay từ đầu, ngữ cảnh sẽ bị pha loãng bởi các mẫu thông tin đúng nhưng thuộc giai đoạn khác, làm


suy giảm chất lượng truy xuất và tăng nguy cơ chọn nhầm đáp án. Cách tiếp cận phù hợp là loại bỏ những câu trả lời nhiễu và tập trung vào những câu trả lời có khả năng chính xác cao: trước hết ước lượng độ khả dĩ của từng phương án dựa trên các tín hiệu nhanh (thời gian, thực thể khóa, từ khóa đặc thù), loại sớm các phương án kém phù hợp; sau đó truy xuất tập trung cho các ứng viên còn lại và tái xếp hạng theo bằng chứng. Khi hợp nhất ngữ cảnh, cần tránh trộn chứng cứ xung đột; thay vào đó, giữ các gói bằng chứng theo phương án để so sánh đối chiếu, rồi chọn đáp án có bằng chứng khớp mốc thời gian và quan hệ rõ ràng nhất. Quy trình này giúp tiết kiệm ngân sách ngữ cảnh, giảm nhiễu và buộc mô hình dựa vào đường dẫn bằng chứng thay vì suy đoán theo ngữ nghĩa bề mặt [1, 4, 12].

Chương 3

Phương pháp tiếp cận

Chương này trình bày chi tiết khung **HisGraphRAG** cho bài toán hỏi đáp lịch sử tiếng Việt trên nền GraphRAG. Xuất phát từ các điểm nghẽn chính được xác định ở Chương 2.2–2.3 (trùng lặp thực thể, nhiều truy xuất, và thiếu ràng buộc thời gian), HisGraphRAG đề xuất ba nguyên tắc cốt lõi: (i) *Căn chỉnh thực thể* để giảm phân mảnh đồ thị; (ii) *Lọc phương án trả lời* nhằm tránh neo truy xuất theo distractors; và (iii) *Nhận thức thời gian* trong toàn bộ vòng truy xuất–xếp hạng. Toàn bộ pipeline được minh hoạ ở Hình 3.1.

- **Căn chỉnh thực thể (Entity Alignment).** Các biến thể tên (ví dụ “Chủ tịch Hồ Chí Minh”/“Hồ Chí Minh”) nếu không hợp nhất sẽ làm loãng tri thức, đứt gãy đường dẫn quan hệ và tạo subgraph nhiễu. Hợp nhất về một danh tính chuẩn giúp tăng nhất quán ngữ nghĩa và độ chính xác truy xuất.
- **Lọc phương án (Answer Candidates Filtering).** Trong MCQ, nếu truy xuất dựa đồng thời lên mọi phương án A/B/C/D, các phương án sai sẽ kéo ngữ cảnh lệch hướng. Lọc trước các lựa chọn kém khả dĩ giúp tập trung bằng chứng vào nhóm phương án hứa hẹn.
- **Nhận thức thời gian (Temporal Awareness).** Câu hỏi lịch sử phụ thuộc mạnh vào mốc/khung thời gian. Tôi đưa ràng buộc thời



Hình 3.1: Tổng quan HisGraphRAG: từ lập chỉ mục (indexing) đến truy vấn (querying).

gian vào cả retriever và reranker để đảm bảo bằng chứng đúng giai đoạn.


3.1 Doc Chunking

Mục tiêu của bước chia đoạn là bảo toàn mạch nghĩa theo chương–mục của sách giáo khoa lịch sử, hạn chế vỡ ngữ nghĩa do cắt theo số token cố định. Cách tiếp cận được thiết kế để giữ cấu trúc nội dung gốc, đồng thời bảo đảm mỗi đoạn phù hợp với ràng buộc độ dài của các bộ mã hoá và mô hình ngôn ngữ hiện dùng [1, 4].

Mô hình hóa tài liệu và đơn vị chia

Mỗi tài liệu được biểu diễn như chuỗi chương $C = \{c_1, \dots, c_n\}$, với mỗi chương c_i gồm các mục $S_i = \{S_{i1}, \dots, S_{im}\}$. Đơn vị chia chính là mục S_{ij} vì mục thường tương ứng với một tiểu chủ đề tương đối khép kín (nhân vật, sự kiện, chính sách). Để duy trì liên kết ngữ cảnh giữa các mục kề nhau, áp dụng cửa sổ chồng lấn theo lân cận trái:

$$x_{ij} = S_{ij-k} \parallel S_{ij},$$



Hình 3.2: Luồng xử lý dữ liệu thô.

trong đó k là tham số chồng lấn và $\parallel$ là phép nối văn bản. Khi x_{ij} vượt ngưỡng token $T_{\max}$ (ràng buộc bởi bộ mã hoá/LLM), tiến hành cắt đệ quy thành $\{x_{ij}^{(1)}, \dots, x_{ij}^{(\ell)}\}$ sao cho $\text{len}(x_{ij}^{(\ell)}) \leq T_{\max}$ với mọi ℓ . Việc cắt ưu tiên ranh giới câu/đoạn, tránh tách rời định nghĩa, ví dụ và mốc thời gian quan trọng.

3.2 Entities and Relationships Extraction


Mục tiêu của bước này là chuyển mỗi đoạn văn đã chia thành các phần tử tri thức có cấu trúc, đủ dùng cho truy xuất theo đồ thị và lọc theo thời gian về sau. Phạm vi miền tập trung vào sáu lớp chính: sự kiện, nhân vật, địa điểm, tổ chức, hành động/chiến lược và tác động. Cách chọn này bám sát cấu trúc trình bày của sách giáo khoa lịch sử, đủ bao phủ nhưng vẫn gọn để vận hành.

Quy trình. Với từng chunk, hệ thống hướng dẫn mô hình trích xuất thực thể đặt tên và quan hệ xuất hiện rõ trong văn bản. Để giữ lược đồ đơn giản và tránh bùng nổ nhãn cạnh, đồ thị dùng một loại cạnh duy nhất `RELATE_TO` kèm một trường mô tả bằng ngôn ngữ tự nhiên nêu bản chất

liên hệ (ví dụ “diễn ra tại”, “ký kết”, “chỉ huy”, “gây hệ quả”). Đầu ra được ràng buộc theo cặp (*head, relation, tail*) và kèm theo các trường: *name, type* $\in \{\text{person, organization, event, place, action, strategy, impact}\}$, chỉ báo nguồn và vị trí trích dẫn trong tài liệu. Trường “gợi ý thời gian” (năm hoặc khoảng năm nếu có) cũng được ghi nhận để hỗ trợ bước gắn mốc về sau.

Lưu trữ. Tri thức được nạp vào hai lớp kho dữ liệu. Lớp đồ thị (Neo4j) lưu *nút = thực thể* và *cạnh = RELATE_TO + mô tả*, đi kèm siêu dữ liệu nguồn, chương–mục và vị trí trang. Lớp thời gian (SQL) lưu thuộc tính *year_start, year_end* cho sự kiện và các thực thể có mốc, dùng chung khoá liên kết với lớp đồ thị để hỗ trợ truy vấn theo thời gian ngay từ đầu. Cách tách lớp này giúp giữ đồ thị gọn, đồng thời cho phép tối ưu hoá các phép lọc theo mốc ở tầng truy xuất và tái xếp hạng.

Lựa chọn thiết kế cho miền lịch sử và MCQ. Qua thử nghiệm, trả lời dựa trên các bản tóm tắt cộng đồng và truy vấn toàn cục không mang lại hiệu quả cao cho bài toán trắc nghiệm nhiều lựa chọn. Vì vậy hệ thống không sử dụng *community report* hay chú giải đám đông; toàn bộ tri thức được dựng trực tiếp từ nguồn và liên kết ngược tới đoạn bằng chứng. Thiết kế này ưu tiên khả năng kiểm chứng, giảm nguy cơ tóm tắt sai lệch ở quy mô lớn và phù hợp với yêu cầu bám sát mốc thời gian, thực thể và quan hệ cụ thể của từng câu hỏi.



Hình 3.3: Luồng trích xuất, chuẩn hoá và lưu trữ thực thể–quan hệ trước khi nạp vào đồ thị và kho thời gian.

3.3 Entity Alignment

Mục tiêu của bước căn chỉnh thực thể là xoá trùng và thống nhất cách gọi để mỗi nhân vật, sự kiện, tổ chức hay địa điểm chỉ còn một nút đại diện trong đồ thị. Trong tài liệu lịch sử, cùng một thực thể có thể xuất hiện với nhiều tên theo thời kỳ, phiên âm hoặc biệt danh (ví dụ “Liên Xô”, “Soviet”, “Soviet Union”). Nếu không xử lý, đồ thị bị phân mảnh, đường dẫn quan hệ đứt mạch và truy xuất thường trả về các tiểu đồ thị vừa to vừa loãng, gây khó khăn cho lập luận theo trình tự thời gian và nhân-quả.

Quy trình căn chỉnh diễn ra theo các bước tuần tự. Trước hết, toàn bộ thực thể đã trích được chuẩn hoá sơ bộ về chuỗi (loại ký tự thừa, thống nhất hoa-thường, chuẩn dấu) và được nhóm chặn theo loại thực thể, gọi ý thời gian và mức gần nhau về tên. Trên từng nhóm chặn, hệ thống tính điểm tương đồng dựa trên tên, mô tả ngắn và giao cắt thời gian để tạo cụm ứng viên. Các cụm này được đưa vào mô hình để hợp nhất ngữ nghĩa với đầu ra gồm tên chuẩn đề xuất, danh sách tên gọi khác (aliases), mô tả tóm tắt thống nhất và mức tin cậy. Những trường hợp dưới ngưỡng tin cậy được gắn nhãn xem lại thủ công để tránh gộp nhầm thực thể khác thời kỳ hoặc khác loại.

Việc chọn tên chuẩn ưu tiên tên tiếng Việt thông dụng trong nguồn liệu. Khi đã chốt cụm, mô tả được hợp nhất thành một bản tóm lược ngắn

có liên kết ngược về nguồn; các cạnh liên quan được dồn về nút chuẩn, loại bỏ cạnh trùng và hoà trộn thuộc tính trùng lặp. Phần thời gian được hợp nhất theo nguyên tắc thận trọng: nếu các biến thể có mốc khác nhau, hệ thống tạo khoảng bao phủ hợp lý và gắn nhãn độ tin cậy để xử lý bổ sung ở bước ràng buộc thời gian.

Cùng với cập nhật đồ thị, hệ thống duy trì bảng ánh xạ `merge_map(old_id, canonical_id, alias, source)` để bảo toàn truy vết nguồn và cho phép tra cứu theo bất kỳ tên nào người dùng nhập. Bảng này cũng hỗ trợ cập nhật hàng loạt cạnh, tránh sót tham chiếu về các thực thể cũ. Chất lượng căn chỉnh được kiểm soát bằng các ràng buộc mềm: chỉ gộp khi loại thực thể trùng khớp; khi mốc thời gian mâu thuẫn thì không gộp tự động; và yêu cầu đáp ứng ít nhất hai trong ba tín hiệu mạnh (chuỗi, ngữ nghĩa, thời gian). Báo cáo kiểm thử cuối mỗi vòng căn chỉnh ghi nhận tỉ lệ giảm thực thể và cạnh, số cụm cần duyệt tay và các trường hợp biên để theo dõi.

Kết quả là một đồ thị gọn và nhất quán hơn: mỗi thực thể duy nhất có một mã chuẩn, danh sách tên gọi khác được lưu đầy đủ, các cạnh đã hợp nhất và nguồn gốc được bảo toàn. Nhờ vậy, các phép duyệt lân cận, truy xuất theo đường đi và lập luận theo trình tự thời gian–nhân–quả trở nên rõ ràng và đáng tin cậy hơn.

3.4 Answer Candidates Filtering

Mục tiêu của bước lọc phương án là loại sớm các đáp án kém khả dĩ trước khi truy xuất, bắt chước chiến lược của thí sinh giỏi: đọc câu hỏi, loại nhanh các lựa chọn gây nhiễu, rồi mới tra cứu sâu cho các ứng viên còn lại. Với bài toán MCQ có bốn lựa chọn $A = \{a_1, a_2, a_3, a_4\}$ và một đáp án đúng, nếu truy xuất đồng thời cho cả bốn, các phương án gây nhiễu dễ kéo ngữ cảnh lệch hướng và làm phình to cửa sổ ngữ cảnh.

Cơ chế chấm điểm. Hệ thống ước lượng độ khả dĩ của từng phương án a_i so với câu hỏi q :

$$P(a_i | q) = \text{LLM_score}(q, a_i),$$

trong đó LLM_score là điểm do mô hình chấm dựa vào kiến thức nội tại. Từ các điểm này, giữ lại tập ứng viên vượt ngưỡng tin cậy θ :

$$\mathcal{A}^* = \{a_i \in A \mid P(a_i | q) \geq \theta\}.$$

Sau khi có $\mathcal{A}^*$, truy xuất được thực hiện riêng cho từng phương án còn lại; mỗi phương án đi kèm một gói bằng chứng độc lập (không trộn lẫn) để so sánh đối chiếu ở bước tiếp theo. Việc tách gói bằng chứng theo phương án giúp hạn chế nhiễu chéo

3.5 Graph & Temporal Retrieval

Mục tiêu của bước này là hình thành một ngữ cảnh có cấu trúc và đúng mốc thời gian để phục vụ bước sinh cuối. Truy vấn đầu vào gồm câu hỏi và tập phương án đã lọc $\mathcal{A}^*$; hai tín hiệu này được mã hoá thành một biểu diễn thống nhất để dẫn dắt truy xuất trên đồ thị và trên kho thời gian.

Truy xuất trên đồ thị. Truy vấn q được mã hoá thành vector v_q . Mỗi thực thể e trong đồ thị có vector v_e được suy ra từ tên và mô tả chuẩn hoá. Độ tương tự được tính bằng

$$\text{sim}(q, e) = \cos(v_q, v_e),$$

từ đó chọn ra tập thực thể đạt ngưỡng δ :

$$\mathcal{E}_{\text{retrieved}} = \{e \in \mathcal{E} \mid \text{sim}(q, e) \geq \delta\}.$$

Với mỗi thực thể đã lấy, hệ thống mở rộng lân cận ở độ sâu nhỏ (ưu tiên cạnh có mô tả phù hợp với câu hỏi và phương án còn lại) để tạo thành tiểu đồ thị liên quan, kèm theo các thuộc tính mô tả và vị trí bằng chứng trong tài liệu gốc. Mục tiêu là giữ một cấu trúc gọn, đủ đường đi cần thiết để giải thích quan hệ giữa sự kiện, nhân vật, địa điểm và tổ chức gắn với truy vấn.

Truy xuất theo thời gian. Khi truy vấn có mốc thời gian t_q hoặc có thể suy ra khoảng mốc, hệ thống xác định cửa sổ

$$[t_{\text{start}}, t_{\text{end}}] = [t_q - \Delta t, t_q + \Delta t],$$

rồi lọc các sự kiện và thực thể trong kho thời gian theo cửa sổ này. Các mốc mở/đóng được xử lý nhất quán; nếu thiếu mốc cụ thể, hệ thống dùng “gợi ý thời gian” đã gắn ở bước trích xuất để ước lượng và chỉ giữ các bản ghi có giao cắt với $[t_{\text{start}}, t_{\text{end}}]$. Khi kết hợp với truy xuất trên đồ thị, ràng buộc thời gian được ưu tiên: các nút hoặc cạnh ngoài khoảng sẽ bị loại hoặc hạ xếp hạng.

Hợp nhất ngữ cảnh. Ngữ cảnh cuối cùng được hợp nhất từ ba nguồn: $\mathcal{E}_{\text{graph}}$ là tập thực thể và đường đi lấy từ đồ thị; $\mathcal{E}_{\text{temporal}}$ là kết quả lọc theo thời gian; $\mathcal{T}_{\text{textchunk}}$ là các trích đoạn gốc đi kèm tham chiếu nguồn. Kết quả được ràng buộc bởi ngân sách ngữ cảnh, ưu tiên bằng chứng “tối thiểu đủ dùng”: đường đi ngắn, đúng mốc, đúng thực thể và có trích dẫn rõ. Để tránh loãng thông tin, các mẫu bằng chứng trùng lặp được gộp, còn các đoạn mâu thuẫn ngoài khoảng thời gian hợp lệ sẽ bị loại. Với bài toán nhiều lựa chọn, ngữ cảnh được giữ theo từng phương án để bước tái xếp hạng so sánh đối chiếu một cách minh bạch trước khi sinh đáp án.

3.6 Reranking

Sau truy xuất, số lượng mục ngữ cảnh thường lớn do tập trung nhiều sự kiện tại cùng một giai đoạn. Nếu đưa quá nhiều vào prompt, tín hiệu bị loãng và có nguy cơ vượt cửa sổ ngữ cảnh. Bước tái xếp hạng vì thế nhằm chọn ra phần nhỏ thông tin thật sự hữu ích: những sự kiện tiêu biểu cho khoảng thời gian đang xét, các quan hệ then chốt giữa thực thể và bằng chứng sát với câu hỏi.

Thay vì dùng bộ chấm điểm tĩnh, hệ thống yêu cầu mô hình lựa chọn k mục ngữ cảnh tốt nhất cho truy vấn q :

$$\mathcal{C}_q^{\text{top-}k} = \text{Select}(q, \mathcal{C}_q, k),$$

trong đó $\text{Select}(\cdot)$ là hàm tượng trưng cho việc LLM đánh giá các dữ kiện cần thiết. Giá trị k được giữ nhỏ để prompt gọn và tập trung, nhưng vẫn đủ bao phủ chuỗi bằng chứng tối thiểu cần thiết.

Quy trình lựa chọn gồm hai nhịp. Nhịp một sàng lọc nhanh theo ràng buộc thời gian và tính trùng lặp, loại bỏ bằng chứng ngoài khoảng hoặc lặp nội dung. Nhịp hai là chấm điểm có hướng dẫn: mô hình biện giải vì sao mỗi mục phù hợp với truy vấn (đúng mốc, đúng thực thể, góp phần phân biệt giữa các phương án) rồi trả về tập $\mathcal{C}_q^{\text{top-}k}$. Khi câu hỏi thuộc dạng nhiều lựa chọn, ngữ cảnh được giữ theo từng phương án để so sánh đối chiếu; sau đó hợp nhất theo nguyên tắc “bằng chứng tối thiểu đủ dùng”, ưu tiên đường dẫn ngắn và rõ trên đồ thị kèm trích đoạn nguồn tương ứng.

Kết quả là một ngữ cảnh gọn, có cấu trúc và đúng mốc thời gian, giúp câu trả lời cuối tăng độ chính xác và nhất quán theo bằng chứng. Khác với cách dùng các bản tóm tắt cộng đồng, hệ thống dựa vào căn chỉnh thực thể, truy xuất theo thời gian và tái xếp hạng do mô hình dẫn dắt để hình thành ngữ cảnh trọng tâm. Toàn bộ quy trình vận hành trên ba kho: đồ thị tri thức (Neo4j), cơ sở dữ liệu thời gian (SQL) và chỉ mục vector (Milvus) để hỗ trợ tìm kiếm lại.

Chương 4

Thực nghiệm

Chương này mô tả dữ liệu, cấu hình hệ thống và các thiết lập then chốt dùng để đánh giá hiệu quả của **HisGraphRAG** cho bài toán hỏi–đáp lịch sử tiếng Việt. Mục tiêu là đảm bảo tính tái lập và làm rõ bối cảnh mà các kết quả ở các mục sau được rút ra.

4.1 Dữ liệu

Kho truy xuất. Nguồn tri thức để lập chỉ mục và xây đồ thị tri thức là SGK Lịch sử 12 (chương trình phổ thông). Tài liệu có cấu trúc chương–mục rõ ràng, gồm văn bản, hình minh họa, biểu đồ và dòng thời gian. Trước khi lập chỉ mục, dữ liệu được tiền xử lý theo pipeline ở Chương 3. Các bước cốt lõi gồm: chuyển PDF sang văn bản giàu nội dung (mỗi trang được chuyển ảnh, phần hình/biểu đồ được mô tả lại bằng ngôn ngữ tự nhiên để bảo toàn thông tin); lọc nhiễu (loại bỏ câu hỏi, bài tập để tránh lệch truy xuất); và chia đoạn theo cấu trúc chương–mục có chồng lấn. Kết quả là một kho tri thức mạch nghĩa, phù hợp để trích xuất thực thể–quan hệ–sự kiện, lập chỉ mục vector và gắn mốc thời gian.

Tập đánh giá. Bài toán downstream là trắc nghiệm hỏi–đáp lịch sử theo chuẩn thi quốc gia. Sử dụng đề **VUEE 2017** và **VUEE 2018**, mỗi năm chọn **03** mã đề chính thức, tổng cộng **120** câu hỏi/năm ($3 \text{ bộ} \times 40$

câu). Mỗi câu có 1 đáp án đúng, giữ nguyên định dạng kỳ thi và được dùng nguyên bản cho suy luận (không huấn luyện, không bổ sung nhãn).

Bộ dữ liệu	Số mã đề	Số câu hỏi
VUEE-2017	3	120
VUEE-2018	3	120
Tổng	6	240

Bảng 4.1: Thống kê bộ đề đánh giá (mỗi câu gồm 4 lựa chọn A/B/C/D).

4.2 Cấu hình thực nghiệm

Hệ thống được tổ chức theo kiến trúc mô-đun, kết hợp LLM, cơ sở dữ liệu đồ thị và tìm kiếm vector. Các thành phần và siêu tham số chính như sau:

- **Mô hình ngôn ngữ chính.** ChatGPT-4o mini dùng cho các bước suy luận có cấu trúc: căn chỉnh thực thể, reranking ngữ cảnh và sinh đáp án cuối. Ưu điểm là hỗ trợ ngữ cảnh dài và tuân thủ hướng dẫn tốt trong môi trường truy xuất có cấu trúc.
- **Mô hình embedding.** text-embedding-3-small dùng cho truy xuất đặc dày và tính tương tự ngữ nghĩa. Tất cả thực thể và truy vấn/câu hỏi được mã hoá và lưu trữ để tìm gần láng giềng hiệu quả.
- **CSDL đồ thị.** Neo4j lưu trữ *thực thể* (nút) và *quan hệ* dạng RELATE_TO (cạnh) kèm mô tả ngôn ngữ tự nhiên, hỗ trợ duyệt lân cận để hợp thành tiểu đồ thị ngữ cảnh.
- **CSDL vector.** Milvus lưu trữ embedding và hỗ trợ tìm kiếm tương tự hiệu năng cao cho top- k đoạn/ngữ cảnh.
- **Các siêu tham số.**

- *Cửa sổ thời gian (Temporal Window)*: trích mốc thời gian từ truy vấn và áp dụng ± 1 năm để thu hồi sự kiện liên quan.
 - *Ngưỡng lọc phương án (Answer Filtering Threshold)*: loại các lựa chọn có độ tin cậy mô hình ước lượng $< 15\%$.
 - *Top-k rerank*: sau truy xuất, LLM chọn **top 15** mục ngữ cảnh hữu ích nhất cho bước suy luận cuối, đảm bảo prompt gọn mà giàu tín hiệu.
- **Nền triển khai.** Hệ thống được phát triển dựa trên và mở rộng từ bản mã nguồn mở *GraphRAG*¹, kết hợp thêm các thành phần *căn chỉnh thực thể*, *lọc phương án MCQ* và *truy xuất theo thời gian* như nêu ở Chương 3.

Ghi chú. Quy trình thực nghiệm gồm hai pha: *indexing* (tiền xử lý PDF $\rightarrow$ chunking theo cấu trúc $\rightarrow$ trích xuất thực thể/quan hệ $\rightarrow$ căn chỉnh thực thể $\rightarrow$ nạp Neo4j/Milvus/SQL) và *querying* (lọc phương án $\rightarrow$ truy xuất đồ thị + lọc theo thời gian $\rightarrow$ LLM-rerank $\rightarrow$ sinh đáp án). Các tham số $T_{\max}$, Δt , δ , k , θ được giữ nhất quán xuyên suốt các thí nghiệm để so sánh công bằng giữa LLM-only, NaiveRAG, GraphRAG cơ sở và HisGraphRAG.

4.3 Kết quả

Mục này trình bày kết quả theo ba góc độ: (i) *chi phí lập chỉ mục* khi có/không có căn chỉnh thực thể; (ii) *hiệu năng truy vấn* của các cấu hình so sánh trên hai bộ VUEE; (iii) *phân tích lỗi minh họa* để làm rõ đóng góp của từng thành phần trong HisGraphRAG.

¹<https://github.com/ImmortalDemonGod/nanographrag>

4.3.1 Kết quả lập chỉ mục (Indexing)

Để đánh giá chi phí của bước *căn chỉnh thực thể*, chúng tôi đo số *token vào/ra* và *thời gian* trong pha indexing, với hai cấu hình: không căn chỉnh và có căn chỉnh. Bảng 4.2 cho thấy khi bật căn chỉnh, số token vào tăng khoảng **+10.6%** (605k $\rightarrow$ 669k) và token ra tăng (190k $\rightarrow$ 219k) do sinh tóm tắt/hợp nhất quan hệ. Tuy nhiên, *thời gian tổng* giảm nhẹ (322s $\rightarrow$ 270s), gợi ý rằng đồ thị gọn-mạch nghĩa hơn giúp các bước xử lý downstream ít phân tán.

Chỉ tiêu	w/o entity alignment	with entity alignment
Token vào (In)	605k	669k
Token ra (Out)	190k	219k
Thời gian (giây)	322	270

Bảng 4.2: Tiêu thụ LLM trong pha lập chỉ mục (indexing).

4.3.2 Kết quả truy vấn (Querying)

Tôi so sánh LLM-only, NaiveRAG, GraphRAG và các biến thể gia tăng (alignment, temporal & rerank, option filtering), cùng hệ **HisGraphRAG** tích hợp đầy đủ. Bảng 4.3 báo cáo độ chính xác, token tiêu thụ và thời gian trên VUEE-2017/2018.

Nhận xét. (i) LLM-only có độ chính xác thấp nhất (68.3%/50.8%) (ii) NaiveRAG tăng vừa phải (72.5%/54.2%), cho thấy tăng cường bằng chứng dù đơn giản vẫn có hiệu quả. (iii) GraphRAG cơ sở nâng rõ rệt (77.5%/60.0%) nhờ cấu trúc thực thể-quan hệ. (iv) Entity Alignment cho kết quả “pha trộn”: giảm nhẹ 2017 (76.7%) nhưng tăng 2018 (61.7%), hàm ý rằng căn chỉnh phát huy khi dữ liệu có nhiều sự mơ hồ/trùng tên. (v) Temporal & Rerank nếu tách riêng có thể kéo xuống (73.3%/56.7%) do “nạp” quá nhiều bằng chứng theo thời gian chưa đủ liên quan, làm phình prompt và lãng phí hiệu. (vi) Answer Filtering cải thiện mạnh

Phương pháp	VUEE-2017			VUEE-2018		
	Acc	Token	Time	Acc	Token	Time
LLM-only	68.3%	22k	0.67s	50.8%	23k	0.67s
NaiveRAG	72.5%	102k	1.21s	54.2%	95k	1.25s
GraphRAG	77.5%	920k	1.75s	60.0%	907k	1.82s
GraphRAG + Entity alignment	76.7%	1.4M	3.14s	61.7%	1.4M	3.21s
GraphRAG + Temporal & Rerank	73.3%	1.7M	7.725s	56.7%	1.7M	6.44s
GraphRAG + Answer candidates Filter	80.8%	949k	3.2s	63.3%	983k	3s
HisGraphRAG (Ours)	81.7%	2.2M	8.14s	70.8%	1.6M	7.68

Bảng 4.3: Kết quả độ chính xác, token và thời gian trên VUEE-2017 và VUEE-2018.

(80.8%/63.3%), nhấn mạnh giá trị loại distractor trước truy xuất. Cuối cùng, **HisGraphRAG**—kết hợp đồng bộ Entity alignment + temporal + rerank + filtering—đạt **81.7%** (2017) và **70.8%** (2018), cao nhất trong tất cả cấu hình.

Về chi phí, HisGraphRAG tiêu thụ nhiều token hơn (2.2M/1.6M) và thời gian tiệm cận ~ 900 s, phản ánh các bước suy luận bổ sung. Trong bối cảnh *ưu tiên độ chính xác và tính giải thích* hơn độ trễ, chi phí này là chấp nhận được. Ngoài ra, mức độ khó cao hơn của VUEE-2018 khiến tất cả cấu hình suy giảm, song HisGraphRAG vẫn giữ *biên hiệu năng* tốt.

4.4 Phân tích lỗi

Mục tiêu của phần này là cho thấy vai trò cụ thể của từng thành phần trong pipeline khi xử lý câu hỏi lịch sử có nhiều mốc và thuật ngữ dễ gây nhiễu. Ví dụ dưới đây minh họa việc thu hẹp ngữ cảnh về phần cốt yếu nhờ căn chỉnh thực thể, ràng buộc thời gian và lọc phương án.

Câu hỏi ví dụ.

Tại Đại hội II (02/1951), Đảng Cộng sản Đông Dương quyết

định thành lập ở mỗi nước Đông Dương:

A. **Đảng Mác–Lênin** (đáp án đúng)

B. Chính phủ liên hiệp

C. Mặt trận thống nhất

D. Lực lượng vũ trang

Bảng 4.4 so sánh *GraphRAG* cơ sở và *HisGraphRAG* theo ba thành phần then chốt.

Thành phần	GraphRAG (không có phương pháp của chúng tôi)	HisGraphRAG (có phương pháp của chúng tôi)
Căn chỉnh thực thể	Thu hồi trùng lặp “ĐCS Đông Dương” / “Đảng Cộng sản của Đông Dương”, chiếm chỗ prompt và trùng thông tin.	Gộp về dạng chuẩn “Đảng Cộng sản Đông Dương”, giảm dư thừa, tăng độ rõ của quan hệ.
Truy xuất theo thời gian	Lấy cả các đại hội I/III không liên quan, làm nhiều quyết nghị.	Trích năm 1951 , lọc sự kiện trong khung ± 1 năm, loại các đại hội ngoài cửa sổ.
Lọc phương án (MCQ)	Ngữ cảnh lan man về “chính phủ liên hiệp” ở bối cảnh khác, dễ kéo mô hình chọn B.	Ước lượng khả dĩ, loại phương án kém phù hợp trước truy xuất, giữ ngữ cảnh sát đáp án.

Bảng 4.4: Tác động của từng thành phần trong HisGraphRAG trên ví dụ minh họa.

Kết luận ngắn. Ba thành phần—căn chỉnh thực thể, truy xuất theo thời gian và lọc phương án—phối hợp để giữ lại bằng chứng tối thiểu đủ dùng, giúp mô hình nhận diện đúng đáp án **Đảng Mác–Lênin** thay vì bị kéo lệch sang “Mặt trận thống nhất” hay “Chính phủ liên hiệp”. Khi bật riêng lẻ từng thành phần, lợi ích có thể chưa rõ rệt; nhưng khi tích hợp theo

pipeline của HisGraphRAG, độ chính xác và tính nhất quán theo bảng chứng được cải thiện rõ.

Chương 5


Áp dụng mô hình vào ứng dụng thực tế

Sau khi hoàn tất bài báo, chúng tôi xây dựng một ứng dụng hoàn chỉnh để **trực quan hoá kết quả** và **vận hành cập nhật tri thức** theo thời gian. Lưu ý rằng các chỉ số thời gian/token trong triển khai thực tế có thể *khác* so với báo cáo thực nghiệm ở các chương trước do khác biệt về hạ tầng, tối ưu hoá I/O và chính sách gọi mô hình.

Lý do xây dựng ứng dụng. (1) Cần một công cụ UI để *quan sát tức thời* tác động của từng thành phần (alignment, temporal, filtering, rerank) lên câu trả lời; (2) Các đề thi gần đây thường gắn với *sự kiện thời sự*, do đó cần một luồng tự động để nạp nguồn mới (bài báo/chuyên đề) và liên hệ với tri thức lịch sử cũ.

5.1 Kết quả đánh giá ứng dụng mô hình vào ứng dụng di động

Hình 5.1 mô tả kiến trúc triển khai gồm bốn lớp: **Datasource** (nguồn liệu), **Automation Tool** (Jenkins), **Database tier** (Neo4j, Milvus, Post-



Hình 5.1: Kiến trúc triển khai ứng dụng HisGraphRAG (số đánh dấu 1–4 tương ứng với các luồng chính).

greSQL), và **Application UI** (Chainlit). Mô hình ngôn ngữ (LLM) được dùng ở cả giai đoạn tiền xử lý (alignment, tóm tắt) lẫn suy luận trực tiếp trong giao diện.

(1) Datasource → Jenkins. Nguồn liệu gồm: SGK Lịch sử 12 (PDF), bài viết/chuyên đề mở rộng, và khi cần sẽ thêm các nguồn thời sự (tin tức được phê duyệt). Jenkins định kỳ kéo dữ liệu mới, thực thi *pipeline indexing*: chuyển PDF → ảnh, VLM trích xuất mô tả hình; chia đoạn theo chương–mục; trích xuất thực thể/quan hệ; gắn mốc thời gian; *căn chỉnh thực thể* bán tự động và đưa nội dung đó vào đồ thị tri thức.

(2) **Jenkins** $\leftrightarrow$ **LLM**. Trong indexing, Jenkins gọi LLM cho các tác vụ: mô tả hình, chuẩn hoá-hợp nhất thực thể (entity alignment), sinh mô tả quan hệ, và tóm tắt phục vụ tìm kiếm. Ở chế độ *cẩn trọng chi phí*, Jenkins thực hiện *batching*, *caching* và kiểm soát tốc độ (rate limit) để giảm token.

(3) **Jenkins** $\leftrightarrow$ **Database tier**. Kết quả indexing được đẩy vào:

- **Neo4j** (KG): nút = thực thể (person, org, event, place, action, strategy, impact); cạnh = `RELATE_TO` + mô tả.
- **Milvus** (Vector DB): lưu embedding của chunk, thực thể, câu hỏi, phương án.
- **PostgreSQL** (Temporal SQL): lưu mốc/khoảng thời gian của sự kiện/thực thể để lọc theo cửa sổ thời gian.

Jenkins chịu trách nhiệm *(re)build gia tăng*: chỉ cập nhật phần thay đổi, đảm bảo downtime thấp.

(4) **Ứng dụng (Chainlit)** $\leftrightarrow$ **Người dùng & LLM**. Giao diện được xây dựng bằng **Chainlit** để có trải nghiệm chat, hiển thị *tiểu đồ thị* liên quan, trích dẫn và giải thích đường dẫn. Luồng truy vấn:


1. Người dùng đặt câu hỏi (có thể dạng MCQ).
2. Ứng dụng lọc phương án (option-aware), *temporal parsing* sinh cửa sổ thời gian.
3. Truy xuất song song: Milvus (đoạn/embedding) + Neo4j (lân cận thực thể/quan hệ) + PostgreSQL (lọc theo thời gian).
4. *LLM reranking* chọn *top-k* ngữ cảnh gọn và có căn cứ; sau đó LLM sinh câu trả lời, cùng phần giải thích/đường dẫn.

Lý do chọn luồng trên. Jenkins đơn giản, ổn định cho CI/CD và cron pipelines; Neo4j có khả năng duyệt đồ thị linh hoạt (pattern matching); Milvus tối ưu tìm kiếm gần-láng-giềng cho embedding quy mô lớn; PostgreSQL thuận lợi cho truy vấn thời gian/biên mốc; Chainlit giúp hiện

thực UI hội thoại nhanh, hỗ trợ hiển thị JSON/đồ thị/trích dẫn; LLM (ChatGPT-4o mini + embedding) phù hợp cho alignment, rerank và sinh đáp án.

Triển khai và vận hành. Các dịch vụ chạy dạng container; logging tập trung (application + Jenkins + DB); giám sát qua metrics & tracing (latency truy xuất, token usage, tỉ lệ dùng bằng chứng). Cơ chế *feature flags* cho phép bật/tắt Alignment, Temporal, Filtering, Rerank để A/B test ngay trong ứng dụng. Về bảo mật: tách kho dữ liệu nội bộ, ẩn khoá API, và lưu audit cho truy vấn nhạy cảm.


5.2 Kết quả đánh giá ứng dụng



id	vector
https://tuoitre.vn/-den-hen-khong-tra-luong-cho-tai-xe-nhieu-tuyen-xe-buyt-da-nang-van-nam-bat-dong-20230708161057187.htm_0	[0.011616721749305725,0.0037128226831...
https://tuoitre.vn/1-000-doan-vien-phu-tho-lam-hang-rao-mem-chong-un-tac-trong-ngay-gio-to-20240415155820569.htm_0	[0.02405758760869503,-0.025850825011...
https://tuoitre.vn/1-000-hoc-bong-chinh-phu-du-hoc-lien-bang-nga-20240222131139699.htm_0	[-0.015090661123394966,-0.0047423834...
https://tuoitre.vn/1-000-phan-qua-trung-thu-cho-benh-nhi-ung-thu-20240911160754288.htm_0	[0.025308819487690926,0.03039809316...
https://tuoitre.vn/1-000-phong-nghe-du-lich-mang-den-van-co-the-qua-tai-du-khach-dung-chu-quan-20240422141002125.htm_0	[0.02719414234161377,0.0302634574472...
https://tuoitre.vn/1-001-cau-hoi-kho-do-cua-phu-huynh-nguoi-viet-voi-giao-vien-ban-ngu-day-tieng-anh-20240909101955613.htm_0	[-0.0037669730372726917,-0.0328001677...
https://tuoitre.vn/1-156-tre-da-duoc-tiem-vac-xin-soi-trong-truong-hoc-20240908075047678.htm_0	[-0.01710093580186367,-0.00934953242...
https://tuoitre.vn/1-3-nguoi-mua-sam-giang-sinh-mat-tien-vi-lo-thong-tin-ca-nhan-20181227121031789.htm_0	[0.038454122841358185,0.018072828650...
https://tuoitre.vn/1-4-gen-y-va-z-o-my-noi-khong-co-y-dinh-tro-thanh-cha-me-vi-ly-do-tai-chinh-20240917232533304.htm_0	[0.05803413689136505,0.0649136826395...
https://tuoitre.vn/1-4-trieu-dong-gui-luc-toi-cua-bac-tai-xe-xe-ba-gac-que-nghe-an-20240911180556736.htm_0	[0.055497463792562485,0.004817621316...
https://tuoitre.vn/1-chiec-ao-dep-mac-hoai-cung-nham-du-lich-viet-can-them-nhieu-ao-moi-20200519095453158.htm_0	[0.008225546218454838,-0.01560486294...
https://tuoitre.vn/1-ti-dong-cua-giao-su-le-ngoc-thach-da-duoc-tat-toan-som-de-ung-ho-mien-bac-20240911163635433.htm_0	[0.038017026752233505,-0.017355184512...

Hình 5.2: Dữ liệu lịch sử được embedding.

Phần này sẽ bao gồm các giao diện của ứng dụng nhằm trực quan hoá các nội dung của phương pháp xây dựng HisGraphRAG ở trên. Giao diện sẽ bao gồm phần giới thiệu cơ bản về chatbox như hình 5.4. Sau đó là kết



Hình 5.3: Giao diện công cụ tự động.

quả trả lời một câu hỏi bất kì và kết quả của các bước truy vấn từ các kho dữ liệu để thêm vào ngữ cảnh câu hỏi: các thực thể ở 5.6, các mối quan hệ ở 5.7 và các thông tin về các sự kiện theo thời gian ở 5.5. Kết quả cuối cùng của mô hình đã dựa vào nội dung nào để đưa ra câu trả lời dựa vào các dữ kiện đã cho sẽ được trực quan ở 5.8

Ghi chú. Ứng dụng cho phép nạp nhanh nguồn mới (thời sự) và tự động liên kết với sự kiện lịch sử trong KG; do vậy, số liệu hiệu năng và độ chính xác có thể thay đổi theo thời gian, phản ánh tốc độ cập nhật tri thức.

HistoryGraphRAG Assistant

Chào mừng bạn đến với hệ thống trả lời câu hỏi lịch sử dựa trên GraphRAG!

Hệ thống sử dụng:

- 🔍 Vector Database (Milvus) để tìm kiếm thực thể
- 🕸 Graph Database (Neo4j/NetworkX) để phân tích quan hệ
- 🗄 PostgreSQL để lưu trữ thông tin thực thể
- 🗣 LLM để rerank và tạo câu trả lời

Cách sử dụng:

Nhập câu hỏi trắc nghiệm lịch sử của bạn và hệ thống sẽ phân tích qua các bước:

1. Tìm kiếm thực thể liên quan
2. Truy vấn cơ sở dữ liệu
3. Rerank kết quả
4. Tạo câu trả lời

Hãy thử đặt câu hỏi!

 ✅ Hệ thống đã sẵn sàng! Bạn có thể bắt đầu đặt câu hỏi.

Hình 5.4: Giao diện người dùng.

Used  PostgreSQL Results ^

Retrieved 10 records from PostgreSQL:

1. ĐÔNG DƯƠNG ĐẠI HỘI

- Time: 1936 (Distance: 0)
- Description: Đông Dương Đại hội là một sự kiện dự kiến sẽ diễn ra vào tháng 8 năm 1936, nhằm tập hợp nhân dân gửi...

2. HỘI NGHỊ BAN CHẤP HÀNH TRUNG ƯƠNG ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG

- Time: 1936 (Distance: 0)
- Description: Hội nghị Ban Chấp hành Trung ương Đảng Cộng sản Đông Dương được tổ chức vào tháng 7 năm 1936, do Lê ...

3. BỐI CẢNH XÃ HỘI VIỆT NAM

- Time: 1930 (Distance: 6)
- Description: Bối cảnh xã hội Việt Nam trong những năm 1929 – 1933 là một thời kỳ đầy thử thách do khủng hoảng kin...

4. ĐÔNG DƯƠNG CỘNG SẢN ĐẢNG

- Time: 1929 (Distance: 7)
- Description: Đông Dương Cộng sản đảng là một chính đảng được thành lập nhằm thay thế Hội Việt Nam Cách mạng Thanh...

5. CUỘC VẬN ĐỘNG DÂN CHỦ 1936 – 1939

- Time: N/A
- Description: Cuộc vận động dân chủ 1936 – 1939 là một phong trào quần chúng rộng lớn dưới sự lãnh đạo của Đảng Cộ...

Hình 5.5: Nội dung các sự kiện theo thời gian.

Used ☒ Vector DB Results ^

Found 20 entities:

1. **ĐÔNG DƯƠNG ĐẠI HỘI**

- Similarity: 0.3694

2. **CUỘC VẬN ĐỘNG DÂN CHỦ 1936 – 1939**

- Similarity: 0.4329

3. **ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG**

- Similarity: 0.4657

4. **HỘI LIÊN HIỆP QUỐC DÂN VIỆT NAM (LIÊN VIỆT)**

- Similarity: 0.4752

5. **BỐI CẢNH XÃ HỘI VIỆT NAM**

- Similarity: 0.4762

6. **ĐÌNH BẢNG**

- Similarity: 0.4778

7. **ĐÔNG DƯƠNG CỘNG SẢN ĐẢNG**

- Similarity: 0.4803

8. **VIỆT NAM NGHĨA ĐOÀN**

- Similarity: 0.4846

9. **ĐẢNG CỘNG SẢN VIỆT NAM**

- Similarity: 0.4893

10. **HỘI NGHỊ BAN CHẤP HÀNH TRUNG ƯƠNG ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG**

- Similarity: 0.4910

... and 10 more entities

Hình 5.6: Kết quả truy vấn các thực thể.

Used ☒ Graph DB Results ^

Graph Statistics:

- Nodes: 10
- Edges: 24

Sample Nodes:

- **ĐÔNG DƯƠNG ĐẠI HỘI** (EVENT)
- **CUỘC VẬN ĐỘNG DÂN CHỦ 1936 – 1939** (EVENT)
- **ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG** (ORGANIZATION)
- **HỘI LIÊN HIỆP QUỐC DÂN VIỆT NAM (LIÊN VIỆT)** (ORGANIZATION)
- **BỐI CẢNH XÃ HỘI VIỆT NAM** (PLACE)

Sample Relationships:

- CUỘC VẬN ĐỘNG DÂN CHỦ 1936 – 1939 → ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG
- ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG → ĐỜI SỐNG NHÂN DÂN
- ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG → ĐẠI HỘI VII
- ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG → CHÍNH PHỦ MẶT TRẬN NHÂN DÂN
- ĐẢNG CỘNG SẢN ĐÔNG DƯƠNG → ĐẢNG CÁCH MẠNG

Hình 5.7: Kết quả truy vấn trên đồ thị.

"Năm 1936, ở Việt Nam các ủy ban hành động được thành lập nhằm mục đích gì?

- A. Để lập ra các hội ái hữu thay cho Công hội đỏ, Nông hội đỏ.
- B. Chuẩn bị mọi mặt cho khởi nghĩa giành chính quyền.
- c. Biểu dương lực lượng khi đón phái viên của Chính phủ Pháp.
- D. Thu thập "dân nguyện" tiến tới Đông Dương Đại hội."

Kết quả

Câu hỏi: "Năm 1936, ở Việt Nam các ủy ban hành động được thành lập nhằm mục đích gì?

- A. Để lập ra các hội ái hữu thay cho Công hội đỏ, Nông hội đỏ.
- B. Chuẩn bị mọi mặt cho khởi nghĩa giành chính quyền.
- c. Biểu dương lực lượng khi đón phái viên của Chính phủ Pháp.
- D. Thu thập "dân nguyện" tiến tới Đông Dương Đại hội."

Câu trả lời: D

Giải thích (có trích dẫn nguồn):

Năm 1936, Ủy ban hành động ở Việt Nam được thành lập với mục tiêu thu thập "dân nguyện" và tiến tới tổ chức Đông Dương Đại hội [PostgreSQL: ĐÔNG DƯƠNG ĐẠI HỘI - năm 1936]. Đây là một phần trong phong trào dân chủ từ 1936-1939, khi Đảng Cộng sản Đông Dương phát động các hoạt động công khai nhằm tận dụng môi trường chính trị cởi mở hơn dưới chính phủ Mặt trận Bình dân Pháp [KG: CUỘC VẬN ĐỘNG DÂN CHỦ 1936 – 1939]. Các ủy ban này đã đóng vai trò quan trọng trong việc tập hợp nguyện vọng của người dân để đấu tranh vì cải cách xã hội và quyền tự do ngôn luận [Kiến thức chung]. Việc chuẩn bị cho Đông Dương Đại hội là cơ hội để thể hiện sức mạnh quần chúng và tạo áp lực cho thực dân Pháp [KG: PHONG TRÀO QUẦN CHÚNG].

Hình 5.8: Kết quả mô hình hỏi đáp.

Chương 6

Kết luận

6.1 Đóng góp của luận văn

Luận văn giới thiệu và hiện thực hoá **HisGraphRAG** — một khung RAG dựa trên đồ thị tri thức chuyên biệt cho hỏi–đáp lịch sử tiếng Việt, nhằm khắc phục ba điểm nghẽn chính của RAG/GraphRAG: (i) trùng lặp/không chuẩn hoá thực thể, (ii) thiếu ràng buộc thời gian trong truy xuất–xếp hạng, và (iii) nhiễu do phương án gây nhiễu (distractors) trong MCQ. Các đóng góp cụ thể:

- **Đóng góp phương pháp luận:** Đề xuất pipeline gồm bốn thành phần phối hợp chặt chẽ: *căn chỉnh thực thể, truy xuất nhận thức thời gian, lọc phương án trả lời và reranking*. Thiết kế này cho phép hình thành *tiểu đồ thị gọn, đúng mốt* và cung cấp ngữ cảnh đầy đủ cho LLM.
- **Đóng góp triển khai:** Xây dựng hệ thống end-to-end trên SGK Lịch sử 12: tiền xử lý, trích xuất thực thể/quan hệ (RELATE_TO), Neo4j (KG) + SQL thời gian + Milvus (vector), cùng chatbot Streamlit và pipeline Jenkins (CI/CD) để liên tục cập nhật đồ thị tri thức.
- **Đóng góp thực nghiệm:** Trên các bộ **VUEE-2017** và **VUEE-2018** (tổng 120 câu), **HisGraphRAG** đạt **81.7%** và **70.8%**, vượt

LLM-only, NaiveRAG và *GraphRAG* cơ sở. Phân tích cho thấy lọc phương án và căn chỉnh thực thể làm giảm nhiễu, còn ràng buộc thời gian giúp tôn trọng trình tự-nhân quả.

- **Đóng góp học thuật:** Một phần nội dung luận văn đã được công bố tại **PACLIC 2025** với bài báo “*HisGraphRAG: GraphRAG for Vietnamese Historical Question Answering*”, khẳng định tính mới và khả năng áp dụng của hướng tiếp cận trong miền lịch sử tiếng Việt.

6.2 Hạn chế

Mặc dù đạt được cải thiện rõ rệt về độ chính xác và tính dựa-bằng-chứng, hệ thống vẫn còn những hạn chế:

- **Chi phí tính toán/độ trễ:** Số token tiêu thụ và thời gian truy vấn tăng (tiệm cận $\sim 900s$ ở cấu hình đầy đủ), chưa phù hợp cho tác vụ thời gian thực hoặc khối lượng lớn.
- **Phụ thuộc LLM ở bước căn chỉnh thực thể:** Căn chỉnh bằng LLM cho độ chính xác cao nhưng tốn kém và khó mở rộng; thiếu các cơ chế ràng buộc dựa quy tắc/embedding để giảm chi phí.
- **Ràng buộc thời gian còn đơn giản:** Cửa sổ ± 1 năm là cài đặt cứng; với một số câu hỏi (*giai đoạn, kéo dài, trước-sau xa*) quy tắc này chưa tối ưu.
- **Đánh giá còn giới hạn:** Chủ yếu dựa trên *độ chính xác MCQ*; thiếu thước đo về *tính giải thích* (path reasoning), *độ tin cậy/viện dẫn*, *hiệu quả-chi phí*, và *nguyên cứu người dùng*.
- **Ontology và kiểm chứng con người:** Chưa xác lập/khai báo *ontology bậc cao* một cách đầy đủ trước khi trích xuất; mức độ *human-in-the-loop* (duyet tên chuẩn, kiểm tra căn chỉnh/rerank) còn hạn chế.

Các điểm yếu mà phản biện nêu (token/time lớn; alignment dựa LLM; cửa sổ thời gian cứng; phạm vi đánh giá; ontology; vai trò lọc phương án;

mức can thiệp thủ công) đã được phản ánh trong mục hạn chế ở trên và là kim chỉ nam cho hướng mở rộng sắp tới.

6.3 Hướng phát triển trong tương lai

Dựa trên kết quả và phản hồi phản biện, các hướng tiếp theo tập trung vào **giảm chi phí, tăng khả năng mở rộng, và mở rộng tiêu chí đánh giá/ứng dụng**:

- **Tối ưu hoá truy xuất thời gian:** Thay thế cửa sổ cố định bằng *temporal window học được* (learned/dynamic), nhận biết loại câu hỏi (*mốc, khoảng, trước-sau*) và tự điều chỉnh biên độ; chuẩn hoá mốc thời gian trong KG (định dạng, độ hạt, quan hệ bao-che, chồng lấn).
- **Căn chỉnh thực thể quy mô lớn:** Kết hợp *hybrid embedding + rule-based clustering* (alias, chính tả, phiên âm) trước khi gọi LLM để giảm token; thiết lập *ontology bậc cao* cho lịch sử Việt Nam và ràng buộc extraction theo ontology; bổ sung *human-in-the-loop* ở các điểm kiểm tra rủi ro cao (tên chuẩn, sự kiện then chốt).
- **Giảm chi phí tổng thể:** Áp dụng *cache/FAISS IVF-PQ, pruning* theo tín hiệu bất lợi, *batching/pipelining* truy vấn, *mixed-precision* và *distillation* (LLM nhỏ cho bước alignment/rerank); cân đối chiến lược top- k và cắt tỉa subgraph theo độ tin cậy.
- **Nâng tính giải thích và chất lượng câu trả lời:** Bắt buộc *path-based justification* (viện dẫn đường dẫn đồ thị), kiểm định bằng *verifier* độc lập; bổ sung thước đo *faithfulness, calibration* (độ tự tin), và phân tích lỗi có hệ thống.
- **Mở rộng đánh giá & dữ liệu:** Bổ sung tập dữ liệu lịch sử các khối lớp/nguồn khác, dạng câu hỏi tự do (generative QA) và *user study* (giáo viên/học sinh) về hữu dụng-giải thích-tốc độ; đánh giá *latency/throughput* và *chi phí* song hành với độ chính xác.

- **Hướng kỹ thuật nâng cao:** Khảo sát *community summaries* (kiểu GraphRAG Microsoft) và/hoặc *GNN/plan-over-graphs (RoG)* để tăng bao phủ đường dẫn; nghiên cứu tích hợp *global + local search* thích nghi theo truy vấn.
- **Triển khai thực tiễn:** Tối ưu hoá phiên bản *near real-time* cho ôn luyện/tra cứu: tiền tính toán subgraph phổ biến, cập nhật gia tăng (incremental indexing), và cơ chế degrade-gracefully khi tài nguyên hạn chế.

Tóm lại, **HisGraphRAG** cho thấy việc *kết hợp tri thức có cấu trúc và ràng buộc thời gian* là chìa khoá để cải thiện suy luận lịch sử của LLM. Trong khi chi phí tính toán vẫn là thách thức cần tối ưu, kết quả thực nghiệm và phản hồi tích cực từ cộng đồng học thuật (PACLIC 2025) khẳng định hướng tiếp cận này có giá trị và còn nhiều dư địa mở rộng cho các ứng dụng giáo dục và nghiên cứu lịch sử tiếng Việt.

Chương 7

Các công trình nghiên cứu

Nội dung của luận văn đã được công bố trong bài báo “HisGraphRAG: GraphRAG for Vietnamese Historical Question Answering” tại The 39th Pacific Asia Conference on Language, Information and Computation (PACLIC 2025)

Tài liệu tham khảo

Tiếng Anh

- [1] Lewis, Patrick et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP”. In: *Advances in Neural Information Processing Systems*. 2020. URL: <https://arxiv.org/abs/2005.11401>.
- [2] Ji, Ziwei et al. “Survey of Hallucination in Natural Language Generation”. In: *ACM Computing Surveys* (2023). URL: <https://arxiv.org/abs/2301.07069>.
- [3] Hogan, Aidan, Blomqvist, Eva, Cochez, Michael, et al. “Knowledge Graphs”. In: *ACM Computing Surveys* 54.4 (2021). DOI: 10.1145/3447772.
- [4] Gao, Luyu, Dai, Zhuyun, Callan, Jamie, et al. “Retrieval-Augmented Generation for Large Language Models: A Survey”. In: *arXiv preprint arXiv:2312.10997* (2024).
- [5] Robertson, Stephen and Zaragoza, Hugo. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389. DOI: 10.1561/15000000019.
- [6] Izacard, Gautier and Grave, Edouard. “Contriever: Unsupervised Dense Passage Retrieval”. In: *arXiv preprint arXiv:2112.09118* (2021). URL: <https://arxiv.org/abs/2112.09118>.

- [7] Gao, Luyu et al. “Precise Zero-Shot Dense Retrieval without Relevance Labels”. In: *arXiv preprint arXiv:2212.10496* (2023). HyDE: Hypothetical Document Embeddings. URL: <https://arxiv.org/abs/2212.10496>.
- [8] Khattab, Omar and Zaharia, Matei. “ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT”. In: *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2020, pp. 39–48. DOI: 10.1145/3397271.3401075.
- [9] Zhang, Hailong, Zhang, Zihan, Chen, Junxian, et al. “LLMLingua: Compressing Prompts for Accelerated Inference of Large Language Models”. In: *arXiv preprint arXiv:2310.05736* (2023). URL: <https://arxiv.org/abs/2310.05736>.
- [10] Wu, Ledell, Petroni, Fabio, Josifoski, Martin, et al. “Zero-shot Entity Linking with BLINK”. In: *EMNLP Findings*. 2020, pp. 1317–1327. URL: <https://arxiv.org/abs/1911.03814>.
- [11] Wu, Junde et al. “Medical Graph RAG: Towards Safe Medical Large Language Model via Graph Retrieval-Augmented Generation”. In: *arXiv preprint arXiv:2408.04187* (2024). URL: <https://arxiv.org/abs/2408.04187>.
- [12] Edge, Darren et al. “From Local to Global: A Graph RAG Approach to Query-Focused Summarization”. In: *arXiv preprint arXiv:2404.16130* (2024). URL: <https://arxiv.org/abs/2404.16130>.
- [13] LeCun, Yann et al. “Gradient-based Learning Applied to Document Recognition”. In: *Proceedings of the IEEE*. Vol. 86. 11. 1998, pp. 2278–2324. DOI: 10.1109/5.726791.
- [14] Hochreiter, Sepp and Schmidhuber, Jürgen. “Long Short-Term Memory”. In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

- [15] Goodfellow, Ian et al. “Generative Adversarial Nets”. In: *Advances in Neural Information Processing Systems*. 2014.
- [16] Vaswani, Ashish et al. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems*. 2017.