

Mục lục

1	Giới thiệu	4
1.1	Bối cảnh và động lực nghiên cứu	4
1.2	Vấn đề đặt ra: khoảng cách ngữ nghĩa giữa tín hiệu cộng tác và LLM	5
1.3	Khoảng trống nghiên cứu	6
1.4	Mục tiêu và đóng góp	7
1.5	Bố cục luận văn	9
2	Các công trình liên quan	10
2.1	Lọc cộng tác truyền thống	10
2.1.1	Phân rã ma trận	11
2.1.2	Lọc cộng tác dựa trên đồ thị	11
2.1.3	Hạn chế của lọc cộng tác thuần túy	11
2.2	Mô hình ngôn ngữ lớn cho hệ thống tư vấn	12
2.2.1	Hai hướng khai thác LLM	12
2.2.2	Rào cản về độ dài ngữ cảnh	13
2.3	Các phương pháp tích hợp CF vào LLM qua không gian véc-tơ	14
2.3.1	Chiếu tuyến tính: CoLLM	14
2.3.2	Học tương phản: SellaRec	14
2.3.3	Mã hóa dạng văn bản: BinLLM	15
2.3.4	Tiêm vào trọng số: CoRA	16
2.3.5	Cầu nối Q-Former: ILM	16
2.3.6	Tổng hợp so sánh	17

2.4	Nền tảng kiến trúc Q-Former	18
2.4.1	BLIP-2: Q-Former cho căn chỉnh ảnh-ngôn ngữ . .	18
2.4.2	InstructBLIP: Conditioning theo chỉ dẫn	19
2.4.3	Kỹ thuật ổn định từ Flamingo	19
2.5	Tổng kết và định vị luận văn	20
3	Phương pháp đề xuất	21
3.1	Tổng quan kiến trúc	21
3.2	Khối Phân rã ma trận	22
3.3	Cầu nối Q-Former: lõi phương pháp	24
3.3.1	Lý do chọn Q-Former thay lớp chiếu tuyến tính . .	24
3.3.2	Kiến trúc Q-Former thích nghi cho gợi ý	25
3.3.3	Hai đường đưa tín hiệu CF vào LLM	25
3.3.4	Kỹ thuật đảm bảo ổn định	26
3.4	Các lựa chọn thiết kế	27
3.4.1	Biểu diễn đa token cho tín hiệu CF	27
3.4.2	Backbone LLM đã instructed và định dạng ChatML	28
3.4.3	Tách lớp chiếu người dùng và vật phẩm	28
3.5	Tăng cường Q-Former theo InstructBLIP	29
3.5.1	Cơ chế conditioning theo chỉ dẫn	29
3.5.2	Thích nghi cho bài toán gợi ý	29
3.5.3	Kết quả và vị trí trong luận văn	30
3.6	Quy trình huấn luyện ba giai đoạn	30
3.6.1	Giai đoạn 1: Tiền huấn luyện biểu diễn	30
3.6.2	Giai đoạn 2: Tiền huấn luyện sinh	32
3.6.3	Giai đoạn 3: Tinh chỉnh CTR	32
3.7	Kết chương	32
4	Thực nghiệm và Kết quả	34
4.1	Thiết lập thực nghiệm	34
4.1.1	Tập dữ liệu	34
4.1.2	Phân chia dữ liệu và giao thức đánh giá	35

4.1.3	Các mô hình baseline	35
4.1.4	Độ đo đánh giá	35
4.1.5	Cài đặt mô hình	36
4.2	Kết quả chính	37
4.3	Phân tích nghịch lý AUC/uAUC	37
4.4	Phân tích ablation	38
4.5	Phân tích bổ sung	39
4.5.1	Đo lường khoảng cách ngữ nghĩa	39
4.5.2	Phân tích theo nhóm người dùng	39
4.6	Thảo luận	40
4.6.1	Đối chiếu với ILM về giao thức đánh giá	40
4.6.2	Điểm mạnh và hạn chế của cầu nối Q-Former	40
4.7	Hạn chế	40
5	Kết luận và Hướng phát triển	41
5.1	Tóm tắt đóng góp	41
5.2	Kết quả đạt được	42
5.3	Hạn chế	42
5.4	Hướng phát triển	43
	Tài liệu tham khảo	45

Chương 1

Giới thiệu

1.1 Bối cảnh và động lực nghiên cứu

Trong thập kỷ vừa qua, hệ thống tư vấn (recommender system) đã trở thành một thành phần cốt lõi trong các nền tảng thương mại điện tử, phát trực tuyến và mạng xã hội. Nhiệm vụ cốt lõi của hệ thống tư vấn là dự đoán mức độ phù hợp giữa người dùng và vật phẩm dựa trên dữ liệu lịch sử tương tác, từ đó đưa ra các gợi ý cá nhân hóa có giá trị thực tiễn cao [1].

Phương pháp lọc cộng tác (collaborative filtering – CF) là nền tảng của phần lớn các hệ thống tư vấn hiện đại. Trong đó, phân rã ma trận (matrix factorization – MF) [2] học ánh xạ người dùng và vật phẩm thành các véc-tơ nhúng ẩn trong không gian đặc trưng thấp chiều, sao cho tích vô hướng giữa hai véc-tơ phản ánh mức độ tương thích. Phân rã ma trận cùng các biến thể như LightGCN [3] – khai thác cấu trúc đồ thị tương tác – đã đạt được hiệu quả đáng kể trên nhiều bộ dữ liệu chuẩn. Tuy vậy, nhóm phương pháp này tồn tại ba hạn chế cố hữu: (i) *ma trận thưa thớt* (data sparsity) – hầu hết các cặp người dùng–vật phẩm chưa có tương tác, khiến không gian huấn luyện cực kỳ thưa; (ii) *vấn đề khởi động nguội* (cold-start) – người dùng mới hoặc vật phẩm mới không có lịch sử tương tác, nên hệ thống không thể tạo biểu diễn nhúng có chất lượng; (iii) *thiếu hiểu biết ngữ nghĩa* – các biểu diễn CF được học hoàn toàn từ tín hiệu

tương tác nhị phân, không nắm được nội dung văn bản mô tả thuộc tính vật phẩm hay sở thích người dùng.

Sự bùng nổ của các mô hình ngôn ngữ lớn (large language model – LLM) trong những năm gần đây đã mở ra một hướng tiếp cận mới để khắc phục những hạn chế trên. LLM được huấn luyện trước trên khối lượng văn bản khổng lồ, tích lũy hiểu biết ngữ nghĩa phong phú về thế giới và khả năng suy luận linh hoạt. Kết hợp LLM với hệ thống tư vấn đã trở thành một hướng nghiên cứu sôi nổi, với hai luồng chính: (1) *LLM-enhanced*: dùng LLM như bộ mã hóa để làm giàu biểu diễn đặc trưng người dùng và vật phẩm; (2) *LLMs as Recommender Systems (LLMs-as-RS)*: đặt bài toán gợi ý trực tiếp như một tác vụ sinh ngôn ngữ, trong đó LLM vừa đóng vai trò hiểu ngữ cảnh vừa đưa ra gợi ý [4]. Hướng tiếp cận LLMs-as-RS đặc biệt hấp dẫn vì khả năng giải quyết cold-start nhờ hiểu biết ngữ nghĩa sẵn có của LLM, và khả năng tận dụng tri thức thế giới để lý giải các gợi ý theo ngôn ngữ tự nhiên.

Luận văn này theo đuổi hướng tiếp cận LLMs-as-RS.

1.2 Vấn đề đặt ra: khoảng cách ngữ nghĩa giữa tín hiệu cộng tác và LLM

Khi đặt bài toán gợi ý như một tác vụ sinh ngôn ngữ, một câu hỏi then chốt xuất hiện: làm thế nào để đưa tín hiệu hành vi lịch sử của người dùng vào LLM một cách hiệu quả? Cách tiếp cận trực tiếp nhất là mã hóa lịch sử tương tác thành văn bản – ví dụ, liệt kê danh sách các phim người dùng đã xem – rồi nối vào chỉ dẫn (prompt) đầu vào của LLM. Tuy nhiên, cách này gặp phải một giới hạn cơ bản: với người dùng có lịch sử phong phú, danh sách vật phẩm nhanh chóng vượt quá độ dài ngữ cảnh (context length) cho phép, làm mất thông tin hoặc tăng chi phí tính toán đáng kể. Đây là trở ngại thực tiễn đã được ghi nhận trong nhiều công trình LLMs-as-RS [5].

Giải pháp tự nhiên là biểu diễn thông tin hành vi dưới dạng *véc-tơ đặc trưng compact*: thay vì liệt kê từng vật phẩm, ta dùng nhúng CF – tổng hợp từ toàn bộ lịch sử tương tác – để nén tín hiệu cộng tác thành một véc-tơ dày đặc. Véc-tơ này sau đó được đưa vào LLM như một *soft token*, bổ sung tín hiệu hành vi mà không làm dài ngữ cảnh. Cách tiếp cận này được gọi là *tích hợp CF vào LLM qua không gian véc-tơ*.

CoLLM [5] là công trình tiên phong theo hướng này: sử dụng một lớp chiếu tuyến tính (MLP một lớp) để ánh xạ véc-tơ CF từ không gian MF vào không gian nhúng của LLM, tạo thành các soft token được chèn vào chỉ dẫn. Mặc dù đơn giản và hiệu quả như một baseline, lớp chiếu tuyến tính có hạn chế cố hữu: nó không nắm được các quan hệ phi tuyến phức tạp giữa không gian CF và không gian ngữ nghĩa của LLM, và không có cơ chế *trích chọn có kiểm soát* – toàn bộ véc-tơ CF được chiếu một lần qua một phép biến đổi duy nhất mà không phân biệt các thành phần nào thực sự quan trọng với ngữ cảnh hiện tại.

Khoảng cách ngữ nghĩa giữa không gian biểu diễn CF (học từ tín hiệu tương tác nhị phân) và không gian ngữ nghĩa của LLM (học từ ngôn ngữ tự nhiên) là một thách thức căn bản. Hai không gian này có nguồn gốc huấn luyện hoàn toàn khác nhau, nên một phép chiếu đơn giản khó có thể thực hiện việc *căn chỉnh* (alignment) hiệu quả. Điều này đặt ra câu hỏi: liệu có cơ chế nối cầu nào mạnh hơn lớp chiếu tuyến tính, có khả năng căn chỉnh tín hiệu CF vào không gian ngữ nghĩa LLM một cách có kiểm soát và linh hoạt hơn?

1.3 Khoảng trống nghiên cứu

Kiến trúc Q-Former, được giới thiệu trong BLIP-2 [6] và phát triển thêm trong InstructBLIP [7], là một cầu nối đa phương thức được thiết kế cho bài toán căn chỉnh giữa thông tin hình ảnh và không gian ngôn ngữ. Q-Former sử dụng một tập nhỏ các véc-tơ truy vấn *học được* (learned query tokens) cùng cơ chế cross-attention để trích xuất có chọn lọc các đặc

trung từ tín hiệu đầu vào, thay vì chiếu toàn bộ tín hiệu qua một phép biến đổi đơn giản. Cơ chế này về nguyên tắc thích hợp hơn cho bài toán căn chỉnh không gian CF vào không gian ngữ nghĩa LLM, vì nó có khả năng học cách tổng hợp và chọn lọc thông tin từ tín hiệu cộng tác tùy thuộc vào ngữ cảnh tác vụ.

Công trình ILM [8] đã thử nghiệm ý tưởng dùng Q-Former như cầu nối tích hợp thông tin CF vào LLM cho bài toán gợi ý. Tuy nhiên, hướng nghiên cứu này còn tồn tại hai khoảng trống quan trọng chưa được giải quyết:

Thứ nhất, ILM chưa đánh giá dưới giao thức dự đoán tỉ lệ nhấp (click-through rate – CTR) với các độ đo AUC và uAUC như CoLLM và các công trình cùng dòng, nên không thể so sánh trực tiếp hiệu quả của cầu nối Q-Former với lớp chiếu tuyến tính trên cùng điều kiện thực nghiệm.

Thứ hai, cầu nối Q-Former trong ILM chưa được tăng cường bằng các kỹ thuật hiện đại như: (i) conditioning theo chỉ dẫn (InstructBLIP [7]) để truy vấn phụ thuộc tác vụ; (ii) biểu diễn đa token cho tín hiệu CF; (iii) các lựa chọn thiết kế như tách lớp chiếu người dùng và vật phẩm.

Luận văn này lấp hai khoảng trống nêu trên:

Mặc dù Q-Former đã được dùng để nối thông tin cộng tác với LLM (ILM), hướng này vẫn chưa được đánh giá dưới giao thức CTR với AUC và uAUC như dòng CoLLM, và chưa được khảo sát khi tăng cường bằng các kỹ thuật hiện đại như InstructBLIP, biểu diễn đa token. Luận văn này lấp khoảng trống đó: xây dựng và tăng cường một cầu nối Q-Former để tích hợp thông tin cộng tác vào LLM, đánh giá có hệ thống dưới giao thức AUC/uAUC và đối chiếu trực tiếp với baseline CoLLM.

1.4 Mục tiêu và đóng góp

Luận văn hướng đến hai mục tiêu chính:

Mục tiêu 1: Thiết kế và hiện thực một mô hình tích hợp tín hiệu CF vào LLM thông qua cầu nối Q-Former, thay thế lớp chiếu tuyến tính của CoLLM. Cụ thể, luận văn xây dựng kiến trúc SigLLM gồm ba khối nối tiếp – phân rã ma trận đông cứng, cầu nối Q-Former, và LLM đông cứng với LoRA – trong đó cầu nối Q-Former đóng vai trò căn chỉnh tín hiệu CF vào không gian ngữ nghĩa của LLM. Song song, luận văn khảo sát các lựa chọn thiết kế bổ sung (biểu diễn đa token, backbone LLM đã instructed, tách lớp chiếu người dùng và vật phẩm) và InstructBLIP như hướng tăng cường chính.

Mục tiêu 2: Đánh giá có hệ thống cầu nối Q-Former dưới giao thức CTR với hai độ đo AUC và uAUC trên tập dữ liệu MovieLens-1M – điều mà ILM chưa thực hiện – đối chiếu trực tiếp với baseline CoLLM và các phương pháp liên quan.

Từ hai mục tiêu trên, luận văn đóng góp:

1. **Cầu nối Q-Former được thích nghi và tăng cường cho bài toán gợi ý:** Luận văn thích nghi kiến trúc Q-Former từ domain ảnh-ngôn ngữ sang domain gợi ý, trong đó tín hiệu CF thay thế đặc trưng ảnh như đầu vào của cross-attention. Bên cạnh kiến trúc cơ sở, luận văn tăng cường cầu nối bằng các lựa chọn thiết kế đã được kiểm chứng (biểu diễn đa token, backbone đã instructed, tách projector người dùng và vật phẩm) và khảo sát InstructBLIP như hướng tăng cường chính, với kết quả thực nghiệm được trình bày ở Chương 4.
2. **Đánh giá có hệ thống dưới giao thức AUC/uAUC:** Luận văn đánh giá cầu nối Q-Former dưới giao thức CTR với AUC và uAUC – cùng giao thức với CoLLM, cho phép so sánh trực tiếp – trên tập dữ liệu MovieLens-1M. Đây là đánh giá mà các công trình Q-Former trước (ILM) chưa thực hiện, đồng thời cung cấp phân tích ablation về đóng góp của từng thành phần trong pipeline SigLLM.

Lưu ý về tư thế viết: Luận văn áp dụng tư thế thực nghiệm trung thực (posture A): báo cáo số liệu thực tế, phân tích nguyên nhân khi kết quả

không như kỳ vọng, và không phóng đại claim vượt quá bằng chứng. Các kết quả chính được trình bày với đầy đủ caveat về giới hạn thực nghiệm (một tập dữ liệu, một seed).

1.5 Bố cục luận văn

Phần còn lại của luận văn được tổ chức như sau.

Chương 2 — Các công trình liên quan phân tích theo bốn nhánh: lọc cộng tác truyền thống và hạn chế của nó; LLM trong hệ thống tư vấn và thách thức về độ dài ngữ cảnh; các phương pháp tích hợp CF vào LLM qua không gian véc-tơ (MLP, tương phản, tiềm trọng số, Q-Former); và nền tảng kiến trúc Q-Former từ BLIP-2 và InstructBLIP. Chương này kết luận rằng cầu nối Q-Former đáng được nghiên cứu và tăng cường sâu hơn.

Chương 3 — Phương pháp đề xuất trình bày kiến trúc SigLLM với ba khối nối tiếp và lý do chọn Q-Former thay lớp chiếu tuyến tính của CoLLM. Chương này mô tả cơ chế Q-Former được thích nghi, các lựa chọn thiết kế, InstructBLIP như hướng tăng cường chính, và quy trình huấn luyện ba giai đoạn.

Chương 4 — Thực nghiệm và Kết quả trình bày thiết lập thực nghiệm trên tập dữ liệu MovieLens-1M, kết quả so sánh với CoLLM và các baseline liên quan, phân tích ablation, và thảo luận về các hạn chế.

Chương 5 — Kết luận và Hướng phát triển tóm tắt đóng góp, chỉ ra các hạn chế còn tồn tại và đề xuất hướng nghiên cứu tiếp theo.

Chương 2

Các công trình liên quan

Chương này xây dựng nền tảng lý thuyết cho luận văn qua bốn nhánh phân tích nối tiếp nhau. *Nhánh đầu tiên* (Mục 2.1) trình bày lọc cộng tác truyền thống và các hạn chế cố hữu của nó, dẫn đến nhu cầu kết hợp LLM. *Nhánh thứ hai* (Mục 2.2) phân tích hai hướng khai thác LLM cho hệ thống tư vấn và chỉ ra rào cản về độ dài ngữ cảnh – yếu tố buộc tín hiệu CF phải được biểu diễn dưới dạng véc-tơ compact thay vì văn bản. *Nhánh thứ ba* (Mục 2.3) phân tích năm cách tích hợp CF vào LLM qua không gian véc-tơ, làm nổi bật điểm mạnh và hạn chế của từng hướng. *Nhánh thứ tư* (Mục 2.4) trình bày nền tảng kiến trúc Q-Former từ BLIP-2 và InstructBLIP – cơ sở lý thuyết cho phương pháp đề xuất ở Chương 3.

2.1 Lọc cộng tác truyền thống

Lọc cộng tác (collaborative filtering – CF) khai thác hành vi tập thể của người dùng: những người dùng có hành vi tương tự trong quá khứ có xu hướng thích những vật phẩm giống nhau trong tương lai. Phương pháp này không cần thông tin nội dung vật phẩm, chỉ dựa trên ma trận tương tác người dùng–vật phẩm [1].

2.1.1 Phân rã ma trận

Phân rã ma trận (matrix factorization – MF) [2] là phương pháp CF nền tảng, đạt được thành công lớn trong cuộc thi Netflix Prize. MF học ánh xạ mỗi người dùng u và vật phẩm i thành các véc-tơ nhúng ẩn $e_u, e_i \in \mathbb{R}^d$ sao cho tích vô hướng $e_u^\top e_i$ xấp xỉ mức độ tương thích. Hàm mục tiêu phổ biến là hồi quy bình phương tối thiểu (RMSE) trên các đánh giá quan sát được, hoặc học xếp hạng cặp theo mục tiêu BPR [9].

Điểm mạnh của MF là tính đơn giản, khả năng mở rộng và hiệu quả thực nghiệm đã được kiểm chứng. Tuy nhiên, MF học biểu diễn tuyến tính qua tích vô hướng, hạn chế khả năng mô hình hóa các quan hệ phi tuyến phức tạp. Lọc cộng tác thần kinh (neural collaborative filtering – NCF) [10] mở rộng MF bằng cách thay tích vô hướng bởi mạng nơ-ron nhiều lớp, cho phép học các tương tác người dùng–vật phẩm phi tuyến.

2.1.2 Lọc cộng tác dựa trên đồ thị

Tương tác người dùng–vật phẩm có thể được biểu diễn tự nhiên như một đồ thị hai phía (bipartite graph). LightGCN [3] khai thác cấu trúc đồ thị này bằng mạng tích chập đồ thị (graph convolutional network – GCN): nhúng của mỗi nút được cập nhật bằng cách tổng hợp tuyến tính nhúng của các nút láng giềng, qua nhiều bước lan truyền. LightGCN đạt hiệu quả cao hơn NCF trên nhiều bộ dữ liệu chuẩn nhờ khai thác được thông tin cấu trúc bậc cao của đồ thị tương tác.

2.1.3 Hạn chế của lọc cộng tác thuần túy

Mặc dù đạt hiệu quả tốt, các phương pháp CF truyền thống tồn tại ba hạn chế cơ bản:

Vấn đề thừa thớt dữ liệu. Ma trận tương tác người dùng–vật phẩm trong thực tế cực kỳ thưa: tỉ lệ quan sát trên tổng số cặp thường dưới 1%. Dữ liệu thừa dẫn đến ước lượng nhúng kém chất lượng cho người dùng và

vật phẩm ít tương tác.

Vấn đề khởi động nguội. Người dùng mới và vật phẩm mới không có lịch sử tương tác, nên các phương pháp CF không thể xây dựng biểu diễn nhúng cho họ. Đây là hạn chế nghiêm trọng trong hệ thống thực tế, nơi người dùng mới và vật phẩm mới liên tục xuất hiện.

Thiếu hiểu biết ngữ nghĩa. Biểu diễn CF học thuần từ tín hiệu tương tác nhị phân, không nắm được nội dung văn bản mô tả vật phẩm hay sở thích người dùng. Điều này hạn chế khả năng gợi ý cho vật phẩm mới (zero interaction) và khả năng giải thích gợi ý bằng ngôn ngữ tự nhiên.

Những hạn chế này thúc đẩy hướng kết hợp LLM – có khả năng hiểu ngữ nghĩa văn bản phong phú – vào hệ thống tư vấn.

2.2 Mô hình ngôn ngữ lớn cho hệ thống tư vấn

LLM được huấn luyện trước trên khối lượng văn bản khổng lồ, thu được khả năng hiểu ngữ nghĩa sâu sắc và suy luận linh hoạt. Khai thác LLM cho hệ thống tư vấn đã trở thành một trong những hướng nghiên cứu tích cực nhất trong những năm gần đây [4].

2.2.1 Hai hướng khai thác LLM

Có thể phân loại các phương pháp kết hợp LLM và hệ thống tư vấn thành hai hướng chính:

LLM-enhanced: dùng LLM như bộ mã hóa để tạo biểu diễn ngữ nghĩa cho người dùng và vật phẩm, sau đó tích hợp vào pipeline gợi ý truyền thống. Trong hướng này, LLM chủ yếu đóng vai trò trích xuất đặc trưng ngôn ngữ; quyết định gợi ý vẫn do các mô hình CF hoặc xếp hạng đảm nhận.

LLMs-as-RS: đặt bài toán gợi ý trực tiếp như một tác vụ sinh ngôn ngữ, trong đó LLM vừa hiểu ngữ cảnh vừa đưa ra gợi ý. P5 [11] là một

trong những công trình đầu tiên theo hướng này, đặt nhiều bài toán gợi ý (xếp hạng, dự đoán đánh giá, giải thích) thành các cặp câu hỏi–trả lời và huấn luyện một mô hình T5 thống nhất. BIGRec [12] tinh chỉnh LLM để gợi ý bằng cách ánh xạ đầu ra ngôn ngữ về không gian vật phẩm qua cơ chế căn chỉnh.

Hướng LLMs-as-RS đặc biệt hấp dẫn vì khả năng tận dụng tri thức thế giới sẵn có trong LLM để giải quyết cold-start – người dùng và vật phẩm mới có thể được mô tả bằng văn bản, và LLM có thể suy luận về sở thích ngay cả khi chưa có lịch sử tương tác. Luận văn này theo đuổi hướng LLMs-as-RS.

2.2.2 Rào cản về độ dài ngữ cảnh

Khi đặt bài toán gợi ý như tác vụ ngôn ngữ, cách tự nhiên nhất để cung cấp thông tin hành vi là mã hóa lịch sử tương tác thành văn bản – chẳng hạn, liệt kê tên các phim người dùng đã xem. Tuy nhiên, người dùng trong thực tế có thể có hàng trăm đến hàng nghìn tương tác. Với mỗi tên phim chiếm vài token, lịch sử đầy đủ nhanh chóng vượt quá giới hạn ngữ cảnh của LLM (thường 2K–8K token với các mô hình phổ biến), hoặc tiêu tốn lượng tính toán rất lớn nếu dùng mô hình context dài.

Đây là rào cản cơ bản đã được nhận diện trong CoLLM [5]: dù LLM có khả năng hiểu ngữ nghĩa, ta không thể đơn giản đưa toàn bộ lịch sử tương tác vào chỉ dẫn dưới dạng văn bản. Giải pháp là biểu diễn tín hiệu hành vi dưới dạng *véc-tơ CF compact* – tổng hợp từ toàn bộ lịch sử – và đưa véc-tơ này vào LLM như soft token. Rào cản này đặt ra vấn đề trung tâm: làm thế nào để *căn chỉnh* véc-tơ CF vào không gian ngữ nghĩa LLM một cách hiệu quả?

2.3 Các phương pháp tích hợp CF vào LLM qua không gian véc-tơ

Nhiều công trình đã đề xuất các cơ chế khác nhau để đưa véc-tơ CF vào LLM. Mục này phân tích năm hướng chính và điểm phản biện của từng hướng.

2.3.1 Chiều tuyến tính: CoLLM

CoLLM [5] là baseline nền tảng của luận văn này. CoLLM dùng một lớp chiều tuyến tính (lớp MLP một lớp) để ánh xạ véc-tơ CF từ không gian MF sang không gian nhúng của LLM, tạo thành soft token được chèn vào chỉ dẫn. LLM (Llama-2 [13]) sau đó thực hiện dự đoán CTR dưới dạng trả lời “Yes” hoặc “No”. Quy trình huấn luyện của CoLLM gồm hai bước: bước đầu tiên huấn luyện LoRA cơ sở chỉ với văn bản (không CF), bước thứ hai huấn luyện mô hình đầy đủ với soft token CF được bơm vào.

Điểm mạnh của CoLLM là sự đơn giản và hiệu quả như một baseline mạnh. Tuy nhiên, lớp chiều tuyến tính có hai hạn chế cơ bản: (i) phép biến đổi tuyến tính không thể nắm được các quan hệ phi tuyến phức tạp giữa không gian CF và không gian ngữ nghĩa LLM; và (ii) không có cơ chế trích chọn có kiểm soát – toàn bộ véc-tơ CF được ánh xạ qua một phép biến đổi duy nhất, không phân biệt thành phần nào quan trọng với ngữ cảnh hiện tại.

2.3.2 Học tương phản: SellaRec

SellaRec [14] căn chỉnh biểu diễn CF và biểu diễn ngôn ngữ thông qua học tương phản (contrastive learning) với mục tiêu InfoNCE: kéo gần biểu diễn của cùng vật phẩm trong không gian CF và không gian ngôn ngữ, đồng thời đẩy xa các vật phẩm khác nhau. Cách tiếp cận này cung cấp một tín hiệu huấn luyện toàn cục mạnh hơn so với chiếu trực tiếp.

Đáng chú ý, SellaRec đã được đánh giá dưới giao thức CTR với AUC và uAUC trên MovieLens-1M – cùng độ đo và tập dữ liệu với luận văn này. Điều này cho thấy khoảng trống đánh giá mà luận văn nhắm đến không phải là khoảng trống của *toàn bộ* dòng CF-LLM, mà đặc thù cho *cầu nối Q-Former*: SellaRec lấp khoảng trống bằng cơ chế học tương phản, trong khi hướng Q-Former (ILM) vẫn chưa được kiểm chứng dưới giao thức này. Hai cơ chế khác nhau về bản chất – học tương phản căn chỉnh hai không gian qua hàm mất mát toàn cục, còn Q-Former trích chọn và tổng hợp tín hiệu CF qua tập truy vấn học được – nên SigLLM và SellaRec bổ sung cho nhau hơn là trùng lặp.

Tuy nhiên, SellaRec dùng Qwen2-7B-Base [15] làm backbone LLM. Trong khi CoLLM dùng Llama-2, luận văn này dùng Qwen2-7B-Instruct – cùng họ mô hình với SellaRec nhưng khác variant (Base so với Instruct). So sánh số liệu giữa SellaRec và SigLLM có thể thực hiện được nhưng cần caveat: sự khác biệt Base/Instruct và giao thức phân chia dữ liệu có thể ảnh hưởng đến kết quả quan sát được.

2.3.3 Mã hóa dạng văn bản: BinLLM

BinLLM [16] đề xuất mã hóa véc-tơ CF thành chuỗi ký tự nhị phân, cho phép đưa tín hiệu CF vào LLM dưới dạng văn bản thông thường mà không cần soft token. Cách tiếp cận này có ưu điểm về tính đơn giản trong triển khai và không yêu cầu thay đổi kiến trúc LLM.

Hạn chế của BinLLM nằm ở bước rời rạc hóa: mã hóa nhị phân không thể lưu giữ đầy đủ thông tin từ véc-tơ CF liên tục, dẫn đến mất mát thông tin không thể khôi phục. Ngoài ra, chuỗi nhị phân không mang ý nghĩa ngữ nghĩa trong từ vựng LLM, nên LLM phải học cách diễn giải cú pháp nhị phân – một bài toán học bổ sung không tầm thường.

2.3.4 Tiêm vào trọng số: CoRA

CoRA [17] đề xuất một cơ chế khác biệt: thay vì đưa CF vào không gian đầu vào của LLM như soft token, CoRA biến đổi véc-tơ CF thành một lượng thay đổi trọng số hạng thấp, phụ thuộc vào mẫu (sample-specific), cộng trực tiếp vào các lớp attention của LLM. Theo đó, mỗi mẫu (cặp người dùng–vật phẩm) có một tập trọng số điều chỉnh riêng, cho phép LLM cá nhân hóa tính toán ở mức độ sâu hơn.

Tuy nhiên, CoRA bỏ hoàn toàn cơ chế soft token – CF chỉ được đưa vào qua đường trọng số. Điều này có nghĩa là CoRA không tận dụng được khả năng căn chỉnh ngữ nghĩa mà soft token trong không gian đầu vào cung cấp. Như sẽ trình bày ở Chương 3, kiến trúc SigLLM kết hợp cả hai đường truyền – soft token và tiêm trọng số – thay vì chọn một trong hai như CoRA.

Cần phân biệt rõ hai vai trò của CoRA trong luận văn. Thứ nhất, *cơ chế* tiêm trọng số hạng thấp phụ thuộc mẫu của CoRA được SigLLM tiếp nhận và hiện thực như một trong hai đường đưa tín hiệu CF vào LLM (chi tiết tại Mục 3.3.3), bên cạnh đường soft token. Thứ hai, *mô hình* CoRA nguyên bản – chỉ dùng đường tiêm trọng số – được dùng như một baseline so sánh trong thực nghiệm (Chương 4). Bản thân kiến trúc CoRA không phải đóng góp kỹ thuật của luận văn; đóng góp nằm ở việc kết hợp cơ chế này với cầu nối Q-Former và đường soft token trong một pipeline thống nhất.

2.3.5 Cầu nối Q-Former: ILM

ILM [8] là công trình đầu tiên áp dụng Q-Former như cầu nối tích hợp tín hiệu CF vào LLM cho bài toán gợi ý. Q-Former sử dụng một tập véc-tơ truy vấn học được cùng cơ chế cross-attention để trích xuất thông tin từ véc-tơ CF, thay vì chiếu trực tiếp. Cơ chế này có khả năng học cách lọc và tổng hợp tín hiệu CF theo cách phù hợp với không gian ngữ nghĩa LLM.

Tuy nhiên, ILM chưa đánh giá dưới giao thức CTR với AUC và uAUC

như CoLLM và các công trình cùng dòng, nên không thể so sánh trực tiếp hiệu quả của cầu nối Q-Former với lớp chiếu tuyến tính. Ngoài ra, cầu nối Q-Former trong ILM chưa được tăng cường bằng các kỹ thuật conditioning theo chỉ dẫn như InstructBLIP.

2.3.6 Tổng hợp so sánh

Bảng 2.1 tổng hợp so sánh các phương pháp tích hợp CF vào LLM được phân tích ở trên.

Bảng 2.1: So sánh các phương pháp tích hợp CF vào LLM qua không gian véc-tơ

Phương pháp	Cơ chế tích hợp	Điểm mạnh	Hạn chế
CoLLM [5]	MLP tuyến tính một lớp	Đơn giản; baseline mạnh	Tuyến tính; không có trích chọn có kiểm soát
SellaRec [14]	Học tương phản	Tín hiệu huấn luyện toàn cục	Backbone khác (Qwen); so sánh hạn chế
BinLLM [16]	Mã hóa nhị phân	Đơn giản; không cần soft token	Mất mát thông tin khi rời rạc hóa
CoRA [17]	Tiêm vào trọng số	Cá nhân hóa sâu trong LLM	Bỏ soft token; không tận dụng căn chỉnh đầu vào
ILM [8]	Q-Former (cross-attention)	Trích chọn có kiểm soát	Chưa báo AUC/uAUC; chưa tăng cường InstructBLIP

Phân tích trên dẫn đến kết luận: cầu nối Q-Former hứa hẹn nhất về

cơ chế căn chỉnh – trích chọn có kiểm soát qua cross-attention, không phụ thuộc vào giả thiết tuyến tính – nhưng còn thiếu kiểm chứng dưới giao thức AUC/uAUC và chưa được tăng cường bằng các kỹ thuật hiện đại. Đây là khoảng trống mà luận văn này nhắm đến.

2.4 Nền tảng kiến trúc Q-Former

2.4.1 BLIP-2: Q-Former cho căn chỉnh ảnh–ngôn ngữ

BLIP-2 [6] giới thiệu Q-Former (Querying Transformer) như một cầu nối nhẹ (lightweight bridge) giữa bộ mã hóa ảnh đông cứng và LLM đông cứng. Q-Former giải quyết bài toán: làm thế nào để trích xuất thông tin từ đặc trưng ảnh (không gian liên tục, chiều cao) và chuyển thành biểu diễn mà LLM có thể xử lý, mà không cần huấn luyện lại hai khối lớn.

Kiến trúc Q-Former gồm một tập nhỏ véc-tơ truy vấn học được $\mathbf{Q} \in \mathbb{R}^{N_q \times d}$ (thường $N_q = 32$) và một bộ transformer. Trong mỗi lớp của Q-Former, các truy vấn đi qua hai loại attention:

1. *Self-attention* giữa các truy vấn với nhau (và với token ngôn ngữ nếu có): cho phép các truy vấn trao đổi thông tin và điều phối lẫn nhau.
2. *Cross-attention* từ các truy vấn đến đặc trưng đầu vào (ảnh hoặc CF): cho phép mỗi truy vấn thu nhận thông tin từ nguồn đầu vào một cách có chọn lọc.

Đầu ra là một khối truy vấn $\mathbf{Z} \in \mathbb{R}^{N_q \times d}$ – một tập hợp compact các véc-tơ đã được “cắt giữ” thông tin từ đầu vào theo cách tối ưu cho ngữ cảnh hiện tại. $\mathbf{Z}$ sau đó được chiếu vào không gian nhúng của LLM và nối với prompt văn bản.

BLIP-2 huấn luyện Q-Former qua hai giai đoạn: (1) tiền huấn luyện biểu diễn với các mục tiêu tương phản ảnh–văn bản (ITC), so khớp ảnh–văn bản (ITM) và sinh văn bản có điều kiện (ITG); (2) tiền huấn luyện

sinh ngôn ngữ để Q-Former học cách tạo biểu diễn mà LLM có thể hiểu. Thiết kế này cho phép BLIP-2 đạt hiệu quả cao trên các tác vụ ảnh–ngôn ngữ mà chỉ cần huấn luyện Q-Former nhẹ, giữ nguyên bộ mã hóa ảnh và LLM.

Ý nghĩa cho bài toán gợi ý: Q-Former có thể được thích nghi để thay thế bộ mã hóa ảnh bằng bộ mã hóa CF (phân rã ma trận), và thực hiện căn chỉnh CF vào không gian LLM thông qua cơ chế cross-attention có kiểm soát.

2.4.2 InstructBLIP: Conditioning theo chỉ dẫn

InstructBLIP [7] mở rộng BLIP-2 bằng cách làm cho Q-Former phụ thuộc vào chỉ dẫn (instruction): thay vì dùng tập truy vấn cố định, các truy vấn của Q-Former tham gia vào self-attention cùng với token chỉ dẫn văn bản. Kết quả là đầu ra $\mathbf{Z}$ của Q-Former phụ thuộc vào nội dung chỉ dẫn – cùng một ảnh đầu vào nhưng với chỉ dẫn khác nhau, Q-Former trích xuất các đặc trưng ảnh khác nhau.

Cải tiến này cho phép InstructBLIP thực hiện hiệu quả trên nhiều tác vụ ảnh–ngôn ngữ đa dạng mà không cần tinh chỉnh riêng từng tác vụ. Kết quả là InstructBLIP vượt trội đáng kể so với BLIP-2 trên nhiều benchmark zero-shot.

Ý nghĩa cho bài toán gợi ý: Q-Former với conditioning chỉ dẫn cho phép truy vấn phụ thuộc tác vụ – ví dụ, cùng tín hiệu CF nhưng với chỉ dẫn khác nhau (“người dùng có thích phim hành động?” vs. “phim này có phù hợp với sở thích của người dùng không?”), Q-Former có thể trích xuất các khía cạnh khác nhau của tín hiệu CF. Đây là hướng tăng cường chính mà luận văn khảo sát và sẽ được trình bày chi tiết ở Mục 3.5.

2.4.3 Kỹ thuật ổn định từ Flamingo

Khi gắn một đường truyền mới lên một LLM đông cứng, việc kiểm soát ổn định là quan trọng. Flamingo [18] – một mô hình đa phương thức quy

mô lớn – đề xuất kỹ thuật cổng tanh khởi tạo không (zero-initialized tanh gate): mỗi đường truyền mới có một tham số cổng g khởi tạo bằng 0, sao cho ban đầu $\Delta = \tanh(0) \cdot (\dots) = 0$, tức LLM không bị ảnh hưởng bởi tín hiệu mới ngay từ đầu. Trong quá trình huấn luyện, cổng học dần để tiếp nhận tín hiệu mới, và hàm tanh giới hạn biên độ thay đổi trong khoảng $(-1, 1)$, ngăn mô hình phân kỳ. SigLLM áp dụng kỹ thuật này trong cả hai đường truyền từ Q-Former vào LLM (chi tiết tại Mục 3.3).

2.5 Tổng kết và định vị luận văn

Nhìn lại bốn nhánh phân tích, có thể rút ra câu kết luận sau:

Trong các phương pháp tích hợp tín hiệu CF vào LLM qua không gian véc-tơ, Q-Former nổi lên như cầu nối hứa hẹn nhất: cơ chế cross-attention với tập truy vấn học được cho phép trích chọn đặc trưng CF có kiểm soát, thay vì nén thô qua lớp chiếu tuyến tính của CoLLM. Tuy nhiên, hướng này chưa được kiểm chứng dưới giao thức AUC/uAUC của dòng CoLLM, và vẫn còn nhiều hướng tăng cường chưa được khai thác – đặc biệt là conditioning theo chỉ dẫn theo InstructBLIP – nên xứng đáng được nghiên cứu sâu hơn.

Chương tiếp theo trình bày kiến trúc SigLLM – hiện thực hóa và tăng cường cầu nối Q-Former cho bài toán gợi ý – cùng lý do thiết kế và quy trình huấn luyện.

Chương 3

Phương pháp đề xuất

Chương này trình bày kiến trúc SigLLM – mô hình được đề xuất trong luận văn – cùng lý do thiết kế và quy trình huấn luyện. Xuất phát từ hạn chế đã phân tích ở Chương 2, trục lập luận của chương là: lớp chiếu tuyến tính của CoLLM không đủ để căn chỉnh hiệu quả tín hiệu CF vào không gian ngữ nghĩa LLM, và cầu nối Q-Former với cross-attention có kiểm soát là lựa chọn thay thế tự nhiên hơn.

Mục 3.1 mô tả kiến trúc tổng thể ba khối. Mục 3.2 trình bày khối phân rã ma trận. Mục 3.3 là lõi kỹ thuật: cầu nối Q-Former và lý do chọn nó thay MLP. Mục 3.4 trình bày các lựa chọn thiết kế bổ sung. Mục 3.5 khảo sát InstructBLIP như hướng tăng cường chính. Mục 3.6 trình bày quy trình huấn luyện ba giai đoạn.

3.1 Tổng quan kiến trúc

Bài toán. Luận văn giải quyết bài toán dự đoán tỉ lệ nhấp (click-through rate – CTR). Cho người dùng u , lịch sử tương tác của người dùng, và một phim mục tiêu i , mô hình đưa ra dự đoán nhị phân về khả năng người dùng thích phim đó – biểu diễn dưới dạng câu trả lời “Yes” hoặc “No”. Đây là bài toán phân loại nhị phân, được đánh giá bằng AUC và uAUC (chi tiết tại Mục 4.1).

Kiến trúc tổng quát. SigLLM gồm ba khối nối tiếp, minh họa ở Hình 3.1:

1. **Khối Phân rã ma trận (MF)** – cung cấp tín hiệu lọc cộng tác dưới dạng véc-tơ nhúng cho người dùng và vật phẩm.
2. **Cầu nối Q-Former** – nén và căn chỉnh véc-tơ CF vào không gian ngữ nghĩa của LLM thông qua cross-attention với các véc-tơ truy vấn học được.
3. **Mô hình ngôn ngữ lớn (LLM)** – thực hiện suy luận và sinh câu trả lời “Yes/No”.


Đặc điểm thiết kế then chốt: Phần lớn tham số của SigLLM được giữ đông cứng (frozen) trong quá trình huấn luyện. Cụ thể, cả MF lẫn LLM đều không được cập nhật; chỉ Q-Former, các lớp chiếu, bộ chuyển thể LoRA [19] và bộ tiêm trọng số (tùy chọn) được huấn luyện. Thiết kế này bảo toàn tri thức ngôn ngữ sẵn có của LLM, giảm chi phí huấn luyện, và cho phép phân tích rõ ràng đóng góp của cầu nối căn chỉnh.

3.2 Khối Phân rã ma trận

Khối MF đóng vai trò nguồn tín hiệu lọc cộng tác. Từ ma trận tương tác người dùng–vật phẩm, MF học ánh xạ mỗi người dùng u và vật phẩm i thành các véc-tơ nhúng ẩn $e_u, e_i \in \mathbb{R}^d$ sao cho tích vô hướng $e_u^\top e_i$ phản ánh mức độ tương thích. MF được huấn luyện theo mục tiêu xếp hạng cặp BPR [9], sau đó được đông cứng.

Ba loại tín hiệu CF được trích xuất để đưa vào cầu nối: (i) nhúng người dùng e_u ; (ii) nhúng phim mục tiêu e_i ; (iii) nhúng các phim trong lịch sử tương tác của người dùng $\{e_{i'} : i' \in \mathcal{H}_u\}$.

Việc huấn luyện MF tách rời khỏi các khối còn lại là một lựa chọn thiết kế nhằm cô lập chất lượng tín hiệu CF khỏi quá trình tối ưu hóa LLM, tạo



Hình 3.1: Kiến trúc tổng quan của SigLLM. Khối MF đông cứng cung cấp tín hiệu lọc cộng tác; cầu nối Q-Former căn chỉnh tín hiệu này thành soft token; LLM đông cứng thực hiện suy luận. Chỉ Q-Former, lớp chiếu, LoRA và bộ tiêm trọng số được huấn luyện.

điều kiện phân tích rõ ràng nút thắt của hệ thống. Trong phạm vi luận văn, MF được huấn luyện trên phần tập huấn luyện của MovieLens-1M (chi tiết tại Mục 4.1).

3.3 Cầu nối Q-Former: lõi phương pháp

3.3.1 Lý do chọn Q-Former thay lớp chiếu tuyến tính

Lớp chiếu tuyến tính của CoLLM [5] thực hiện ánh xạ $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d_{\text{LLM}}}$ qua một ma trận trọng số duy nhất. Thiết kế này có hai hạn chế:

Hạn chế 1: Giả thiết tuyến tính. Phép chiếu tuyến tính giả định rằng không gian CF và không gian ngữ nghĩa LLM liên kết qua một ánh xạ affine. Tuy nhiên, hai không gian này có nguồn gốc huấn luyện hoàn toàn khác nhau – một từ tín hiệu tương tác nhị phân, một từ ngôn ngữ tự nhiên – và quan hệ giữa chúng nhiều khả năng phi tuyến và phức tạp.

Hạn chế 2: Không có trích chọn có kiểm soát. Lớp chiếu ánh xạ toàn bộ véc-tơ CF qua một phép biến đổi duy nhất, không phân biệt thành phần nào quan trọng với ngữ cảnh hiện tại. Trong khi đó, bài toán CTR đòi hỏi tích hợp thông tin từ nhiều nguồn (nhúng người dùng, nhúng phim mục tiêu, nhúng lịch sử) một cách linh hoạt theo từng mẫu.

Q-Former giải quyết cả hai hạn chế trên, nhưng nguồn gốc của lợi thế cần được xác định chính xác. Khác với lớp chiếu tuyến tính dùng chung một ma trận cho mọi mẫu, cross-attention trong Q-Former thực hiện tổng hợp *phụ thuộc đầu vào* (input-dependent): trọng số tổng hợp các véc-tơ CF thay đổi theo từng mẫu, vượt qua giả thiết ánh xạ affine cố định. Tuy nhiên, lợi thế chính *không* nằm ở khả năng nén của cross-attention – vì đầu vào CF chỉ gồm vài véc-tơ, cross-attention chủ yếu đóng vai trò tổng hợp có trọng số (chi tiết tại Mục 3.3.2) – mà nằm ở *tập véc-tơ truy vấn học được phối hợp qua self-attention*: mỗi truy vấn học cách trích xuất một khía cạnh khác nhau của tín hiệu CF và điều phối lẫn nhau để tổng hợp biểu diễn tối ưu cho tác vụ, điều mà một phép chiếu tuyến tính đơn lẻ

không làm được. Đây là luận điểm được nhất quán xuyên suốt chương và được kiểm chứng qua ablation ở Mục 4.4.

3.3.2 Kiến trúc Q-Former thích nghi cho gợi ý

Cầu nối được xây dựng dựa trên kiến trúc Q-Former theo Instruct-BLIP [7], kế thừa từ BLIP-2 [6]. SigLLM sử dụng $Q = 16$ véc-tơ truy vấn học được $\mathbf{Q} \in \mathbb{R}^{Q \times d_{\text{model}}}$, với $d_{\text{model}} = 768$.

Trong mỗi lớp Q-Former, các truy vấn đi qua hai loại attention:

1. *Self-attention* giữa các truy vấn với nhau (và với token chỉ dẫn, nếu dùng InstructBLIP): cho phép các truy vấn điều phối lẫn nhau và tích hợp thông tin ngữ cảnh tác vụ.
2. *Cross-attention* từ các truy vấn đến đặc trưng CF: mỗi truy vấn trọng số hóa và tổng hợp thông tin từ tập véc-tơ CF đầu vào $\{e_u, e_i, e_v\}$.

Đầu ra là khối truy vấn $\mathbf{Z} = \text{cf_q} \in \mathbb{R}^{B \times Q \times d_{\text{model}}}$, trong đó B là kích thước lô và $Q = 16$.

Quan sát quan trọng về vai trò thay đổi giữa hai domain. Trong InstructBLIP, đầu vào của cross-attention là một chuỗi dài các mảng ảnh (patch features), và cross-attention là cơ chế nén chính: nén hàng trăm patch thành $Q = 32$ truy vấn. Trong SigLLM, đầu vào của cross-attention chỉ là một vài véc-tơ CF (người dùng, vật phẩm mục tiêu, lịch sử), nên cross-attention chủ yếu thực hiện tổng hợp có trọng số. Cơ chế trích xuất đặc trưng phụ thuộc tác vụ chủ yếu đến từ self-attention giữa các truy vấn và token chỉ dẫn. Nhận định này giải thích quan sát thực nghiệm rằng việc tăng số lớp Q-Former không cải thiện đáng kể kết quả, trong khi đa dạng hóa chỉ dẫn lại có tác dụng.

3.3.3 Hai đường đưa tín hiệu CF vào LLM

Khối truy vấn $\mathbf{Z}$ được đưa vào LLM theo hai đường song song:

Đường soft token. $\mathbf{Z}$ được chiếu từ không gian Q-Former sang không gian nhúng của LLM qua lớp chiếu tuyến tính $W_{\text{proj}} \in \mathbb{R}^{d_{\text{model}} \times d_{\text{LLM}}}$, tạo thành Q soft token được chèn vào chỉ dẫn tại vị trí đánh dấu $\langle \text{CFTokens} \rangle$. Các soft token này tồn tại trong không gian đầu vào của LLM, cho phép LLM xử lý tín hiệu CF cùng với văn bản.

Đường tiêm trọng số. Theo hướng của CoRA [17], $\mathbf{Z}$ được biến thành lượng thay đổi trọng số hạng thấp, riêng cho từng mẫu, cộng trực tiếp vào các lớp chiếu q_{proj} và v_{proj} trong khối attention của LLM. Với đầu vào x của một lớp attention, lượng thay đổi Δ được tính theo Công thức 3.1:

$$\Delta = s \cdot g \cdot ((x A^\top) B), \quad s = \frac{\alpha}{Q}, \quad (3.1)$$

trong đó $A = P_{\text{down}}(\mathbf{Z})$ và $B = P_{\text{up}}(\mathbf{Z})$ là các phép chiếu hạng thấp sinh từ $\mathbf{Z}$, g là cổng vô hướng, α là siêu tham số tỉ lệ. Khác với LoRA – học lượng thay đổi cố định dùng chung cho mọi mẫu – bộ tiêm này sinh Δ từ $\mathbf{Z}$ của từng mẫu, tạo ra điều chỉnh cá nhân hóa theo từng cặp người dùng–vật phẩm.

Điểm khác biệt so với CoRA nguyên bản: CoRA [17] chỉ dùng đường tiêm trọng số, bỏ hoàn toàn soft token. SigLLM giữ cả hai đường song song, cho phép tín hiệu CF tác động vào LLM qua cả không gian đầu vào lẫn trọng số attention. Nghiên cứu ablation ở Mục 4.4 so sánh hiệu quả của ba chế độ: chỉ soft token, chỉ tiêm trọng số, và kết hợp cả hai.

3.3.4 Kỹ thuật đảm bảo ổn định

Việc gắn thêm một đường tiêm trọng số vào LLM đông cứng đòi hỏi kiểm soát ổn định cẩn thận. Bốn kỹ thuật sau được áp dụng, theo Flamingo [18]:

1. *Cổng tanh khởi tạo không.* Mỗi đường tiêm có cổng g khởi tạo bằng 0; do đó $\Delta = 0$ tại bước đầu, LLM giữ nguyên hành vi ban đầu và

điều chỉnh dần trong quá trình huấn luyện. Hàm tanh giới hạn biên độ Δ trong khoảng $(-1, 1)$. Thực nghiệm không có cổng này cho thấy mô hình phân kỳ và AUC suy về mức ngẫu nhiên 0,5.

2. *Không khởi tạo không cho P_{up} .* Nếu cả cổng lẫn P_{up} đều bằng 0 thì gradient của cả hai bằng 0, đường tiêm không thể khởi động. Chỉ cổng được khởi tạo bằng 0; P_{up} được khởi tạo với độ lệch chuẩn 0,02.
3. *Chuẩn hóa truy vấn về chuẩn L2 đơn vị* trước bộ chiếu hạng thấp, nhằm tách độ lớn của Δ khỏi chuẩn của $\mathbf{Z}$. Chuẩn của $\mathbf{Z}$ quan sát được ở mức trung bình khoảng 16, đủ lớn để gây bất ổn nếu không chuẩn hóa.
4. *Tính toán ở độ chính xác fp32* để tránh tràn số, và xử lý đặc biệt khi kích thước lô không khớp trong quá trình sinh tự hồi quy (autoregressive decoding).

3.4 Các lựa chọn thiết kế

Ngoài kiến trúc cầu nối Q-Former, SigLLM kết hợp một số lựa chọn thiết kế bổ sung. Các lựa chọn này được ghi nhận minh bạch nhưng không phải đóng góp chính của luận văn; vai trò của từng lựa chọn được đánh giá qua ablation ở Mục 4.4.

3.4.1 Biểu diễn đa token cho tín hiệu CF

Phiên bản cơ sở nén toàn bộ tín hiệu CF thành một soft token duy nhất trước khi chèn vào chỉ dẫn. Biểu diễn đa token (multi-token) giữ nguyên $Q = 16$ truy vấn đầu ra của Q-Former dưới dạng 16 soft token riêng biệt, cung cấp dải băng thông cao hơn để truyền thông tin CF vào LLM. Ảnh hưởng của lựa chọn này đối với AUC và uAUC được báo cáo ở Bảng 4.2.

3.4.2 Backbone LLM đã instructed và định dạng ChatML

Phiên bản cơ sở sử dụng Qwen2-7B-Base [15] – mô hình chưa được tinh chỉnh theo chỉ dẫn – với chỉ dẫn ở định dạng hoàn thành văn bản đơn giản. Lựa chọn thiết kế này thay bằng Qwen2-7B-Instruct [15] và định dạng ChatML tương ứng: một thông điệp hệ thống yêu cầu trả lời “Yes/No”, một lượt người dùng chứa chỉ dẫn và vị trí `<CFTokens>`, và một lượt trợ lý. Bộ tách token được điều chỉnh để soft token không trùng với các token điều khiển `<|im_start|>` và `<|im_end|>`.

Lý do: Thử nghiệm cho thấy tăng dung lượng LoRA trên backbone Base không cải thiện kết quả: tăng hạng LoRA lên $r = 16$ trên các lớp $[q, k, v, o]$ dẫn đến quá khớp (overfitting) – mất mát huấn luyện giảm nhanh nhưng uAUC trên tập kiểm định giảm. Kết quả này cho thấy dung lượng mô hình không phải nút thắt; nút thắt nằm ở chất lượng căn chỉnh của Q-Former. Backbone Instruct cung cấp tiên nghiệm tuân theo chỉ dẫn sẵn có, giải phóng dung lượng LoRA để tập trung vào việc sử dụng tín hiệu CF.

3.4.3 Tách lớp chiếu người dùng và vật phẩm

Trong kiến trúc cơ sở, một lớp chiếu chung ánh xạ cả nhúng người dùng lẫn nhúng vật phẩm từ không gian MF sang không gian Q-Former. Tuy nhiên, đặc trưng hình học của véc-tơ người dùng (user-factor) và véc-tơ vật phẩm (item-factor) trong không gian MF khác nhau: người dùng mã hóa sở thích tổng hợp, trong khi vật phẩm mã hóa thuộc tính nội dung. Dùng chung một phép chiếu cho cả hai loại có thể gây xung đột hình học.

Lựa chọn thiết kế này tách thành hai lớp chiếu riêng: một cho nhúng người dùng e_u và một cho các nhúng vật phẩm $\{e_i, e_{i'}\}$. Để duy trì khả năng nạp từ checkpoint cũ (chỉ có một lớp chiếu chung), trọng số của lớp chiếu chung được khởi tạo đồng thời cho cả hai lớp mới.

3.5 Tăng cường Q-Former theo InstructBLIP

3.5.1 Cơ chế conditioning theo chỉ dẫn

InstructBLIP [7] mở rộng Q-Former bằng cách đưa token chỉ dẫn văn bản tham gia vào self-attention cùng với các véc-tơ truy vấn. Kết quả là đầu ra $\mathbf{Z}$ của Q-Former phụ thuộc vào nội dung chỉ dẫn: cùng một đầu vào CF nhưng với chỉ dẫn khác nhau, Q-Former trích xuất các khía cạnh khác nhau. Thiết kế này cho phép một Q-Former duy nhất xử lý nhiều tác vụ khác nhau mà không cần tinh chỉnh riêng.

3.5.2 Thách thức cho bài toán gợi ý

Trong SigLLM, chỉ dẫn (instruction) được đưa vào self-attention của Q-Former dưới dạng tập token. Với bài toán CTR trên MovieLens-1M, chỉ dẫn mô tả tác vụ và ngữ cảnh người dùng–phim: ví dụ, “*Given the user’s watching history and preferences, predict whether the user will click on the target movie.*”

Cơ chế conditioning theo chỉ dẫn hứa hẹn cải thiện chất lượng trích xuất đặc trưng CF vì Q-Former có thể tập trung vào các khía cạnh của tín hiệu CF liên quan nhất đến tác vụ CTR cụ thể. Trong bài toán BLIP-2/InstructBLIP, conditioning theo chỉ dẫn mang lại cải thiện đáng kể trên các tác vụ zero-shot [7].

Lưu ý về phạm vi của conditioning. Trong InstructBLIP, sức mạnh của cơ chế đến từ việc chỉ dẫn *thay đổi* giữa nhiều tác vụ khác nhau, khiến cùng một đầu vào cho ra biểu diễn khác nhau tùy tác vụ. Trong phiên bản hiện tại của SigLLM, chỉ dẫn CTR được giữ *cố định* cho mọi mẫu; do đó cơ chế thực chất gần với Q-Former truy vấn cố định có bổ sung ngữ cảnh tác vụ ở tầng self-attention, hơn là conditioning phụ thuộc từng mẫu theo đúng nghĩa của InstructBLIP. Việc khảo sát nhiều mẫu chỉ dẫn khác nhau (ví dụ, chỉ dẫn phụ thuộc thể loại phim hay hồ sơ người dùng) để

khai thác đầy đủ conditioning phụ thuộc mẫu được đề ngỏ như một hướng thực nghiệm; luận văn không claim vượt quá những gì cấu hình chỉ dẫn cố định hỗ trợ.

3.5.3 Kết quả và vị trí trong luận văn

Thực nghiệm về hiệu quả của InstructBLIP trên bài toán gợi ý được trình bày ở Mục 4.2 và Mục 4.4 của Chương 4. Như đã lưu ý ở Mục 1.4, kết quả của hướng tăng cường này vẫn đang trong quá trình thực nghiệm; luận văn báo cáo những gì đã đo được mà không phóng đại claim vượt quá bằng chứng.

3.6 Quy trình huấn luyện ba giai đoạn

SigLLM được huấn luyện qua ba giai đoạn nối tiếp, theo giao thức của CoLLM [5] với điều chỉnh cho phù hợp với kiến trúc Q-Former.

3.6.1 Giai đoạn 1: Tiền huấn luyện biểu diễn

Q-Former được huấn luyện với bốn mục tiêu tương phản và căn chỉnh:

- *Căn chỉnh vật phẩm–văn bản (ITC)*: tối đa hóa độ tương đồng giữa biểu diễn Q-Former của một vật phẩm (từ nhúng MF) và biểu diễn văn bản của vật phẩm đó (tên phim, thể loại). Đây là mục tiêu căn chỉnh chính.
- *So khớp vật phẩm–văn bản (ITM)*: phân loại nhị phân cặp vật phẩm–văn bản có khớp hay không.
- *Sinh văn bản có điều kiện (ITG)*: sinh văn bản mô tả vật phẩm từ biểu diễn Q-Former.
- *Tương phản người dùng–vật phẩm*: kéo gần biểu diễn của các cặp tương tác dương và đẩy xa các cặp âm.

Vấn đề mất cân bằng dữ liệu và giải pháp. Trên MovieLens-1M, số cặp người dùng–vật phẩm dương khoảng 888 nghìn, trong khi số cặp vật phẩm–văn bản chỉ khoảng 3 nghìn – tỉ lệ khoảng 0,34%. Với lô kích thước 64, kỳ vọng số mẫu vật phẩm–văn bản mỗi lô chỉ khoảng 0,22, nên điều kiện “ít nhất hai mẫu cùng loại” để kích hoạt ITC/ITM/ITG hiếm khi được thỏa. Hệ quả là ba mục tiêu căn chỉnh chính gần như không được huấn luyện, dẫn đến Q-Former không học được căn chỉnh CF–văn bản.

Giải pháp gồm hai điều chỉnh được tổng hợp ở Bảng 3.1:

Bảng 3.1: Hai điều chỉnh cân bằng dữ liệu Giai đoạn 1

Điều chỉnh	Tầng	Tác động
Giới hạn số cặp người dùng–vật phẩm ở mức 20.000	Dữ liệu	Nâng tỉ lệ mẫu vật phẩm–văn bản lên $\approx 13\%$; kỳ vọng ≈ 8 mẫu/lô $\Rightarrow$ điều kiện “ít nhất 2 mẫu” gần như luôn thỏa
Giảm trọng số mất mát người dùng–vật phẩm từ 1,0 xuống 0,5	Mất mát	Điều hòa cường độ gradient giữa các mục tiêu

Điều chỉnh giới hạn số cặp yêu cầu dựng lại tệp dữ liệu (vì giới hạn được cố định khi dựng), trong khi trọng số mất mát được đọc lúc huấn luyện và có hiệu lực ngay. Do danh sách cặp người dùng–vật phẩm kế thừa thứ tự sắp theo thời gian của dữ liệu gốc, việc lấy phần đầu danh sách sẽ thiên lệch về các tương tác sớm (phim và người dùng thời kỳ đầu). Để loại bỏ thiên lệch này, danh sách được xáo trộn ngẫu nhiên với hạt giống cố định trước khi cắt, biến giới hạn 20.000 thành một mẫu ngẫu nhiên đồng nhất mà vẫn bảo đảm tính tái lập.

3.6.2 Giai đoạn 2: Tiền huấn luyện sinh

Q-Former và lớp chiếu được huấn luyện với mục tiêu sinh ngôn ngữ: từ biểu diễn Q-Former của tín hiệu CF, sinh văn bản mô tả vật phẩm. Giai đoạn này dạy đầu ra của cầu nối trở thành soft token mà LLM có thể diễn giải – tức căn chỉnh không gian Q-Former với không gian ngữ nghĩa của LLM đông cứng.

3.6.3 Giai đoạn 3: Tinh chỉnh CTR

Giai đoạn này theo giao thức hai bước của CoLLM [5]:

Bước 1: Huấn luyện LoRA cơ sở với chỉ dẫn chỉ gồm văn bản (tên phim, thể loại, lịch sử dưới dạng văn bản), không có tín hiệu CF. Bước này thiết lập đường cơ sở cho khả năng dự đoán chỉ từ văn bản và ổn định hóa LLM trước khi tiếp nhận soft token.

Bước 2: Huấn luyện mô hình đầy đủ với tín hiệu CF được bơm vào qua soft token, tiêu trọng số, hoặc cả hai. Mô hình được khởi tạo từ checkpoint của Bước 1. Nhãn giám sát là token “Yes” hoặc “No” tương ứng với nhãn CTR.

Chi phí tính toán. So với CoLLM, SigLLM có chi phí huấn luyện cao hơn do kiến trúc Q-Former phức tạp hơn lớp chiếu tuyến tính, và đường tiêu trọng số bổ sung hai phép nhân ma trận trên mỗi lớp attention. Chi phí cụ thể (số tham số huấn luyện được, thời gian huấn luyện mỗi giai đoạn) được báo cáo ở Mục 4.1. Luận văn không tuyên bố chi phí tăng thêm là “không đáng kể”; đây là đánh đổi có chủ đích cho chất lượng căn chỉnh tốt hơn.

3.7 Kết chương

Chương này đã trình bày kiến trúc ba khối của SigLLM và lý do chọn cầu nối Q-Former thay lớp chiếu tuyến tính của CoLLM. Luận điểm cốt lõi

là: cơ chế cross-attention với tập truy vấn học được cho phép căn chỉnh tín hiệu CF vào không gian ngữ nghĩa LLM có kiểm soát hơn, vượt qua giới hạn của giả thiết tuyến tính. Các lựa chọn thiết kế bổ sung (đa token, backbone Instruct, tách projector) và hướng tăng cường InstructBLIP được trình bày như các thành phần đã khảo sát, với kết quả thực nghiệm ở Chương 4.

Chương 4

Thực nghiệm và Kết quả

Chương này trình bày thiết lập thực nghiệm, kết quả đánh giá SigLLM so với các baseline, phân tích ablation và thảo luận. Tất cả số liệu trong chương được báo cáo trên một lần chạy duy nhất (một seed); khoảng tin cậy chưa được tính – đây là một hạn chế được thừa nhận (Mục 4.7).

4.1 Thiết lập thực nghiệm

4.1.1 Tập dữ liệu

Thực nghiệm được thực hiện trên tập dữ liệu **MovieLens-1M** [20], một bộ dữ liệu chuẩn rộng rãi trong nghiên cứu hệ thống tư vấn. Tập dữ liệu gồm khoảng 1 triệu đánh giá từ 6.040 người dùng cho 3.706 phim, với mỗi đánh giá là số sao từ 1 đến 5. Theo giao thức của CoLLM [5], đánh giá được nhị phân hóa thành nhãn CTR: đánh giá ≥ 4 sao được coi là nhấp (click), còn lại là không nhấp.

Luận văn giới hạn thực nghiệm trên MovieLens-1M; tập Amazon Books được đề xuất như hướng phát triển (Mục 5.4) nhằm kiểm chứng khả năng tổng quát của mô hình trên domain đa dạng hơn.

4.1.2 Phân chia dữ liệu và giao thức đánh giá

Theo giao thức của CoLLM [5], dữ liệu được sắp xếp theo thời gian và phân chia thành tập huấn luyện, kiểm định và kiểm tra theo tỉ lệ 8:1:1. Để đảm bảo so sánh công bằng, các siêu tham số được chọn dựa trên tập kiểm định và số liệu cuối cùng được báo cáo trên tập kiểm tra.

4.1.3 Các mô hình baseline

Baseline chính:

- **CoLLM** [5]: phương pháp tích hợp CF vào LLM qua MLP một lớp; cùng giao thức, cùng tập dữ liệu. Đây là baseline chính để đánh giá đóng góp của cầu nối Q-Former.

Baseline đối chiếu (số liệu từ bài báo gốc; không chạy lại):

- **CoRA** [17]: tiêm trọng số, không có soft token; backbone Llama-2 (cùng với CoLLM).
- **BinLLM** [16]: mã hóa nhị phân CF vào LLM.
- **SellaRec** [14]: học tương phản InfoNCE, backbone Qwen2-7B-Base; *lưu ý: SigLLM dùng Qwen2-7B-Instruct – cùng họ mô hình, khác variant Base/Instruct; so sánh số liệu có thể thực hiện nhưng cần caveat về sự khác biệt variant và giao thức phân chia dữ liệu.*
- **ILM** [8]: Q-Former cho gợi ý; *lưu ý: ILM không báo cáo AUC/uAUC theo giao thức CTR, nên không thể so sánh trực tiếp về số liệu; được đề cập trong phần thảo luận.*

4.1.4 Độ đo đánh giá

Luận văn dùng hai độ đo chính theo giao thức CoLLM:

- **AUC** (Area Under the ROC Curve): đánh giá khả năng phân biệt tổng thể trên toàn tập kiểm tra – xác suất để điểm dự đoán của mẫu dương cao hơn mẫu âm.
- **uAUC** (user-level AUC): AUC được tính riêng trong phạm vi từng người dùng rồi lấy trung bình. uAUC đánh giá chất lượng xếp hạng *nội-người-dùng* và bất biến với các phép biến đổi đơn điệu theo từng người dùng.

Bổ sung: Accuracy và F1 (độ đo phân loại nhị phân), Precision@K và NDCG@K (độ đo xếp hạng top-K), và cosine similarity trước/sau căn chỉnh (đo mức độ thu hẹp khoảng cách ngữ nghĩa CF–LLM).

4.1.5 Cài đặt mô hình

- **LLM backbone**: Qwen2-7B-Instruct [15], đông cứng hoàn toàn.
- **MF**: phân rã ma trận BPR [9], chiều ẩn $d = 64$, được huấn luyện và đông cứng trước khi tích hợp.
- **Q-Former**: $Q = 16$ truy vấn, $d_{\text{model}} = 768$, 2 lớp.
- **LoRA** [19]: hạng $r = 8$, áp dụng trên các lớp $[q, v]$ của LLM.
- **Batch size**: 64 (Giai đoạn 1), 16 (Giai đoạn 3).
- **Optimizer**: AdamW, learning rate 10^{-4} .
- **Phần cứng**: một GPU NVIDIA A100 80GB.
- **Tham số huấn luyện được**: tổng cộng khoảng 8,65 triệu tham số (8.650.754), gồm 2,52 triệu tham số LoRA (2.523.136; $r = 8$, $\alpha = 16$) và khoảng 6,13 triệu tham số của cầu nối Q-Former, các lớp chiếu và bộ tiêm trọng số. Con số này rất nhỏ so với 7 tỉ tham số đông cứng của LLM backbone, phản ánh thiết kế tinh chỉnh hiệu quả tham số.

- **Thời gian huấn luyện:** mỗi epoch mất khoảng 4–6 phút trên phần cứng nói trên (0,65–0,84 giây/iteration tùy giai đoạn).

4.2 Kết quả chính

Bảng 4.1 so sánh SigLLM với CoLLM và các baseline theo AUC và uAUC.

Bảng 4.1: Kết quả so sánh trên MovieLens-1M. Số liệu baseline từ bài báo gốc (ngoại trừ CoLLM được chạy lại theo giao thức giống hệt). Ký hiệu * đánh dấu backbone khác (Qwen).

Phương pháp	AUC	uAUC	Acc	F1
MF (chỉ CF)	[TBD]	[TBD]	–	–
CoLLM [5]	[TBD]	[TBD]	[TBD]	[TBD]
CoRA [17]	[TBD]	[TBD]	–	–
BinLLM [16]	[TBD]	[TBD]	–	–
SellaRec* [14]	[TBD]	[TBD]	–	–
SigLLM (đề xuất)	[TBD]	[TBD]	[TBD]	[TBD]

Lưu ý: Các ô [TBD] (To Be Determined) sẽ được điền sau khi hoàn thành thực nghiệm. Luận văn áp dụng tư thế thực nghiệm trung thực: không điền số liệu ước lượng hay giả định; chỉ báo cáo kết quả thực đo.

4.3 Phân tích nghịch lý AUC/uAUC

uAUC tính AUC trong phạm vi từng người dùng rồi lấy trung bình, nên bất biến với các phép biến đổi đơn điệu riêng theo người dùng. Điều này dẫn đến một đặc điểm quan trọng: tín hiệu CF nếu chỉ giúp phân biệt giữa các người dùng (thay đổi *mức nền* điểm dự đoán của mỗi người dùng) thì cải thiện AUC nhưng không cải thiện uAUC. Mô hình cần học thứ tự

xếp hạng *trong* từng người dùng – cặp vật phẩm nào người dùng này thích hơn – thay vì chỉ phân biệt người dùng với nhau.

Nếu thực nghiệm cho thấy SigLLM cải thiện AUC đáng kể nhưng uAUC tương đương CoLLM, đây không nhất thiết là thất bại: nó có thể phản ánh việc cầu nối Q-Former học được biểu diễn phân biệt giữa người dùng tốt hơn, nhưng chưa nắm được thứ tự nội-người-dùng một cách sâu. Mục 4.4 và 4.6 phân tích thêm điều này.

4.4 Phân tích ablation

Bảng 4.2 trình bày phân tích ablation các thành phần của SigLLM.

Bảng 4.2: Phân tích ablation trên MovieLens-1M. Mỗi hàng tắt/bật một thành phần.

Cấu hình	AUC	uAUC
SigLLM đầy đủ	[TBD]	[TBD]
– Không soft token (chỉ tiêm trọng số)	[TBD]	[TBD]
– Không tiêm trọng số (chỉ soft token)	[TBD]	[TBD]
– Không CF (chỉ text, LoRA cơ sở)	[TBD]	[TBD]
– Một token thay đa token	[TBD]	[TBD]
– Backbone Base thay Instruct	[TBD]	[TBD]
– Projector chung thay tách riêng	[TBD]	[TBD]
– Không InstructBLIP conditioning	[TBD]	[TBD]
SigLLM + InstructBLIP conditioning	[TBD]	[TBD]

Ablation chính: So sánh “Không CF” với các cấu hình có CF (bắt kể qua đường nào) đo đóng góp tổng thể của việc bơm tín hiệu cộng tác. So sánh “Không soft token” và “Không tiêm trọng số” tách biệt đóng góp của từng đường truyền. Hàng “Không InstructBLIP conditioning” vs. “SigLLM + InstructBLIP conditioning” đo trực tiếp đóng góp của cơ chế conditioning theo chỉ dẫn.

4.5 Phân tích bổ sung

4.5.1 Đo lường khoảng cách ngữ nghĩa

Để kiểm chứng rằng cầu nối Q-Former thực sự thu hẹp khoảng cách ngữ nghĩa giữa không gian CF và không gian LLM, luận văn đo cosine similarity giữa: (i) véc-tơ CF thô (đầu ra MF) và véc-tơ nhúng token LLM tương ứng trước khi huấn luyện cầu nối; (ii) soft token đầu ra Q-Former và véc-tơ nhúng token LLM sau khi huấn luyện. Kết quả kỳ vọng: cosine similarity tăng sau huấn luyện, cho thấy Q-Former thực sự căn chỉnh không gian CF về phía không gian ngữ nghĩa LLM.

4.5.2 Phân tích theo nhóm người dùng

Luận văn phân tích AUC và uAUC theo hai nhóm người dùng: (i) người dùng hoạt động (nhiều tương tác, MF tốt) và (ii) người dùng thừa thớt (ít tương tác, MF yếu). Nếu cầu nối Q-Former bổ sung được thông tin ngữ nghĩa từ LLM, kỳ vọng cải thiện rõ hơn ở nhóm người dùng thừa thớt – hướng đến giải quyết bài toán cold-start.

4.6 Thảo luận

4.6.1 Đối chiếu với ILM về giao thức đánh giá

ILM [8] không báo cáo AUC/uAUC theo giao thức CTR, nên không thể so sánh số liệu trực tiếp. Đây là lý do chính luận văn đặt ra mục tiêu đánh giá Q-Former dưới giao thức CoLLM: cung cấp cơ sở so sánh công bằng trong cùng điều kiện thực nghiệm.

4.6.2 Điểm mạnh và hạn chế của cầu nối Q-Former

So với lớp chiếu tuyến tính của CoLLM, cầu nối Q-Former có cơ chế trích chọn đặc trưng rõ ràng hơn qua cross-attention và có khả năng mở rộng bằng conditioning theo chỉ dẫn (InstructBLIP). Tuy nhiên, chi phí tính toán cao hơn và số tham số huấn luyện được nhiều hơn – một đánh đổi cần được cân nhắc tùy điều kiện triển khai.

4.7 Hạn chế

Luận văn thừa nhận các hạn chế thực nghiệm sau:

1. **Một tập dữ liệu:** Thực nghiệm chỉ trên MovieLens-1M; khả năng tổng quát sang domain khác chưa được kiểm chứng.
2. **Một seed:** Chưa có khoảng tin cậy; kết quả có thể dao động giữa các lần chạy khác nhau.
3. **Ablation InstructBLIP:** Nếu thực nghiệm ablation riêng InstructBLIP chưa hoàn thành, kết luận về đóng góp của InstructBLIP sẽ được ghi nhận là hướng phát triển thay vì đóng góp đã kiểm chứng.
4. **Baseline heterogeneous:** SellaRec dùng backbone Qwen khác; so sánh với SellaRec phản ánh sự khác biệt cả về cơ chế lẫn backbone LLM.

Chương 5

Kết luận và Hướng phát triển

5.1 Tóm tắt đóng góp

Luận văn đặt ra câu hỏi: liệu cầu nối Q-Former – với cơ chế cross-attention có kiểm soát – có thể thực hiện căn chỉnh tín hiệu CF vào không gian ngữ nghĩa LLM hiệu quả hơn lớp chiếu tuyến tính của CoLLM? Để trả lời, luận văn thiết kế, hiện thực và đánh giá mô hình SigLLM, đóng góp theo hai hướng đã phát biểu ở Mục 1.4:

Đóng góp 1: Cầu nối Q-Former được thích nghi và tăng cường cho bài toán gợi ý. SigLLM thay thế lớp MLP một lớp của CoLLM bằng kiến trúc Q-Former, trong đó tín hiệu CF (nhúng người dùng, vật phẩm mục tiêu, lịch sử) thay thế đặc trưng ảnh làm đầu vào cross-attention. Bên cạnh kiến trúc cơ sở, luận văn khảo sát các lựa chọn thiết kế (biểu diễn đa token, backbone LLM đã instructed, tách lớp chiếu người dùng/vật phẩm) và InstructBLIP như hướng tăng cường chính. Kết quả chi tiết được trình bày ở Chương 4.

Đóng góp 2: Đánh giá có hệ thống dưới giao thức AUC/uAUC. Luận văn là, theo hiểu biết của tác giả, đánh giá cầu nối Q-Former trong bài toán gợi ý dưới giao thức CTR với AUC và uAUC – cùng giao thức với CoLLM – cho phép so sánh trực tiếp. Phân tích ablation tách biệt đóng góp của từng thành phần.

5.2 Kết quả đạt được

[Phần này sẽ được hoàn thiện sau khi thực nghiệm hoàn thành. Số liệu thực đo sẽ được điền vào đây.]

Từ kết quả ở Bảng 4.1 và 4.2, có thể rút ra các kết luận sau:

- *[Phân tích kết quả so với CoLLM về AUC và uAUC – điền sau thực nghiệm.]*
- *[Phân tích ablation: đường nào (soft token, tiêm trọng số) đóng góp nhiều hơn – điền sau thực nghiệm.]*
- *[Phân tích InstructBLIP conditioning: có cải thiện không – điền sau thực nghiệm.]*

5.3 Hạn chế

Luận văn thừa nhận các hạn chế sau, được thừa nhận minh bạch thay vì che giấu:

1. **Phạm vi thực nghiệm hẹp:** Chỉ thực nghiệm trên MovieLens-1M. Tập Amazon Books – được đề xuất trong đề cương – được chuyển sang hướng phát triển để tập trung phân tích chuyên sâu trên một tập dữ liệu.
2. **Thiếu khoảng tin cậy:** Kết quả từ một seed duy nhất. Biến động thống kê giữa các lần chạy chưa được đo.
3. **Ablation InstructBLIP chưa đầy đủ:** Nếu bật/tắt riêng InstructBLIP conditioning chưa được thực nghiệm đủ, kết luận về đóng góp riêng của nó còn hạn chế.

4. **Chi phí tính toán cao hơn CoLLM:** Q-Former và đường tiềm trọng số làm tăng chi phí huấn luyện so với lớp MLP đơn giản của CoLLM.
5. **Baseline không đồng nhất:** SellaRec dùng backbone LLM khác, giới hạn khả năng so sánh thuần về cơ chế căn chỉnh.

5.4 Hướng phát triển

Từ những hạn chế và quan sát của luận văn, các hướng nghiên cứu tiếp theo được đề xuất:

Mở rộng thực nghiệm:

- Đánh giá trên Amazon Books và các tập dữ liệu ngoài domain phim để kiểm chứng khả năng tổng quát.
- Chạy nhiều seed và báo cáo $\text{mean} \pm \text{std}$ để đánh giá độ ổn định.

Ablation và phân tích sâu hơn:

- Ablation bật/tắt riêng InstructBLIP conditioning để chốt đóng góp độc lập của thành phần này.
- Phân tích attention map của Q-Former để hiểu truy vấn nào học cách trích xuất thông tin gì từ tín hiệu CF.

Cải thiện uAUC:

- Tiền huấn luyện MF trên dữ liệu dày đặc hơn (nhiều tháng hơn) để cải thiện chất lượng nhúng CF, từ đó cải thiện thứ tự xếp hạng nội-người-dùng.
- Thêm mục tiêu bảo toàn thứ tự (ranking loss) trong Giai đoạn 3 để tối ưu trực tiếp uAUC.

Mở rộng kiến trúc:

- Nghiên cứu kết hợp CoRA (tiêm trọng số) và soft token trong một pipeline thống nhất như đề xuất trong SigLLM, và so sánh với CoRA nguyên bản chỉ dùng tiêm trọng số.
- Khảo sát các backbone LLM khác (Llama-3, Mistral) để kiểm chứng tính tổng quát của cầu nối Q-Former.

Tài liệu tham khảo

- [1] S. Zhang, L. Yao, A. Sun, and Y. Tay, “Deep learning based recommender system: A survey and new perspectives,” *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019. DOI: 10.1145/3285029
- [2] Y. Koren, R. Bell, and C. Volinsky, “Matrix factorization techniques for recommender systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263
- [3] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063
- [4] L. Wu et al., “A survey on large language models for recommendation,” *arXiv preprint arXiv:2305.19860*, 2023.
- [5] Y. Zhang, F. Feng, J. Zhang, K. Lv, and X. He, “CoLLM: Integrating collaborative embeddings into large language models for recommendation,” *arXiv preprint arXiv:2310.19488*, 2023.
- [6] J. Li, D. Li, S. Savarese, and S. Hoi, “BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models,” in *Proceedings of the 40th International Conference on Machine Learning*, 2023, pp. 19 730–19 742.

- [7] W. Dai et al., “InstructBLIP: Towards general-purpose vision-language models with instruction tuning,” *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [8] L. Yang et al., “Item-language model for conversational recommendation,” *arXiv preprint arXiv:2406.02844*, 2024.
- [9] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, 2009, pp. 452–461.
- [10] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T.-S. Chua, “Neural collaborative filtering,” in *Proceedings of the 26th International Conference on World Wide Web*, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569
- [11] S. Geng, S. Liu, Z. Fu, Y. Ge, and Y. Zhang, “Recommendation as language processing (RLP): A unified pretrain, personalized prompt & predict paradigm (P5),” in *Proceedings of the 16th ACM Conference on Recommender Systems*, 2022, pp. 299–315. DOI: 10.1145/3523227.3546767
- [12] K. Bao et al., “BIGRec: A generalizable and controllable large language model framework for recommendation,” *arXiv preprint arXiv:2308.12242*, 2023.
- [13] H. Touvron et al., “Llama 2: Open foundation and fine-tuned chat models,” *arXiv preprint arXiv:2307.09288*, 2023.
- [14] Z. Wang et al., “Enhancing LLM-based recommendation through semantic-aligned collaborative knowledge,” *arXiv preprint arXiv:2504.10107*, 2025.
- [15] A. Yang et al., “Qwen2 technical report,” *arXiv preprint arXiv:2407.10671*, 2024.

- [16] Y. Zhang, K. Bao, M. Yan, W. Wang, F. Feng, and X. He, “Text-like encoding of collaborative information in large language models for recommendation,” in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024)*, arXiv:2406.03210; model referred to in thesis as BinLLM, 2024.
- [17] J. Zhang, K. Bao, Y. Zhang, W. Wang, F. Feng, and X. He, “CoRA: Collaborative information perception by large language model’s weights for recommendation,” *arXiv preprint arXiv:2408.10645*, 2024.
- [18] J.-B. Alayrac et al., “Flamingo: A visual language model for few-shot learning,” in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 23 716–23 736.
- [19] E. J. Hu et al., “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022.
- [20] F. M. Harper and J. A. Konstan, “The MovieLens datasets: History and context,” *ACM Transactions on Interactive Intelligent Systems*, vol. 5, no. 4, pp. 1–19, 2015. DOI: 10.1145/2827872