

**ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN**

Họ tên HVCH: Bùi Nguyên Quốc Bảo
Mã số học viên: 24C12002

**ĐỀ CƯƠNG NGHIÊN CỨU ĐỀ TÀI
LUẬN VĂN THẠC SĨ**

Tên đề tài:

**NÂNG CAO HIỆU QUẢ HỆ THỐNG TƯ VẤN SỬ DỤNG MÔ HÌNH NGÔN NGỮ LỚN KẾT
HỢP KỸ THUẬT CÁN CHỈNH ĐA PHƯƠNG THỨC THÔNG TIN CỘNG TÁC**

Ngành: Hệ thống thông tin

Mã số ngành: 8480104

Xác nhận của giảng viên hướng dẫn
(Ký tên và ghi rõ họ tên)

Họ tên:.....

TP. HCM, tháng năm

NỘI DUNG

1. Giới thiệu tổng quan:

Với sự phát triển nhanh chóng của nhiều nền tảng số và dịch vụ web như hiện nay, từ thương mại điện tử, giáo dục trực tuyến đến truyền thông, hệ thống tư vấn (RecSys, RS) dần đóng vai trò thiết yếu để giải quyết những nhu cầu tư vấn những sản phẩm phù hợp tới nhu cầu của người dùng. Các phương pháp, kỹ thuật tư vấn truyền thống như Collaborative Filtering (lọc cộng tác), Matrix Factorization, ... đã được nghiên cứu phát triển và ứng dụng rộng rãi trong nhiều thập kỷ qua dựa trên ma trận lịch sử tương tác người dùng – sản phẩm. Tuy nhiên, các kỹ thuật này vẫn còn nhiều hạn chế: vấn đề dữ liệu thưa (sparse data), bài toán khởi động nguội (cold start) và đặc biệt những hạn chế trong việc thiếu kiến thức về thế giới thực và khả năng “hiểu” sở thích và động lực thực sự của người dùng còn kém [1]. Trong khi đó, sự nổi lên của các Mô hình Ngôn ngữ Lớn (LLM – Large Language Models) trong các tác vụ xử lý ngôn ngữ tự nhiên đánh dấu một cột mốc cách mạng và có nhiều tiềm năng mang lại sự thay đổi lớn trong nhiều lĩnh vực khác. Các mô hình LLM có khả năng hiểu ngôn ngữ nghĩa, tổng quát hóa và suy luận cực kỳ ấn tượng. Sự phát triển của các mô hình LLM cũng đang truyền cảm hứng cho nhiều hướng nghiên cứu mới và đầy hứa hẹn đối với lĩnh vực hệ thống tư vấn, nhờ vào khả năng hiểu ngữ nghĩa của các mô hình này.

Hiện nay, nhiều nghiên cứu đã khai thác LLM trong hệ thống tư vấn. Các khảo sát như "Towards Next-Generation LLM-based Recommender Systems: A Survey and Beyond" và "How Can Recommender Systems Benefit from Large Language Models" hệ thống hoá toàn diện các hướng kết hợp LLM với recommendation. Các nghiên cứu chia hướng khai thác LLM thành hai hướng tiếp cận chính: LLMs-as-Recommender Systems (LLMs as RS) – tức sử dụng LLM như một mô hình tư vấn hoàn chỉnh; và LLM-enhanced RS – tức dùng LLM như một thành phần hỗ trợ trong các hệ thống RS truyền thống [2]. Cách phân loại này thể hiện rõ vai trò của LLM trong các hệ thống tư vấn: hoặc đảm nhận trực tiếp nhiệm vụ tư vấn đầu cuối, hoặc đóng vai trò cải thiện, bổ sung cho các hệ tư vấn truyền thống như bộ mã hóa đặc trưng ngữ nghĩa hoặc bộ giải thích sở thích người dùng. Việc phân biệt này giúp hình thành cơ sở cho việc lựa chọn phương pháp tiếp cận phù

hợp trong nghiên cứu phát triển hệ thống tư vấn sử dụng mô hình ngôn ngữ lớn (LLM). Đề tài lựa chọn hướng LLM-as-Recommender Systems, với mục tiêu khai thác trực tiếp khả năng suy luận và biểu diễn ngữ nghĩa mạnh mẽ của các mô hình ngôn ngữ lớn (LLMs) để thực hiện nhiệm vụ tư vấn. Trọng tâm nghiên cứu là căn chỉnh và tích hợp thông tin cộng tác và không gian ngữ nghĩa của LLM, qua đó giúp LLM vừa tiếp nhận được thông tin cộng tác từ lịch sử tương tác người dùng – sản phẩm, vừa duy trì ưu thế về khả năng hiểu ngữ nghĩa. Cách tiếp cận này kỳ vọng tạo ra một hệ thống tư vấn hiệu quả hơn trong cả bối cảnh cold-start và warm-start, đồng thời cải thiện tính chính xác và khả năng giải thích so với các mô hình truyền thống.

Các hệ thống tư vấn theo hướng LLMs-as-RS thường tận dụng khả năng hiểu ngữ nghĩa và năng lực suy luận của LLM để trực tiếp thực hiện tác vụ tư vấn – ví dụ như sinh ra danh sách các sản phẩm phù hợp cho người dùng dưới dạng văn bản. Ưu điểm nổi bật của cách tiếp cận này là khả năng hiểu ngữ cảnh sâu, tận dụng tri thức ngôn ngữ và thế giới thực mà LLM đã học được để giải mã sở thích tiềm ẩn hoặc giải thích lý do cho mỗi đề xuất. Điều này đặc biệt hữu ích để giải quyết vấn đề cold start: thiếu dữ liệu lịch sử tương tác rõ ràng của người dùng mới, sản phẩm mới – điểm yếu cố hữu của hệ thống tư vấn truyền thống, hệ tư vấn lọc cộng tác. Tuy nhiên, LLMs-as-RS cũng tồn tại nhiều thách thức đáng kể. Đầu tiên là độ trễ suy luận cao (i): quá trình sinh văn bản (token-by-token) từ mô hình autoregressive rất tốn thời gian và tài nguyên, gây khó khăn trong việc áp dụng cho các hệ thống yêu cầu phản hồi theo thời gian thực. Thứ hai, các LLM thường không được huấn luyện đặc biệt cho tác vụ tư vấn (ii), nên thiếu khả năng học thông tin cộng tác do không được bổ sung thông tin cộng tác hoặc có bổ sung nhưng chưa hiệu quả. Việc mô hình hóa sở thích người dùng chỉ thông qua văn bản mà không có cơ chế học từ tập dữ liệu lịch sử tương tác người dùng – sản phẩm, hoặc cơ chế bổ sung thông tin cộng tác chưa hiệu quả (do giới hạn độ dài ngữ cảnh của LLM, khiến việc mô tả đầy đủ hành vi người dùng và đặc trưng sản phẩm dưới dạng văn bản trở nên bất khả thi, đặc biệt với người dùng có nhiều lượt tương tác), khiến hiệu quả tư vấn chưa tối ưu.

Ngược lại, các hệ thống tư vấn truyền thống như Matrix Factorization, LightGCN hay các mô hình two-tower CF được thiết kế chuyên biệt cho tác vụ tư vấn, nên rất hiệu quả về mặt tính toán. Chúng có thể tạo ra đề xuất theo thời gian thực với độ trễ cực thấp,

đễ dàng triển khai ở quy mô lớn (hàng triệu người dùng và sản phẩm). Các mô hình này khai thác trực tiếp cấu trúc tương tác người dùng – sản phẩm để học ra sở thích ngầm, giúp nắm bắt thông tin cộng tác một cách hiệu quả. Tuy nhiên, nhược điểm lớn của RecSys truyền thống là thiếu khả năng hiểu ngữ cảnh, không tận dụng được thông tin phong phú từ nội dung mô tả (text, metadata), hoặc kiến thức thế giới bên ngoài. Điều này khiến hệ thống gặp khó khăn trong bài toán cold-start, không lý giải được vì sao sản phẩm được tư vấn, và thường phải phụ thuộc vào số lượng lớn tương tác để học được mô hình tốt.

Chính vì vậy, việc kết hợp LLM vào hệ thống tư vấn đang được xem là một hướng đi tiềm năng nhằm kết hợp khả năng hiểu ngữ nghĩa sâu của LLM và xử lý đa phương thức của LLM với thông tin cộng tác trên lịch sử tương tác của các mô hình truyền thống. Một hướng nghiên cứu nổi bật mới hình thành và phát triển trong những năm gần đây: LLMs-as RS, trong đó chính mô hình ngôn ngữ lớn đóng vai trò là hệ thống tư vấn cốt lõi. Khác với các phương pháp tăng cường (LLM-enhanced RS) chỉ sử dụng LLM như thành phần phụ trợ, LLMs-as-RS tận dụng trực tiếp năng lực ngôn ngữ của LLM để sinh ra tư vấn. Tuy nhiên, để đạt được hiệu quả ngang bằng hoặc vượt qua hệ thống lọc cộng tác, đặc biệt là trong điều kiện warm-start, thách thức then chốt là thu hẹp khoảng cách ngữ nghĩa khi tích hợp thông tin cộng tác vào không gian LLM (semantic gap) – tức gắn kết hai không gian: không gian ngữ nghĩa mà LLM học được và không gian biểu diễn sở thích tiềm ẩn (latent vector) từ lịch sử tương tác người dùng – sản phẩm. Giải quyết được khoảng cách ngữ nghĩa khi tích hợp với thông tin cộng tác sẽ giúp các mô hình LLMs-as-RS vừa tận dụng tri thức ngữ nghĩa sâu, vừa tiếp nhận thông tin cộng tác một cách hiệu quả, mở đường cho các hệ thống tư vấn thể hệ mới vừa giàu ý nghĩa, vừa đủ chính xác và có khả năng thích ứng cao trong thực tiễn.

Đáng chú ý, các nghiên cứu gần đây đề xuất những mô hình như CoLLM [2], ILM [3] và SeLLa-Rec [4] đã cho thấy tiềm năng rõ rệt của hướng LLMs-as-RS kết hợp đa phương thức, khi tận dụng trực tiếp tri thức ngữ nghĩa và năng lực suy luận của LLM kết hợp thông tin cộng tác để thực hiện tác vụ tư vấn. Các mô hình này minh chứng rằng việc kết hợp không gian ngữ nghĩa của LLM với thông tin cộng tác từ lịch sử tương tác thông qua các kỹ thuật căn chỉnh đa phương thức (multimodal alignment) có thể thu hẹp đáng kể khoảng cách ngữ nghĩa, từ đó nâng cao độ chính xác đặc biệt trong kịch bản warm-

start. Đồng thời, kết quả các nghiên cứu cũng chỉ ra khả năng triển khai thực tế là hoàn toàn khả thi, khi độ trễ được giảm thiểu và chi phí tính toán vẫn duy trì ở mức chấp nhận được.

Mô hình	Vai trò của LLM	Ưu điểm	Hạn chế
Traditional CF (MF, LightGCN)	Không sử dụng	Hiệu quả tính toán, dễ triển khai, latency nhỏ, dễ triển khai công nghiệp, dễ scale	Không hiểu ngữ cảnh, không giải thích được kết quả tư vấn, không hoạt động tốt khi gặp cold-start
LLM – enhanced RS	LLM dùng làm encoder, scoring, hoặc hỗ trợ reasoning	Kết hợp được Semantic + CF, giảm latency, tăng độ chính xác	Cần tinh chỉnh mô hình ngôn ngữ cho tác vụ gợi ý hoặc sử dụng SLM nhằm giảm chi phí tính toán, khó tận dụng tri thức thế giới sâu như LLM-as-RS.
LLM as RS (CoLLM, ILM, SELLA-Rec...)	LLM sinh trực tiếp đầu ra (Yes / No hoặc tư vấn) qua prompt	Hiểu ngữ nghĩa, lý giải được tư vấn, giải quyết tốt cold start	Tốc độ chậm, khoảng cách ngữ nghĩa giữa không gian ngữ nghĩa và không gian cộng tác, cần cơ chế căn chỉnh thông tin cộng tác vào không gian ngữ nghĩa để đạt được kết quả tư vấn chính xác hơn (projection, contrastive learning,...)

Bảng. Một số hướng tiếp cận tiêu biểu trong hệ thống tư vấn

Từ bảng phân tích một số hướng tiếp cận tiêu biểu trong việc tích hợp mô hình ngôn ngữ lớn (LLM) vào hệ thống tư vấn, ta có thể nhận thấy rằng mỗi phương pháp đều

mang lại những đóng góp quan trọng nhưng vẫn tồn tại những hạn chế nhất định. Các mô hình như CoLLM (Wang et al., 2024) [2] đã nỗ lực tích hợp thông tin cộng tác vào không gian ngôn ngữ bằng cách ánh xạ embedding cộng tác từ mô hình LightGCN vào LLM, đồng thời áp dụng kỹ thuật LoRA để fine-tune LLM hiệu quả với chi phí huấn luyện thấp hơn. Tuy nhiên, CoLLM vẫn đối mặt với vấn đề semantic gap (khoảng cách ngữ nghĩa): LLM có khả năng xử lý ngữ nghĩa và tri thức thế giới mạnh, nhưng lại khó tiếp nhận và tận dụng đầy đủ các thông tin cộng tác vốn phản ánh sở thích ngầm từ lịch sử tương tác người dùng – sản phẩm, vì CoLLM chỉ tích hợp 1 lớp ánh xạ MLP đơn giản. Sự khác biệt trong việc biểu diễn vector giữa 2 không gian này khiến mô hình chưa khai thác tối đa sức mạnh của cả thông tin cộng tác lẫn khả năng hiểu ngữ nghĩa của LLM. Vì vậy, nghiên cứu này tập trung đề xuất một hướng cải tiến CoLLM nhằm thu hẹp khoảng cách ngữ nghĩa giữa vector embedding cộng tác và semantic embedding của LLM, thông qua sử dụng các kỹ thuật căn chỉnh đa phương thức tốt hơn cho các mô hình tư vấn sử dụng ngôn ngữ lớn tích hợp thông tin cộng tác. Cụ thể, mô hình hướng tới căn chỉnh và tích hợp giữa thông tin cộng tác và không gian ngữ nghĩa của mô hình ngôn ngữ lớn thông qua các cơ chế căn chỉnh đa phương thức (multimodal alignment). Để đạt được điều này, nghiên cứu xem xét, so sánh và sử dụng cơ chế căn chỉnh hiệu quả trong các cơ chế căn chỉnh đa phương thức hiện được đề xuất [5], bao gồm:

Kỹ thuật / Mô hình	Cơ chế	Ưu điểm	Hạn chế
Multi-layer Perceptron (MLP)	Sử dụng một hoặc nhiều lớp MLP để ánh xạ embedding cộng tác (CF) sang không gian embedding ngữ nghĩa của LLM	Đơn giản, dễ triển khai, chi phí huấn luyện thấp, hoạt động ổn định trong điều kiện dữ liệu hạn chế	Bị giới hạn về khả năng biểu diễn phi tuyến phức tạp; không nắm bắt được mối quan hệ ngữ nghĩa sâu giữa hai không gian embedding, dẫn đến hiện tượng semantic gap.
Contrastive Learning	Học hàm ánh xạ sao cho embedding của các cặp user/item –	Đơn giản, hiệu quả, và đặc biệt phù hợp cho alignment giữa	Cần số lượng mẫu âm (negative pairs) đủ lớn và kỹ thuật sampling tốt

	text tương ứng được kéo lại gần nhau, trong khi các cặp không liên quan bị đẩy xa ra, thông qua contrastive loss (ví dụ InfoNCE)	hai không gian khác biệt; giúp LLM dễ dàng nhận dạng và phân biệt mối quan hệ ngữ nghĩa liên qua	để đảm bảo độ ổn định; đôi khi chỉ cần chỉnh ở mức toàn cục mà chưa học được cấu trúc ngữ nghĩa chi tiết
Variational Autoencoder (VAE)	Mã hóa embedding cộng tác và embedding ngữ nghĩa vào một không gian tiềm ẩn chung, trong đó các vector tương ứng có phân phối gần nhau, giúp giảm khoảng cách giữa hai miền biểu diễn	Tạo sự tương thích phân phối tự nhiên giữa CF và LLM, giúp mô hình hiểu được quan hệ tiềm ẩn phức tạp; tăng khả năng tổng quát hóa và hỗ trợ học không giám sát	Huấn luyện phức tạp hơn do cần tối ưu reconstruction loss và KL divergence; dễ gặp hiện tượng posterior collapse hoặc mất thông tin khi không cân bằng tốt giữa hai miền dữ liệu
Q-Former	Học một tập các query embeddings để trích xuất thông tin ngữ nghĩa quan trọng từ vector cộng tác và ánh xạ có chọn lọc (selective mapping) sang không gian LLM thông qua cơ chế cross-attention	Giữ nguyên cấu trúc của LLM (LLM frozen), đồng thời cho phép mô hình học cách kết nối hai không gian một cách có kiểm soát; tăng khả năng diễn giải và linh hoạt trong quá trình fusion.	Cần tinh chỉnh số lượng query và độ sâu attention phù hợp; chi phí tính toán cao hơn so với MLP, đặc biệt khi số lượng user/item embedding lớn.

Bảng. Tổng hợp các cơ chế căn chỉnh đa phương thức.

Song song, mô hình áp dụng LoRA để tinh chỉnh có chọn lọc các tham số trong LLM thay vì fine-tune toàn bộ mô hình. Cách tiếp cận này kỳ vọng giúp LLM vừa duy trì được khả năng hiểu ngữ nghĩa sâu, vừa tiếp nhận hiệu quả thông tin cộng tác, từ đó nâng cao chất lượng tư vấn và đảm bảo khả năng triển khai trong các ứng dụng thực tế.

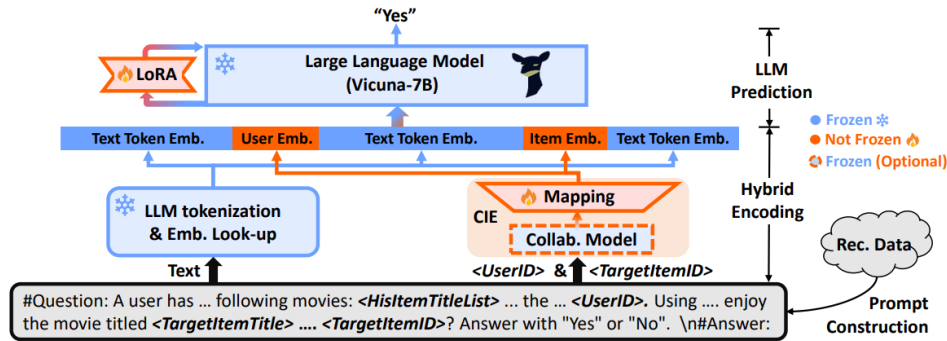


Figure 2: Model architecture overview of our CoLLM, comprising three key components: prompt construction, hybrid encoding, and LLM prediction. “Collab.” is short for “collaborative”, “Rec.” for “recommendation”, and “Emb.” for “embedding”.

Hình: Mô hình CoLLM

2. Mục đích nghiên cứu

- Tính cấp thiết:

Hiện nay, các hệ thống tư vấn cá nhân hóa đóng vai trò quan trọng trong việc giúp người dùng định hướng thông tin, sản phẩm, dịch vụ phù hợp trên các nền tảng số. Mặc dù các mô hình truyền thống như Collaborative Filtering hay Matrix Factorization đã được triển khai rộng rãi, chúng vẫn bộc lộ những điểm yếu về khả năng hiểu ngữ nghĩa và xử lý ngữ cảnh sâu. Sự phát triển mạnh mẽ của các mô hình ngôn ngữ lớn (LLMs) như LLaMA, GPT, BERT... đã mở ra một hướng đi mới đầy tiềm năng. Các nghiên cứu như CoLLM đã bước đầu tích hợp latent vector từ mô hình cộng tác vào không gian ngôn ngữ của LLM nhằm khai thác đồng thời tín hiệu hành vi và tri thức ngữ nghĩa. Tuy nhiên, các mô hình này vẫn đối mặt với vấn đề khoảng cách ngữ nghĩa giữa không gian cộng tác và không gian LLM, khiến LLM khó tận dụng đầy đủ các tín hiệu hành vi tiềm ẩn từ dữ liệu lịch sử tương tác. Do đó, cần có một hướng cải tiến để thu hẹp khoảng cách ngữ nghĩa, vừa tận dụng được tri thức ngữ nghĩa phong phú từ LLM, vừa kế thừa khả năng học thông tin cộng tác hiệu quả, từ đó nâng cao chất lượng tư vấn và khả năng ứng dụng thực tiễn.

- Tính mới, ý nghĩa thực tiễn của đề tài:

So với các mô hình hiện có như CoLLM – vốn đã mở đường cho việc tích hợp embedding cộng tác vào không gian LLM thông qua ánh xạ trực tiếp – nghiên cứu này

tập trung thu hẹp khoảng cách ngữ nghĩa (semantic gap) cho thông tin cộng tác bằng cách ứng dụng các cơ chế căn chỉnh đa phương thức (multimodal alignment). Cụ thể, mô hình căn chỉnh và tích hợp thông tin cộng tác với không gian ngữ nghĩa của LLM thông qua các việc sử dụng 1 trong các cơ chế đề xuất như MLP projection, Contrastive Learning, Variational Autoencoder (VAE) và Q-Former, nhằm giúp LLM vừa duy trì khả năng hiểu ngữ nghĩa và tri thức thế giới, vừa hấp thụ hiệu quả tín hiệu cộng tác để nâng cao chất lượng tư vấn. Cách tiếp cận này vừa giúp mô hình duy trì khả năng hiểu ngữ nghĩa và tri thức thế giới vốn có của LLM, vừa khai thác hiệu quả hơn tín hiệu hành vi từ dữ liệu người dùng. Nhờ đó, mô hình không chỉ cải thiện độ chính xác tư vấn, mà còn giảm thiểu semantic gap – một trong những thách thức trọng yếu khi tích hợp LLM vào hệ thống tư vấn – đồng thời vẫn đảm bảo chi phí huấn luyện và khả năng triển khai thực tế ở mức hợp lý.

3. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là mô hình CoLLM – một kiến trúc tư vấn dựa trên LLM với khả năng tích hợp embedding cộng tác vào không gian ngôn ngữ. Trên cơ sở đó, đề tài tập trung vào việc cải tiến cơ chế căn chỉnh giữa thông tin cộng tác và không gian ngữ nghĩa của LLM nhằm thu hẹp khoảng cách ngữ nghĩa. Cụ thể, nghiên cứu xem xét các hướng cải tiến như: (i) thay thế ánh xạ tuyến tính đơn giản bằng các kỹ thuật căn chỉnh để tăng khả năng hòa nhập thông tin cộng tác vào LLM; (ii) sử dụng LoRA để fine-tuning 1 phần mô hình LLM thay vì huấn luyện toàn bộ mô hình để giảm chi phí tính toán; và (iii) thiết kế kiến trúc theo hướng modular, tách biệt khối biểu diễn và khối dự đoán, giúp mô hình dễ mở rộng, triển khai linh hoạt hơn trong các hệ thống tư vấn thực tế.

4. Các phương pháp nghiên cứu

Để hiện thực hóa mục tiêu thu hẹp semantic gap và cải tiến mô hình CoLLM, đề tài sẽ áp dụng tổng hợp các phương pháp nghiên cứu lý thuyết và thực nghiệm như sau:

a. Phương pháp nghiên cứu lý thuyết:

Phân tích tài liệu học thuật và khảo sát tổng quan:

- Nghiên cứu các mô hình tư vấn kết hợp LLM cố gắng giải quyết semantic gap (như CoLLM [2], ILM [3], SeLLa-Rec [4]), các kỹ thuật

tích hợp embedding cộng tác, kỹ thuật căn chỉnh không gian ngữ nghĩa (projection, constrastive learning, attention-based fusion, Q-Former, VAE, ...) và các kỹ thuật tinh chỉnh tham số như LoRA.

- Cơ sở lý thuyết được xây dựng dựa trên các bài báo gần đây như: CoLLM: Integrating Collaborative Embeddings into Large Language Models for Recommendation (Wang et al., 2024) [2], Item-Language Model for Conversational Recommendation, (Li Yang et al., 2024) [3], Enhancing LLM-based Recommendation through Semantic-Aligned Collaborative Knowledge (Wang et al., 2024) [4], survey Multimodal Alignment and Fusion: A Survey [5] và How Can Recommender Systems Benefit from Large Language Models? (Lin et al., 2023) [7].
- Đề xuất mô hình cải tiến sử dụng các cơ chế căn chỉnh: Dựa trên cấu trúc gốc của CoLLM, đề tài đề xuất cải tiến mới thay vì chỉ dùng lớp projection tuyến tính, sẽ áp dụng kỹ thuật căn chỉnh nâng cao như đã đề cập bên trên để thu hẹp semantic gap khi tích hợp thông tin cộng tác đa phương thức vào LLM. Ngoài ra áp dụng LoRA để tinh chỉnh một phần nhỏ tham số trong LLM cho tác vụ tư vấn, giúp giảm chi phí huấn luyện mà vẫn đảm bảo hiệu quả.

b. Phương pháp nghiên cứu thực nghiệm

Dữ liệu thực nghiệm:

- Sử dụng các tập dữ liệu tư vấn tiêu chuẩn như MovieLens 1M, Amazon Book, đảm bảo có đầy đủ thông tin tương tác và mô tả nội dung.

Huấn luyện mô hình:

- Baseline: triển khai CoLLM gốc với backbone LLM decoder-based (ví dụ GPT-2, Mistral-7B), sử dụng projection tuyến tính để ánh xạ embedding cộng tác vào không gian LLM.
- Cải tiến: giữ nguyên pipeline CoLLM, thay thế lớp projection tuyến tính bằng cơ chế semantic alignment như đã đề cập phía trên. Áp dụng LoRA để tinh chỉnh một số lớp của LLM thay vì full fine-tuning nhằm tiết kiệm tài nguyên.

So sánh mô hình:

- Các baseline gồm: Matrix Factorization, CoLLM.
- Mô hình được đánh giá theo các tiêu chí:
 - Độ chính xác phân loại (binary prediction): Accuracy, F1-score, AUC.
 - Hiệu quả top-k recommendation: Precision@K, NDCG@K
 - Số lượng tham số tinh chỉnh: triệu tham số (million parameters)
 - Khả năng thu hẹp semantic gap: cosine similarity giữa embedding CF và semantic embedding sau alignment.

c. Công cụ và thiết bị sử dụng:

Ngôn ngữ lập trình: Python 3.10 Framework: PyTorch, HuggingFace Transformers, PEFT (LoRA), Scikit-learn,...

Thiết bị tính toán: Google Colab Pro / Google Cloud với GPU A100 (nếu có)

d. Phương pháp kiểm tra và đánh giá

Áp dụng cross-validation với K-fold hoặc Holdout set để đảm bảo kết quả ổn định. Chạy thử nghiệm trên nhiều seed để đánh giá độ tin cậy. Phân tích kết quả theo từng khía cạnh: cold-start, warm-start, classification accuracy (F1, AUC,...), semantic alignment.

Công cụ:

- Huggingface Transformers, PEFT/LoRA.
- PyTorch, scikit-learn, Colab Pro, OpenRouter API.

5. Nội dung và phạm vi của vấn đề sẽ đi sâu nghiên cứu

Đề tài tập trung cải tiến mô hình CoLLM bằng cách thay thế cơ chế ánh xạ tuyến tính từ embedding cộng tác sang không gian ngữ nghĩa của LLM bằng các kỹ thuật alignment (như contrastive learning, lớp MLP projection, VAE, Q-Former, ...), nhằm thu hẹp semantic gap và tăng cường khả năng căn chỉnh đa phương thức (multimodal alignment) nhằm nâng cao chất lượng tư vấn. Nghiên cứu giữ nguyên cấu trúc backbone của LLM và chỉ áp dụng tinh chỉnh chọn lọc bằng LoRA để tiết kiệm tài nguyên huấn luyện, đồng thời đảm bảo tính khả thi triển khai. Phạm vi thực nghiệm được tiến hành trên các tập dữ liệu MovieLens và Amazon Books, so sánh với các mô hình baseline và đánh giá theo các chỉ số Accuracy, F1, Precision@K, NDCG@K, cũng như mức độ semantic alignment giữa không gian CF và LLM..

6. Nơi thực hiện đề tài nghiên cứu của luận văn

Đề tài nghiên cứu được thực hiện tại Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM.

7. Thời gian thực hiện:

Mục tiêu	Thời gian	Nội dung
Luận văn	01 tháng	Giai đoạn 1: Khảo sát tổng quan về các hệ thống tư vấn truyền thống và các hướng tiếp cận hiện đại tích hợp LLM như CoLLM, ILM, SeLLa-Rec, BinLLM. Phân tích các giới hạn của CF truyền thống, cold-start, và tiềm năng của LLM và các kỹ thuật tinh chỉnh như LoRA Khảo sát các nghiên cứu giải quyết semantic gap giữa thông tin cộng tác và không gian ngữ nghĩa của LLM như CoLLM, SeLLa-Rec, ILM và các kỹ thuật căn chỉnh embedding cộng tác vào không gian ngữ nghĩa LLM
	03 tháng	Giai đoạn 2: Triển khai pipeline CoLLM: – Huấn luyện mô hình CF nền (MF). – Thay thế ánh xạ projection tuyến tính bằng các kỹ thuật semantic alignment như đã đề cập để thu hẹp semantic gap giữa embedding của thông tin cộng tác đa phương thức và không gian ngữ nghĩa của LLM. – Thiết kế prompt template kết hợp embedding và ngữ cảnh. – Tinh chỉnh bằng LoRA cho tác vụ tư vấn
	02 tháng	Giai đoạn 3: Thực nghiệm và đánh giá: – Tiền xử lý dữ liệu (MovieLens 1M hoặc Amazon Books). – Chạy thử nghiệm với nhiều loại prompt, nhiều mức fine-tune (LoRA vs zero-shot). – Đánh giá bằng các chỉ số RMSE, MAE (score); Precision@K, Recall@K, NDCG (top-k). – So sánh chi phí inference, độ phức tạp mô hình.
	1,5 tháng	Giai đoạn 4: Viết khóa luận thạc sĩ

	0,5 tháng	Giai đoạn 5: Báo cáo khóa luận thạc sĩ
--	-----------	---

8. Các tài liệu tham khảo được sử dụng khi viết đề cương:

- [1] Q. WANG, J. LI and S. WANG, "Towards Next-Generation LLM-based Recommender Systems: A Survey and Beyond," 2024.
- [2] Y. Zhang, F. Feng, J. Zhang, K. Bao, Q. Wang and X. He, "CoLLM: Integrating Collaborative Embeddings into Large Language Models for Recommendation," 2020.
- [3] L. Y. *. al, "Item-Language Model for Conversational Recommendation," 2024.
- [4] Z. Wang, J. Lin, X. Yang, Y. Liu, S. Feng, D. Wang and Y. Zhang, "Enhancing LLM-based Recommendation through Semantic-Aligned Collaborative Knowledge," 2025.
- [5] S. Li and H. Tang, "Multimodal Alignment and Fusion: A Survey," *IJCV (International Journal of Computer Vision)*, 2025.
- [6] B. Zheng, Y. Hou, H. Lu, Y. Chen, W. X. Zhao, M. Chen and J.-R. Wen, "Adapting Large Language Models by Integrating Collaborative Semantics for Recommendation," 2024.
- [7] J. LIN, X. DAI and Y. XI, "How Can Recommender Systems Benefit from Large Language Models: A Survey," 2024.
- [8] Z. SUN, K. ZHENG and Z. SI, "Large Language Models Enhanced Collaborative Filtering," 2024.
- [9] B. N. M. Hoang, H. T. H. Vy, T. G. Tiet, V. T. M. Hang, H. L. T. K. Nhung and L. N. H. Nam, "Using Bert Embedding to improve memory-based collaborative filtering recommender systems," 2021.
- [10] Y. Zhang, K. Bao, M. Yan, W. Wang, F. Feng and X. He, "Text-like Encoding of Collaborative Information in Large Language Models for Recommendation," 2024.
- [11] W. Wei, X. Ren, J. Tang, Q. Wang, L. Su, S. Cheng, J. Wang, D. Yin and C. Huang, "LLMRec: Large Language Models with Graph Augmentation for Recommendation," 2024.