

Mục lục

1	Giới thiệu	4
1.1	Bối cảnh và động lực nghiên cứu	4
1.2	Vấn đề đặt ra: khoảng cách ngữ nghĩa giữa tín hiệu cộng tác và LLM	5
1.3	Khoảng trống nghiên cứu	6
1.4	Mục tiêu và đóng góp	7
1.5	Bố cục luận văn	9
2	Các công trình liên quan	10
2.1	Lọc cộng tác truyền thống	10
2.1.1	Phân rã ma trận	11
2.1.2	Lọc cộng tác dựa trên đồ thị	11
2.1.3	Hạn chế của lọc cộng tác thuần túy	11
2.2	Mô hình ngôn ngữ lớn cho hệ thống tư vấn	12
2.2.1	Hai hướng khai thác LLM	12
2.2.2	Rào cản về độ dài ngữ cảnh	13
2.3	Các phương pháp tích hợp CF vào LLM qua không gian véc-tơ	14
2.3.1	Chiếu tuyến tính: CoLLM	14
2.3.2	Học tương phản: SellaRec	14
2.3.3	Mã hóa dạng văn bản: BinLLM	15
2.3.4	Tiêm vào trọng số: CoRA	16
2.3.5	Cầu nối Q-Former: ILM	16
2.3.6	Tổng hợp so sánh	17

2.4	Nền tảng kiến trúc Q-Former	18
2.4.1	BLIP-2: Q-Former cho căn chỉnh ảnh-ngôn ngữ . .	18
2.4.2	InstructBLIP: Conditioning theo chỉ dẫn	19
2.4.3	Kỹ thuật ổn định từ Flamingo	19
2.5	Tổng kết và định vị luận văn	20
3	Phương pháp đề xuất	21
3.1	Tổng quan kiến trúc	21
3.2	Khối Phân rã ma trận	22
3.3	Cầu nối Q-Former: lõi phương pháp	24
3.3.1	Lý do chọn Q-Former thay lớp chiếu tuyến tính . .	24
3.3.2	Kiến trúc Q-Former thích nghi cho gợi ý	25
3.3.3	Đưa tín hiệu CF vào LLM qua soft token	26
3.3.4	Điều kiện hóa truy vấn theo người dùng	26
3.3.5	Mục tiêu bảo toàn thứ tự nội-người-dùng	27
3.4	Các lựa chọn thiết kế	28
3.4.1	Biểu diễn đa token cho tín hiệu CF	28
3.4.2	Backbone LLM đã tinh chỉnh theo chỉ dẫn	28
3.4.3	Tách lớp chiếu người dùng và vật phẩm	29
3.5	Tăng cường Q-Former theo InstructBLIP	30
3.5.1	Cơ chế conditioning theo chỉ dẫn	30
3.5.2	Thích nghi cho bài toán gợi ý	30
3.5.3	Kết quả và vị trí trong luận văn	31
3.6	Quy trình huấn luyện ba giai đoạn	31
3.6.1	Giai đoạn 1: Tiền huấn luyện biểu diễn	31
3.6.2	Giai đoạn 2: Tiền huấn luyện sinh	33
3.6.3	Giai đoạn 3: Tinh chỉnh CTR	33
3.7	Kết chương	34
4	Thực nghiệm và Kết quả	35
4.1	Thiết lập thực nghiệm	35
4.1.1	Tập dữ liệu	35

4.1.2	Phân chia dữ liệu và giao thức đánh giá	36
4.1.3	Các mô hình baseline	36
4.1.4	Độ đo đánh giá	37
4.1.5	Cài đặt mô hình	37
4.2	Kết quả chính	38
4.3	Phân tích nghịch lý AUC/uAUC	40
4.4	Phân tích ablation	41
4.5	Phân tích bổ sung	42
4.5.1	Đo lường khoảng cách ngữ nghĩa	42
4.5.2	Phân tích theo nhóm người dùng (warm/cold) . . .	43
4.6	Thảo luận	44
4.6.1	Đối chiếu với ILM về giao thức đánh giá	44
4.6.2	Điểm mạnh và hạn chế của cầu nối Q-Former . . .	44
4.7	Hạn chế	44
5	Kết luận và Hướng phát triển	46
5.1	Tóm tắt đóng góp	46
5.2	Kết quả đạt được	47
5.3	Hạn chế	48
5.4	Hướng phát triển	48
	Tài liệu tham khảo	50

Chương 1

Giới thiệu

1.1 Bối cảnh và động lực nghiên cứu

Trong thập kỷ vừa qua, hệ thống tư vấn (recommender system) đã trở thành một thành phần cốt lõi trong các nền tảng thương mại điện tử, phát trực tuyến và mạng xã hội. Nhiệm vụ cốt lõi của hệ thống tư vấn là dự đoán mức độ phù hợp giữa người dùng và vật phẩm dựa trên dữ liệu lịch sử tương tác, từ đó đưa ra các gợi ý cá nhân hóa có giá trị thực tiễn cao [1].

Phương pháp lọc cộng tác (collaborative filtering – CF) là nền tảng của phần lớn các hệ thống tư vấn hiện đại. Trong đó, phân rã ma trận (matrix factorization – MF) [2] học ánh xạ người dùng và vật phẩm thành các véc-tơ nhúng ẩn trong không gian đặc trưng thấp chiều, sao cho tích vô hướng giữa hai véc-tơ phản ánh mức độ tương thích. Phân rã ma trận cùng các biến thể như LightGCN [3] – khai thác cấu trúc đồ thị tương tác – đã đạt được hiệu quả đáng kể trên nhiều bộ dữ liệu chuẩn. Tuy vậy, nhóm phương pháp này tồn tại ba hạn chế cố hữu: (i) *ma trận thưa thớt* (data sparsity) – hầu hết các cặp người dùng–vật phẩm chưa có tương tác, khiến không gian huấn luyện cực kỳ thưa; (ii) *vấn đề khởi động nguội* (cold-start) – người dùng mới hoặc vật phẩm mới không có lịch sử tương tác, nên hệ thống không thể biểu diễn nhúng có chất lượng; (iii) *thiếu hiểu biết ngữ nghĩa* – các biểu diễn CF được học hoàn toàn từ tín hiệu

tương tác nhị phân, không nắm được nội dung văn bản mô tả thuộc tính vật phẩm hay sở thích người dùng.

Sự bùng nổ của các mô hình ngôn ngữ lớn (large language model – LLM) trong những năm gần đây đã mở ra một hướng tiếp cận mới để khắc phục những hạn chế trên. LLM được huấn luyện trước trên khối lượng văn bản khổng lồ, tích lũy hiểu biết ngữ nghĩa phong phú về thế giới và khả năng suy luận linh hoạt. Kết hợp LLM với hệ thống tư vấn đã trở thành một hướng nghiên cứu sôi nổi, với hai luồng chính: (1) *LLM-enhanced*: dùng LLM như bộ mã hóa để làm giàu biểu diễn đặc trưng người dùng và vật phẩm; (2) *LLMs as Recommender Systems (LLMs-as-RS)*: đặt bài toán gợi ý trực tiếp như một tác vụ sinh ngôn ngữ, trong đó LLM vừa đóng vai trò hiểu ngữ cảnh vừa đưa ra gợi ý [4]. Hướng tiếp cận LLMs-as-RS đặc biệt hấp dẫn vì khả năng giải quyết cold-start nhờ hiểu biết ngữ nghĩa sẵn có của LLM, và khả năng tận dụng tri thức thế giới để lý giải các gợi ý theo ngôn ngữ tự nhiên.

Luận văn này theo đuổi hướng tiếp cận LLMs-as-RS.

1.2 Vấn đề đặt ra: khoảng cách ngữ nghĩa giữa tín hiệu cộng tác và LLM

Khi đặt bài toán gợi ý như một tác vụ sinh ngôn ngữ, một câu hỏi then chốt xuất hiện: làm thế nào để đưa tín hiệu hành vi lịch sử của người dùng vào LLM một cách hiệu quả? Cách tiếp cận trực tiếp nhất là mã hóa lịch sử tương tác thành văn bản – ví dụ, liệt kê danh sách các phim người dùng đã xem – rồi nối vào chỉ dẫn (prompt) đầu vào của LLM. Tuy nhiên, cách này gặp phải một giới hạn cơ bản: với người dùng có lịch sử phong phú, danh sách vật phẩm nhanh chóng vượt quá độ dài ngữ cảnh (context length) cho phép, làm mất thông tin hoặc tăng chi phí tính toán đáng kể. Đây là trở ngại thực tiễn đã được ghi nhận trong nhiều công trình LLMs-as-RS [5].

Giải pháp tự nhiên là biểu diễn thông tin hành vi dưới dạng *véc-tơ đặc trưng gọn (compact)*: thay vì liệt kê từng vật phẩm, ta dùng nhúng CF – tổng hợp từ toàn bộ lịch sử tương tác – để nén tín hiệu cộng tác thành một véc-tơ dày đặc. Véc-tơ này sau đó được đưa vào LLM như một *soft token*, bổ sung tín hiệu hành vi mà không làm dài ngữ cảnh. Cách tiếp cận này được gọi là *tích hợp CF vào LLM qua không gian véc-tơ*.

CoLLM [5] là công trình tiên phong theo hướng này: sử dụng một lớp chiếu tuyến tính (MLP một lớp) để ánh xạ véc-tơ CF từ không gian MF vào không gian nhúng của LLM, tạo thành các soft token được chèn vào chỉ dẫn. Mặc dù đơn giản và hiệu quả như một baseline, lớp chiếu tuyến tính có hạn chế cố hữu: nó không nắm được các quan hệ phi tuyến phức tạp giữa không gian CF và không gian ngữ nghĩa của LLM, và không có cơ chế *trích chọn có kiểm soát* – toàn bộ véc-tơ CF được chiếu một lần qua một phép biến đổi duy nhất mà không phân biệt các thành phần nào thực sự quan trọng với ngữ cảnh hiện tại.

Khoảng cách ngữ nghĩa giữa không gian biểu diễn CF (học từ tín hiệu tương tác nhị phân) và không gian ngữ nghĩa của LLM (học từ ngôn ngữ tự nhiên) là một thách thức căn bản. Hai không gian này có nguồn gốc huấn luyện hoàn toàn khác nhau, nên một phép chiếu đơn giản khó có thể *căn chỉnh (alignment)* hiệu quả. Điều này đặt ra câu hỏi: liệu có cơ chế nối cầu nào mạnh hơn lớp chiếu tuyến tính, có khả năng căn chỉnh tín hiệu CF vào không gian ngữ nghĩa LLM một cách có kiểm soát và linh hoạt hơn?

1.3 Khoảng trống nghiên cứu

Kiến trúc Q-Former, được giới thiệu trong BLIP-2 [6] và phát triển thêm trong InstructBLIP [7], là một cầu nối đa phương thức được thiết kế cho bài toán căn chỉnh giữa thông tin hình ảnh và không gian ngôn ngữ. Q-Former sử dụng một tập nhỏ các véc-tơ truy vấn *học được* (learned query tokens) cùng cơ chế cross-attention để trích xuất có chọn lọc các đặc

trung từ tín hiệu đầu vào, thay vì chiếu toàn bộ tín hiệu qua một phép biến đổi đơn giản. Cơ chế này về nguyên tắc thích hợp hơn cho bài toán căn chỉnh không gian CF vào không gian ngữ nghĩa LLM, vì nó có khả năng học cách tổng hợp và chọn lọc thông tin từ tín hiệu cộng tác tùy thuộc vào ngữ cảnh tác vụ.

Công trình ILM [8] đã thử nghiệm ý tưởng dùng Q-Former như cầu nối tích hợp thông tin CF vào LLM cho bài toán gợi ý. Tuy nhiên, hướng nghiên cứu này còn tồn tại hai khoảng trống quan trọng chưa được giải quyết:

Thứ nhất, ILM chưa đánh giá dưới giao thức dự đoán tỉ lệ nhấp (click-through rate – CTR) với các độ đo AUC và uAUC như CoLLM và các công trình cùng dòng, nên không thể so sánh trực tiếp hiệu quả của cầu nối Q-Former với lớp chiếu tuyến tính trên cùng điều kiện thực nghiệm.

Thứ hai, cầu nối Q-Former trong ILM chưa được tăng cường bằng các kỹ thuật hiện đại như: (i) conditioning theo chỉ dẫn (InstructBLIP [7]) để truy vấn phụ thuộc tác vụ; (ii) biểu diễn đa token cho tín hiệu CF; (iii) các lựa chọn thiết kế như tách lớp chiếu người dùng và vật phẩm.

Luận văn này lấp hai khoảng trống nêu trên:

Mặc dù Q-Former đã được dùng để nối thông tin cộng tác với LLM (ILM), hướng này vẫn chưa được đánh giá dưới giao thức CTR với AUC và uAUC như dòng CoLLM, và chưa được khảo sát khi tăng cường bằng các kỹ thuật hiện đại như InstructBLIP, biểu diễn đa token. Luận văn này lấp khoảng trống đó: xây dựng và tăng cường một cầu nối Q-Former để tích hợp thông tin cộng tác vào LLM, đánh giá có hệ thống dưới giao thức AUC/uAUC và đối chiếu trực tiếp với baseline CoLLM.

1.4 Mục tiêu và đóng góp

Luận văn hướng đến hai mục tiêu chính:

Mục tiêu 1: Thiết kế và hiện thực một mô hình tích hợp tín hiệu CF vào LLM thông qua cầu nối Q-Former, thay thế lớp chiếu tuyến tính của CoLLM. Cụ thể, luận văn xây dựng kiến trúc SigLLM gồm ba khối nối tiếp – phân rã ma trận đông cứng, cầu nối Q-Former, và LLM đông cứng (Vicuna-7B-v1.5) với LoRA – trong đó cầu nối Q-Former đóng vai trò căn chỉnh tín hiệu CF vào không gian ngữ nghĩa của LLM. Trên nền cầu nối soft token, luận văn bổ sung hai đòn bẩy huấn luyện: điều kiện hóa truy vấn theo người dùng (`user_conditioned`, nhằm cải thiện AUC) và mục tiêu bảo toàn thứ tự nội-người-dùng (`align_rank_loss`, nhằm cải thiện uAUC). Song song, luận văn khảo sát các lựa chọn thiết kế bổ sung (biểu diễn đa token, backbone đã tinh chỉnh chỉ dẫn, tách lớp chiếu người dùng và vật phẩm) và InstructBLIP như hướng tăng cường.

Mục tiêu 2: Đánh giá có hệ thống cầu nối Q-Former dưới giao thức CTR với hai độ đo AUC và uAUC trên hai tập dữ liệu MovieLens-1M và Amazon-Book – điều mà ILM chưa thực hiện – đối chiếu trực tiếp với baseline CoLLM, BinLLM và CoRA.

Từ hai mục tiêu trên, luận văn đóng góp:

- Cầu nối Q-Former được thích nghi và tăng cường cho bài toán gợi ý:** Luận văn thích nghi kiến trúc Q-Former từ miền ảnh-ngôn ngữ sang miền gợi ý, trong đó tín hiệu CF thay thế đặc trưng ảnh như đầu vào của cross-attention, và đưa vào LLM qua đường soft token. Trên nền đó, luận văn bổ sung hai đòn bẩy huấn luyện – điều kiện hóa truy vấn theo người dùng và mục tiêu bảo toàn thứ tự nội-người-dùng – cải thiện lần lượt AUC và uAUC, cùng các lựa chọn thiết kế bổ sung (biểu diễn đa token, backbone đã tinh chỉnh chỉ dẫn, tách projector) và khảo sát InstructBLIP.
- Đánh giá có hệ thống dưới giao thức AUC/uAUC:** Luận văn đánh giá cầu nối Q-Former dưới giao thức CTR với AUC và uAUC – cùng giao thức với CoLLM, cho phép so sánh trực tiếp – trên hai tập dữ liệu MovieLens-1M và Amazon-Book. Đây là đánh giá mà các

công trình Q-Former trước (ILM) chưa thực hiện, đồng thời cung cấp phân tích ablation về đóng góp của từng đòn bẩy và phân rã warm/cold làm rõ trần uAUC.

Về quan điểm trình bày kết quả: Luận văn tuân thủ nguyên tắc thực nghiệm trung thực: báo cáo số liệu thực tế, phân tích nguyên nhân khi kết quả không như kỳ vọng, và không phóng đại kết luận vượt quá bằng chứng. Các kết quả chính được trình bày kèm đầy đủ lưu ý về giới hạn thực nghiệm (một seed, một số ablation thành phần còn để ngỏ).

1.5 Bố cục luận văn

Phần còn lại của luận văn được tổ chức như sau.

Chương 2 — Các công trình liên quan phân tích theo bốn nhánh: lọc cộng tác truyền thống và hạn chế của nó; LLM trong hệ thống tư vấn và thách thức về độ dài ngữ cảnh; các phương pháp tích hợp CF vào LLM qua không gian véc-tơ (MLP, tương phản, tiêu trọng số, Q-Former); và nền tảng kiến trúc Q-Former từ BLIP-2 và InstructBLIP. Chương này kết luận rằng cầu nối Q-Former đáng được nghiên cứu và tăng cường sâu hơn.

Chương 3 — Phương pháp đề xuất trình bày kiến trúc SigLLM với ba khối nối tiếp và lý do chọn Q-Former thay lớp chiếu tuyến tính của CoLLM. Chương này mô tả cơ chế Q-Former được thích nghi, các lựa chọn thiết kế, InstructBLIP như hướng tăng cường chính, và quy trình huấn luyện ba giai đoạn.

Chương 4 — Thực nghiệm và Kết quả trình bày thiết lập thực nghiệm trên hai tập dữ liệu MovieLens-1M và Amazon-Book, kết quả so sánh với CoLLM, BinLLM và CoRA, phân tích ablation hai đòn bẩy huấn luyện, phân rã warm/cold, và thảo luận hạn chế.

Chương 5 — Kết luận và Hướng phát triển tóm tắt đóng góp, chỉ ra các hạn chế còn tồn tại và đề xuất hướng nghiên cứu tiếp theo.

Chương 2

Các công trình liên quan

Chương này xây dựng nền tảng lý thuyết cho luận văn qua bốn nhánh phân tích nối tiếp nhau. *Nhánh đầu tiên* (Mục 2.1) trình bày lọc cộng tác truyền thống và các hạn chế cố hữu của nó, dẫn đến nhu cầu kết hợp LLM. *Nhánh thứ hai* (Mục 2.2) phân tích hai hướng khai thác LLM cho hệ thống tư vấn và chỉ ra rào cản về độ dài ngữ cảnh – yếu tố buộc tín hiệu CF phải được biểu diễn dưới dạng véc-tơ gọn (compact) thay vì văn bản. *Nhánh thứ ba* (Mục 2.3) phân tích năm cách tích hợp CF vào LLM qua không gian véc-tơ, làm nổi bật điểm mạnh và hạn chế của từng hướng. *Nhánh thứ tư* (Mục 2.4) trình bày nền tảng kiến trúc Q-Former từ BLIP-2 và InstructBLIP – cơ sở lý thuyết cho phương pháp đề xuất ở Chương 3.

2.1 Lọc cộng tác truyền thống

Lọc cộng tác (collaborative filtering – CF) khai thác hành vi tập thể của người dùng: những người dùng có hành vi tương tự trong quá khứ có xu hướng thích những vật phẩm giống nhau trong tương lai. Phương pháp này không cần thông tin nội dung vật phẩm, chỉ dựa trên ma trận tương tác người dùng–vật phẩm [1].

2.1.1 Phân rã ma trận

Phân rã ma trận (matrix factorization – MF) [2] là phương pháp CF nền tảng, đạt được thành công lớn trong cuộc thi Netflix Prize. MF học ánh xạ mỗi người dùng u và vật phẩm i thành các véc-tơ nhúng ẩn $e_u, e_i \in \mathbb{R}^d$ sao cho tích vô hướng $e_u^\top e_i$ xấp xỉ mức độ tương thích. Hàm mục tiêu phổ biến là hồi quy bình phương tối thiểu (RMSE) trên các đánh giá quan sát được, hoặc học xếp hạng cặp theo mục tiêu BPR [9].

Điểm mạnh của MF là tính đơn giản, khả năng mở rộng và hiệu quả thực nghiệm đã được kiểm chứng. Tuy nhiên, MF học biểu diễn tuyến tính qua tích vô hướng, hạn chế khả năng mô hình hóa các quan hệ phi tuyến phức tạp. Loại cộng tác thần kinh (neural collaborative filtering – NCF) [10] mở rộng MF bằng cách thay tích vô hướng bởi mạng nơ-ron nhiều lớp, cho phép học các tương tác người dùng–vật phẩm phi tuyến.

2.1.2 Loại cộng tác dựa trên đồ thị

Tương tác người dùng–vật phẩm có thể được biểu diễn tự nhiên như một đồ thị hai phía (bipartite graph). LightGCN [3] khai thác cấu trúc đồ thị này bằng mạng tích chập đồ thị (graph convolutional network – GCN): nhúng của mỗi nút được cập nhật bằng cách tổng hợp tuyến tính nhúng của các nút láng giềng, qua nhiều bước lan truyền. LightGCN đạt hiệu quả cao hơn NCF trên nhiều bộ dữ liệu chuẩn nhờ khai thác được thông tin cấu trúc bậc cao của đồ thị tương tác.

2.1.3 Hạn chế của loại cộng tác thuần túy

Mặc dù đạt hiệu quả tốt, các phương pháp CF truyền thống tồn tại ba hạn chế cơ bản:

Vấn đề thừa thớt dữ liệu. Ma trận tương tác người dùng–vật phẩm trong thực tế cực kỳ thưa: tỉ lệ quan sát trên tổng số cặp thường dưới 1%. Dữ liệu thừa dẫn đến ước lượng nhúng kém chất lượng cho người dùng và

vật phẩm ít tương tác.

Vấn đề khởi động nguội. Người dùng mới và vật phẩm mới không có lịch sử tương tác, nên các phương pháp CF không thể xây dựng biểu diễn nhúng cho họ. Đây là hạn chế nghiêm trọng trong hệ thống thực tế, nơi người dùng mới và vật phẩm mới liên tục xuất hiện.

Thiếu hiểu biết ngữ nghĩa. Biểu diễn CF học thuần từ tín hiệu tương tác nhị phân, không nắm được nội dung văn bản mô tả vật phẩm hay sở thích người dùng. Điều này hạn chế khả năng gợi ý cho vật phẩm mới (zero interaction) và khả năng giải thích gợi ý bằng ngôn ngữ tự nhiên.

Những hạn chế này thúc đẩy hướng kết hợp LLM – có khả năng hiểu ngữ nghĩa văn bản phong phú – vào hệ thống tư vấn.

2.2 Mô hình ngôn ngữ lớn cho hệ thống tư vấn

LLM được huấn luyện trước trên khối lượng văn bản khổng lồ, thu được khả năng hiểu ngữ nghĩa sâu sắc và suy luận linh hoạt. Khai thác LLM cho hệ thống tư vấn đã trở thành một trong những hướng nghiên cứu tích cực nhất trong những năm gần đây [4].

2.2.1 Hai hướng khai thác LLM

Có thể phân loại các phương pháp kết hợp LLM và hệ thống tư vấn thành hai hướng chính:

LLM-enhanced: dùng LLM như bộ mã hóa để tạo biểu diễn ngữ nghĩa cho người dùng và vật phẩm, sau đó tích hợp vào pipeline gợi ý truyền thống. Trong hướng này, LLM chủ yếu đóng vai trò trích xuất đặc trưng ngôn ngữ; quyết định gợi ý vẫn do các mô hình CF hoặc xếp hạng đảm nhận.

LLMs-as-RS: đặt bài toán gợi ý trực tiếp như một tác vụ sinh ngôn ngữ, trong đó LLM vừa hiểu ngữ cảnh vừa đưa ra gợi ý. P5 [11] là một

trong những công trình đầu tiên theo hướng này, đặt nhiều bài toán gợi ý (xếp hạng, dự đoán đánh giá, giải thích) thành các cặp câu hỏi–trả lời và huấn luyện một mô hình T5 thống nhất. BIGRec [12] tinh chỉnh LLM để gợi ý bằng cách ánh xạ đầu ra ngôn ngữ về không gian vật phẩm qua cơ chế căn chỉnh.

Hướng LLMs-as-RS đặc biệt hấp dẫn vì khả năng tận dụng tri thức thế giới sẵn có trong LLM để giải quyết cold-start – người dùng và vật phẩm mới có thể được mô tả bằng văn bản, và LLM có thể suy luận về sở thích ngay cả khi chưa có lịch sử tương tác. Luận văn này theo đuổi hướng LLMs-as-RS.

2.2.2 Rào cản về độ dài ngữ cảnh

Khi đặt bài toán gợi ý như tác vụ ngôn ngữ, cách tự nhiên nhất để cung cấp thông tin hành vi là mã hóa lịch sử tương tác thành văn bản – chẳng hạn, liệt kê tên các phim người dùng đã xem. Tuy nhiên, người dùng trong thực tế có thể có hàng trăm đến hàng nghìn tương tác. Với mỗi tên phim chiếm vài token, lịch sử đầy đủ nhanh chóng vượt quá giới hạn ngữ cảnh của LLM (thường 2K–8K token với các mô hình phổ biến), hoặc tiêu tốn lượng tính toán rất lớn nếu dùng mô hình ngữ cảnh dài.

Đây là rào cản cơ bản đã được nhận diện trong CoLLM [5]: dù LLM có khả năng hiểu ngữ nghĩa, ta không thể đơn giản đưa toàn bộ lịch sử tương tác vào chỉ dẫn dưới dạng văn bản. Giải pháp là biểu diễn tín hiệu hành vi dưới dạng *véc-tơ CF gọn* – tổng hợp từ toàn bộ lịch sử – và đưa véc-tơ này vào LLM như soft token. Rào cản này đặt ra vấn đề trung tâm: làm thế nào để *căn chỉnh* véc-tơ CF vào không gian ngữ nghĩa LLM một cách hiệu quả?

2.3 Các phương pháp tích hợp CF vào LLM qua không gian véc-tơ

Nhiều công trình đã đề xuất các cơ chế khác nhau để đưa véc-tơ CF vào LLM. Mục này phân tích năm hướng chính và điểm phản biện của từng hướng.

2.3.1 Chiều tuyến tính: CoLLM

CoLLM [5] là baseline nền tảng của luận văn này. CoLLM dùng một lớp chiều tuyến tính (lớp MLP một lớp) để ánh xạ véc-tơ CF từ không gian MF sang không gian nhúng của LLM, tạo thành soft token được chèn vào chỉ dẫn. LLM (Llama-2 [13]) sau đó dự đoán CTR dưới dạng trả lời “Yes” hoặc “No”. Quy trình huấn luyện của CoLLM gồm hai bước: bước đầu tiên huấn luyện LoRA cơ sở chỉ với văn bản (không CF), bước thứ hai huấn luyện mô hình đầy đủ với soft token CF được bơm vào.

Điểm mạnh của CoLLM là sự đơn giản và hiệu quả như một baseline mạnh. Tuy nhiên, lớp chiều tuyến tính có hai hạn chế cơ bản: (i) phép biến đổi tuyến tính không thể nắm được các quan hệ phi tuyến phức tạp giữa không gian CF và không gian ngữ nghĩa LLM; và (ii) không có cơ chế trích chọn có kiểm soát – toàn bộ véc-tơ CF được ánh xạ qua một phép biến đổi duy nhất, không phân biệt thành phần nào quan trọng với ngữ cảnh hiện tại.

2.3.2 Học tương phản: SellaRec

SellaRec [14] căn chỉnh biểu diễn CF và biểu diễn ngôn ngữ thông qua học tương phản (contrastive learning) với mục tiêu InfoNCE: kéo gần biểu diễn của cùng vật phẩm trong không gian CF và không gian ngôn ngữ, đồng thời đẩy xa các vật phẩm khác nhau. Cách tiếp cận này cung cấp một tín hiệu huấn luyện toàn cục mạnh hơn so với chiếu trực tiếp.

Đáng chú ý, SellaRec đã được đánh giá dưới giao thức CTR với AUC và uAUC trên MovieLens-1M – cùng độ đo và tập dữ liệu với luận văn này. Điều này cho thấy khoảng trống đánh giá mà luận văn nhắm đến không phải là khoảng trống của *toàn bộ* dòng CF-LLM, mà đặc thù cho *cầu nối Q-Former*: SellaRec lấp khoảng trống bằng cơ chế học tương phản, trong khi hướng Q-Former (ILM) vẫn chưa được kiểm chứng dưới giao thức này. Hai cơ chế khác nhau về bản chất – học tương phản căn chỉnh hai không gian qua hàm mất mát toàn cục, còn Q-Former trích chọn và tổng hợp tín hiệu CF qua tập truy vấn học được – nên SigLLM và SellaRec bổ sung cho nhau hơn là trùng lặp.

Tuy nhiên, SellaRec dùng Qwen2-7B-Base [15] làm backbone LLM. Luận văn này dùng Vicuna-7B-v1.5 [16] – một mô hình tinh chỉnh chỉ dẫn trên nền Llama-2, cùng họ với backbone Llama-2 của CoLLM – để so sánh trung thực với baseline chính. So sánh số liệu giữa SellaRec và SigLLM có thể thực hiện được nhưng cần lưu ý: sự khác biệt backbone (Qwen2-Base so với Vicuna/Llama-2) và giao thức phân chia dữ liệu có thể ảnh hưởng đến kết quả quan sát được.

2.3.3 Mã hóa dạng văn bản: BinLLM

BinLLM [17] đề xuất mã hóa véc-tơ CF thành chuỗi ký tự nhị phân, cho phép đưa tín hiệu CF vào LLM dưới dạng văn bản thông thường mà không cần soft token. Cách tiếp cận này có ưu điểm về tính đơn giản trong triển khai và không yêu cầu thay đổi kiến trúc LLM.

Hạn chế của BinLLM nằm ở bước rời rạc hóa: mã hóa nhị phân không thể lưu giữ đầy đủ thông tin từ véc-tơ CF liên tục, dẫn đến mất mát thông tin không thể khôi phục. Ngoài ra, chuỗi nhị phân không mang ý nghĩa ngữ nghĩa trong từ vựng LLM, nên LLM phải học cách diễn giải cú pháp nhị phân – một bài toán học bổ sung không tầm thường.

2.3.4 Tiêm vào trọng số: CoRA

CoRA [18] đề xuất một cơ chế khác biệt: thay vì đưa CF vào không gian đầu vào của LLM như soft token, CoRA biến đổi véc-tơ CF thành một lượng thay đổi trọng số hạng thấp, phụ thuộc vào mẫu (sample-specific), cộng trực tiếp vào các lớp attention của LLM. Theo đó, mỗi mẫu (cặp người dùng–vật phẩm) có một tập trọng số điều chỉnh riêng, cho phép LLM cá nhân hóa tính toán ở mức độ sâu hơn.

Tuy nhiên, CoRA bỏ hoàn toàn cơ chế soft token – CF chỉ được đưa vào qua đường trọng số. Điều này có nghĩa là CoRA không tận dụng được khả năng căn chỉnh ngữ nghĩa mà soft token trong không gian đầu vào cung cấp. CoRA vì thế đại diện cho một *hướng thiết kế khác* với luận văn: can thiệp vào trọng số attention của LLM thay vì căn chỉnh tín hiệu CF trong không gian đầu vào.

SigLLM đi theo hướng soft token: tín hiệu CF được căn chỉnh qua cầu nối Q-Former rồi chèn vào chỉ dẫn dưới dạng soft token, giữ LLM hoàn toàn đông cứng và không sinh trọng số theo từng mẫu (chi tiết tại Chương 3). Luận văn không hiện thực cơ chế tiêm trọng số của CoRA; thay vào đó, *mô hình* CoRA nguyên bản được dùng như một baseline so sánh trong thực nghiệm trên Amazon-Book (Chương 4), đặt cạnh CoLLM và BinLLM để định vị SigLLM trong cùng dòng phương pháp.

2.3.5 Cầu nối Q-Former: ILM

ILM [8] là công trình đầu tiên áp dụng Q-Former như cầu nối tích hợp tín hiệu CF vào LLM cho bài toán gợi ý. Q-Former sử dụng một tập véc-tơ truy vấn học được cùng cơ chế cross-attention để trích xuất thông tin từ véc-tơ CF, thay vì chiếu trực tiếp. Cơ chế này có khả năng học cách lọc và tổng hợp tín hiệu CF theo cách phù hợp với không gian ngữ nghĩa LLM.

Tuy nhiên, ILM chưa đánh giá dưới giao thức CTR với AUC và uAUC như CoLLM và các công trình cùng dòng, nên không thể so sánh trực tiếp hiệu quả của cầu nối Q-Former với lớp chiếu tuyến tính. Ngoài ra, cầu nối

Q-Former trong ILM chưa được tăng cường bằng các kỹ thuật conditioning theo chỉ dẫn như InstructBLIP.

2.3.6 Tổng hợp so sánh

Bảng 2.1 tổng hợp so sánh các phương pháp tích hợp CF vào LLM được phân tích ở trên.

Bảng 2.1: So sánh các phương pháp tích hợp CF vào LLM qua không gian véc-tơ

Phương pháp	Cơ chế tích hợp	Điểm mạnh	Hạn chế
CoLLM [5]	MLP tuyến tính một lớp	Đơn giản; baseline mạnh	Tuyến tính; không có trích chọn có kiểm soát
SellaRec [14]	Học tương phản	Tín hiệu huấn luyện toàn cục	Backbone khác (Qwen); so sánh hạn chế
BinLLM [17]	Mã hóa nhị phân	Đơn giản; không cần soft token	Mất mát thông tin khi rời rạc hóa
CoRA [18]	Tiêm vào trọng số	Cá nhân hóa sâu trong LLM	Bỏ soft token; không tận dụng căn chỉnh đầu vào
ILM [8]	Q-Former (cross-attention)	Trích chọn có kiểm soát	Chưa báo AUC/uAUC; chưa tăng cường InstructBLIP

Phân tích trên dẫn đến kết luận: câu nói Q-Former hứa hẹn nhất về cơ chế căn chỉnh – trích chọn có kiểm soát qua cross-attention, không phụ thuộc vào giả thiết tuyến tính – nhưng còn thiếu kiểm chứng dưới giao

thức AUC/uAUC và chưa được tăng cường bằng các kỹ thuật hiện đại. Đây là khoảng trống mà luận văn này nhắm đến.

2.4 Nền tảng kiến trúc Q-Former

2.4.1 BLIP-2: Q-Former cho căn chỉnh ảnh–ngôn ngữ

BLIP-2 [6] giới thiệu Q-Former (Querying Transformer) như một cầu nối nhẹ (lightweight bridge) giữa bộ mã hóa ảnh đông cứng và LLM đông cứng. Q-Former giải quyết bài toán: làm thế nào để trích xuất thông tin từ đặc trưng ảnh (không gian liên tục, chiều cao) và chuyển thành biểu diễn mà LLM có thể xử lý, mà không cần huấn luyện lại hai khối lớn.

Kiến trúc Q-Former gồm một tập nhỏ véc-tơ truy vấn học được $\mathbf{Q} \in \mathbb{R}^{N_q \times d}$ (thường $N_q = 32$) và một bộ transformer. Trong mỗi lớp của Q-Former, các truy vấn đi qua hai loại attention:

1. *Self-attention* giữa các truy vấn với nhau (và với token ngôn ngữ nếu có): cho phép các truy vấn trao đổi thông tin và điều phối lẫn nhau.
2. *Cross-attention* từ các truy vấn đến đặc trưng đầu vào (ảnh hoặc CF): cho phép mỗi truy vấn thu nhận thông tin từ nguồn đầu vào một cách có chọn lọc.

Đầu ra là một khối truy vấn $\mathbf{Z} \in \mathbb{R}^{N_q \times d}$ – một tập hợp gọn các véc-tơ đã được “cất giữ” thông tin từ đầu vào theo cách tối ưu cho ngữ cảnh hiện tại. $\mathbf{Z}$ sau đó được chiếu vào không gian nhúng của LLM và nối với prompt văn bản.

BLIP-2 huấn luyện Q-Former qua hai giai đoạn: (1) tiền huấn luyện biểu diễn với các mục tiêu tương phản ảnh–văn bản (ITC), so khớp ảnh–văn bản (ITM) và sinh văn bản có điều kiện (ITG); (2) tiền huấn luyện sinh ngôn ngữ để Q-Former học cách tạo biểu diễn mà LLM có thể hiểu. Thiết kế này cho phép BLIP-2 đạt hiệu quả cao trên các tác vụ ảnh–ngôn

ngữ mà chỉ cần huấn luyện Q-Former nhẹ, giữ nguyên bộ mã hóa ảnh và LLM.

Ý nghĩa cho bài toán gợi ý: Q-Former có thể được thích nghi để thay thế bộ mã hóa ảnh bằng bộ mã hóa CF (phân rã ma trận), và căn chỉnh CF vào không gian LLM thông qua cơ chế cross-attention có kiểm soát.

2.4.2 InstructBLIP: Conditioning theo chỉ dẫn

InstructBLIP [7] mở rộng BLIP-2 bằng cách làm cho Q-Former phụ thuộc vào chỉ dẫn (instruction): thay vì dùng tập truy vấn cố định, các truy vấn của Q-Former tham gia vào self-attention cùng với token chỉ dẫn văn bản. Kết quả là đầu ra $\mathbf{Z}$ của Q-Former phụ thuộc vào nội dung chỉ dẫn – cùng một ảnh đầu vào nhưng với chỉ dẫn khác nhau, Q-Former trích xuất các đặc trưng ảnh khác nhau.

Cải tiến này cho phép InstructBLIP đạt hiệu quả trên nhiều tác vụ ảnh-ngôn ngữ đa dạng mà không cần tinh chỉnh riêng từng tác vụ. Kết quả là InstructBLIP vượt trội đáng kể so với BLIP-2 trên nhiều benchmark zero-shot.

Ý nghĩa cho bài toán gợi ý: Q-Former với conditioning chỉ dẫn cho phép truy vấn phụ thuộc tác vụ – ví dụ, cùng tín hiệu CF nhưng với chỉ dẫn khác nhau (“người dùng có thích phim hành động?” vs. “phim này có phù hợp với sở thích của người dùng không?”), Q-Former có thể trích xuất các khía cạnh khác nhau của tín hiệu CF. Đây là hướng tăng cường chính mà luận văn khảo sát và sẽ được trình bày chi tiết ở Mục 3.5.

2.4.3 Kỹ thuật ổn định từ Flamingo

Khi gán một đường truyền mới lên một LLM đông cứng, việc kiểm soát ổn định là quan trọng. Flamingo [19] – một mô hình đa phương thức quy mô lớn – đề xuất kỹ thuật cổng tanh khởi tạo không (zero-initialized tanh gate): mỗi đường truyền mới có một tham số cổng g khởi tạo bằng 0, sao cho ban đầu $\Delta = \tanh(0) \cdot (\dots) = 0$, tức LLM không bị ảnh hưởng bởi tín

hiệu mới ngay từ đầu. Trong quá trình huấn luyện, công học dần để tiếp nhận tín hiệu mới, và hàm tanh giới hạn biên độ thay đổi trong khoảng $(-1, 1)$, ngăn mô hình phân kỳ. SigLLM kế thừa *nguyên tắc khởi tạo bằng không* này: cả phần dịch truy vấn theo người dùng lần đầu ra phụ của mục tiêu bảo toàn thứ tự đều được khởi tạo bằng không, nên mỗi cơ chế mới bắt đầu ở trạng thái trung tính (no-op) và chỉ lớn dần nếu tín hiệu huấn luyện thưởng cho nó (chi tiết tại Mục 3.3).

2.5 Tổng kết và định vị luận văn

Nhìn lại bốn nhánh phân tích, có thể rút ra câu kết luận sau:

Trong các phương pháp tích hợp tín hiệu CF vào LLM qua không gian véc-tơ, Q-Former nổi lên như cầu nối hứa hẹn nhất: cơ chế cross-attention với tập truy vấn học được cho phép trích chọn đặc trưng CF có kiểm soát, thay vì nén thô qua lớp chiếu tuyến tính của CoLLM. Tuy nhiên, hướng này chưa được kiểm chứng dưới giao thức AUC/uAUC của dòng CoLLM, và vẫn còn nhiều hướng tăng cường chưa được khai thác – đặc biệt là conditioning theo chỉ dẫn theo InstructBLIP – nên xứng đáng được nghiên cứu sâu hơn.

Chương tiếp theo trình bày kiến trúc SigLLM – hiện thực hóa và tăng cường cầu nối Q-Former cho bài toán gợi ý – cùng lý do thiết kế và quy trình huấn luyện.

Chương 3

Phương pháp đề xuất

Chương này trình bày kiến trúc SigLLM – mô hình được đề xuất trong luận văn – cùng lý do thiết kế và quy trình huấn luyện. Xuất phát từ hạn chế đã phân tích ở Chương 2, trục lập luận của chương là: lớp chiếu tuyến tính của CoLLM không đủ để căn chỉnh hiệu quả tín hiệu CF vào không gian ngữ nghĩa LLM, và cầu nối Q-Former với cross-attention có kiểm soát là lựa chọn thay thế tự nhiên hơn.

Mục 3.1 mô tả kiến trúc tổng thể ba khối. Mục 3.2 trình bày khối phân rã ma trận. Mục 3.3 là lõi kỹ thuật: cầu nối Q-Former và lý do chọn nó thay MLP. Mục 3.4 trình bày các lựa chọn thiết kế bổ sung. Mục 3.5 khảo sát InstructBLIP như hướng tăng cường chính. Mục 3.6 trình bày quy trình huấn luyện ba giai đoạn.

3.1 Tổng quan kiến trúc

Bài toán. Luận văn giải quyết bài toán dự đoán tỉ lệ nhấp (click-through rate – CTR). Cho người dùng u , lịch sử tương tác của người dùng, và một phim mục tiêu i , mô hình đưa ra dự đoán nhị phân về khả năng người dùng thích phim đó – biểu diễn dưới dạng câu trả lời “Yes” hoặc “No”. Đây là bài toán phân loại nhị phân, được đánh giá bằng AUC và uAUC (chi tiết tại Mục 4.1).

Kiến trúc tổng quát. SigLLM gồm ba khối nối tiếp, minh họa ở Hình 3.1:


1. **Khối Phân rã ma trận (MF)** – cung cấp tín hiệu lọc cộng tác dưới dạng véc-tơ nhúng cho người dùng và vật phẩm.
2. **Cầu nối Q-Former** – nén và căn chỉnh véc-tơ CF vào không gian ngữ nghĩa của LLM thông qua cross-attention với các véc-tơ truy vấn học được.
3. **Mô hình ngôn ngữ lớn (LLM)** – suy luận và sinh câu trả lời “Yes/No”.

Đặc điểm thiết kế then chốt: Phần lớn tham số của SigLLM được giữ đông cứng (frozen) trong quá trình huấn luyện. Cụ thể, cả MF lẫn LLM đều không được cập nhật; chỉ Q-Former, các lớp chiếu và bộ chuyển thể LoRA [20] được huấn luyện. Tín hiệu CF được đưa vào LLM qua một đường duy nhất – soft token trong không gian đầu vào – thay vì can thiệp vào trọng số của LLM. Thiết kế này bảo toàn tri thức ngôn ngữ sẵn có của LLM, giảm chi phí huấn luyện, và cho phép phân tích rõ ràng đóng góp của cầu nối căn chỉnh.

3.2 Khối Phân rã ma trận

Khối MF đóng vai trò nguồn tín hiệu lọc cộng tác. Từ ma trận tương tác người dùng–vật phẩm, MF học ánh xạ mỗi người dùng u và vật phẩm i thành các véc-tơ nhúng ẩn $e_u, e_i \in \mathbb{R}^d$ sao cho tích vô hướng $e_u^\top e_i$ phản ánh mức độ tương thích. MF được huấn luyện theo mục tiêu xếp hạng cặp BPR [9], sau đó được đông cứng.

Ba loại tín hiệu CF được trích xuất để đưa vào cầu nối: (i) nhúng người dùng e_u ; (ii) nhúng phim mục tiêu e_i ; (iii) nhúng các phim trong lịch sử tương tác của người dùng $\{e_{i'} : i' \in \mathcal{H}_u\}$.



Hình 3.1: Kiến trúc tổng quan của SigLLM. Khối MF đông cứng cung cấp tín hiệu lọc cộng tác; cầu nối Q-Former căn chỉnh tín hiệu này thành các soft token được chèn vào chỉ dẫn; LLM đông cứng thực hiện suy luận. Chỉ Q-Former, các lớp chiếu và bộ chuyển thể LoRA được huấn luyện.

Việc huấn luyện MF tách rời khỏi các khối còn lại là một lựa chọn thiết kế nhằm cô lập chất lượng tín hiệu CF khỏi quá trình tối ưu hóa LLM, tạo điều kiện phân tích rõ ràng nút thắt của hệ thống. Trong phạm vi luận văn, MF được huấn luyện trên phần tập huấn luyện của MovieLens-1M (chi tiết tại Mục 4.1).

3.3 Cầu nối Q-Former: lỗi phương pháp

3.3.1 Lý do chọn Q-Former thay lớp chiếu tuyến tính

Lớp chiếu tuyến tính của CoLLM [5] ánh xạ $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d_{\text{LLM}}}$ qua một ma trận trọng số duy nhất. Thiết kế này có hai hạn chế:

Hạn chế 1: Giả thiết tuyến tính. Phép chiếu tuyến tính giả định rằng không gian CF và không gian ngữ nghĩa LLM liên kết qua một ánh xạ affine. Tuy nhiên, hai không gian này có nguồn gốc huấn luyện hoàn toàn khác nhau – một từ tín hiệu tương tác nhị phân, một từ ngôn ngữ tự nhiên – và quan hệ giữa chúng nhiều khả năng phi tuyến và phức tạp.

Hạn chế 2: Không có trích chọn có kiểm soát. Lớp chiếu ánh xạ toàn bộ véc-tơ CF qua một phép biến đổi duy nhất, không phân biệt thành phần nào quan trọng với ngữ cảnh hiện tại. Trong khi đó, bài toán CTR đòi hỏi tích hợp thông tin từ nhiều nguồn (nhúng người dùng, nhúng phim mục tiêu, nhúng lịch sử) một cách linh hoạt theo từng mẫu.

Q-Former giải quyết cả hai hạn chế trên, nhưng nguồn gốc của lợi thế cần được xác định chính xác. Khác với lớp chiếu tuyến tính dùng chung một ma trận cho mọi mẫu, cross-attention trong Q-Former thực hiện tổng hợp *phụ thuộc đầu vào* (input-dependent): trọng số tổng hợp các véc-tơ CF thay đổi theo từng mẫu, vượt qua giả thiết ánh xạ affine cố định. Tuy nhiên, lợi thế chính *không* nằm ở khả năng nén của cross-attention – vì đầu vào CF chỉ gồm vài véc-tơ, cross-attention chủ yếu đóng vai trò tổng hợp có trọng số (chi tiết tại Mục 3.3.2) – mà nằm ở *tập véc-tơ truy vấn học được phối hợp qua self-attention*: mỗi truy vấn học cách trích xuất một

khía cạnh khác nhau của tín hiệu CF và điều phối lẫn nhau để tổng hợp biểu diễn tối ưu cho tác vụ, điều mà một phép chiếu tuyến tính đơn lẻ không làm được. Đây là luận điểm được nhất quán xuyên suốt chương và được kiểm chứng qua ablation ở Mục 4.4.

3.3.2 Kiến trúc Q-Former thích nghi cho gợi ý

Cầu nối được xây dựng dựa trên kiến trúc Q-Former theo Instruct-BLIP [7], kế thừa từ BLIP-2 [6]. SigLLM sử dụng $Q = 8$ véc-tơ truy vấn học được $\mathbf{Q} \in \mathbb{R}^{Q \times d_{\text{model}}}$, với $d_{\text{model}} = 768$ và nhánh văn bản khởi tạo từ `bert-base-uncased`.

Trong mỗi lớp Q-Former, các truy vấn đi qua hai loại attention:

1. *Self-attention* giữa các truy vấn với nhau (và với token chỉ dẫn, nếu dùng InstructBLIP): cho phép các truy vấn điều phối lẫn nhau và tích hợp thông tin ngữ cảnh tác vụ.
2. *Cross-attention* từ các truy vấn đến đặc trưng CF: mỗi truy vấn trọng số hóa và tổng hợp thông tin từ tập véc-tơ CF đầu vào $\{e_u, e_i, e_{i'}\}$.

Đầu ra là khối truy vấn $\mathbf{Z} = \text{cf_q} \in \mathbb{R}^{B \times Q \times d_{\text{model}}}$, trong đó B là kích thước lô và $Q = 8$.

Quan sát quan trọng về vai trò thay đổi giữa hai miền. Trong InstructBLIP, đầu vào của cross-attention là một chuỗi dài các mảng ảnh (patch features), và cross-attention là cơ chế nén chính: nén hàng trăm patch thành $Q = 32$ truy vấn. Trong SigLLM, đầu vào của cross-attention chỉ là một vài véc-tơ CF (người dùng, vật phẩm mục tiêu, lịch sử), nên cross-attention chủ yếu thực hiện tổng hợp có trọng số. Cơ chế trích xuất đặc trưng phụ thuộc tác vụ chủ yếu đến từ self-attention giữa các truy vấn và token chỉ dẫn. Nhận định này giải thích quan sát thực nghiệm rằng việc tăng số lớp Q-Former không cải thiện đáng kể kết quả, trong khi đa dạng hóa chỉ dẫn lại có tác dụng.

3.3.3 Đưa tín hiệu CF vào LLM qua soft token

Khởi truy vấn $\mathbf{Z}$ được chiếu từ không gian Q-Former sang không gian nhúng của LLM qua lớp chiếu tuyến tính $W_{\text{proj}} \in \mathbb{R}^{d_{\text{model}} \times d_{\text{LLM}}}$, tạo thành Q soft token. Các soft token này được chèn vào chỉ dẫn tại vị trí của token chuyên dụng `<rec_soft_token>`; phần văn bản của chỉ dẫn đánh dấu danh sách vật phẩm lịch sử và vật phẩm mục tiêu bằng `<ItemIDList>` và `<TargetItemID>` tương ứng. Một token chuyên dụng có định danh riêng (tách khỏi từ vựng gốc) được dùng thay cho `<unk>` nhằm tránh va chạm với các token ngoài-từ-vựng hay token đệm, và một lớp chuẩn hóa (LayerNorm) tại đầu ra lớp chiếu giữ cho độ lớn (scale) của soft token tương thích với các véc-tơ nhúng văn bản của LLM. Nhờ đó LLM xử lý tín hiệu CF ngay trong không gian đầu vào, cùng chuỗi với văn bản, mà không cần can thiệp vào trọng số bên trong của LLM.

Đây là điểm khác biệt so với CoRA [18]: CoRA biến $\mathbf{Z}$ thành lượng thay đổi trọng số hạng thấp theo từng mẫu, cộng vào các lớp attention của LLM (Mục 2.3.4), trong khi SigLLM chỉ dùng đường soft token. Lựa chọn này giữ LLM hoàn toàn đông cứng, tránh chi phí và rủi ro bất ổn của việc sinh trọng số theo từng mẫu, đồng thời tập trung toàn bộ dung lượng học vào cầu nối căn chỉnh. Trên nền đường soft token, luận văn bổ sung hai đòn bẩy huấn luyện – điều kiện hóa truy vấn theo người dùng (Mục 3.3.4) và mục tiêu bảo toàn thứ tự nội-người-dùng (Mục 3.3.5) – nhằm cải thiện lần lượt AUC và uAUC.

3.3.4 Điều kiện hóa truy vấn theo người dùng

Trong kiến trúc cơ sở, tập truy vấn $\mathbf{Q}$ cố định và dùng chung cho mọi mẫu. Cơ chế *điều kiện hóa theo người dùng* (user-conditioned queries) dịch tập truy vấn theo nhúng CF của người dùng trước khi đưa vào Q-Former:

$$\tilde{\mathbf{Q}} = \mathbf{Q} + g_u(e_u), \quad (3.1)$$

trong đó g_u là một lớp chiếu tuyến tính (`user_proj`) từ không gian MF sang không gian truy vấn, được *khởi tạo bằng không* (zero-init). Nhờ khởi tạo bằng không, ở bước đầu cơ chế là một phép đồng nhất (no-op), $\tilde{\mathbf{Q}} = \mathbf{Q}$; phần dịch chỉ lớn dần nếu tín hiệu CTR thưởng cho nó trong quá trình huấn luyện.

Cơ chế này gắn với đặc điểm của uAUC (Mục 4.3). Phần dịch $g_u(e_u)$ *thay đổi giữa các người dùng nhưng không đổi trong phạm vi một người dùng*: nó nâng khả năng phân biệt *giữa* các người dùng – cải thiện AUC toàn cục – trong khi gần như trung tính với uAUC, vốn bất biến với dịch chuyển mức nền riêng theo từng người dùng. Vì g_u chỉ xuất hiện khi bật cờ và được khởi tạo bằng không, cơ chế tương thích với checkpoint cũ và chỉ cần huấn luyện lại Bước 2 của Giai đoạn 3.

3.3.5 Mục tiêu bảo toàn thứ tự nội-người-dùng

Hàm mất mát mặc định của Giai đoạn 3 là entropy chéo nhị phân (BCE) trên token “Yes”/“No”. Mục tiêu này tối ưu biên độ phân loại nhưng không trực tiếp ép *thứ tự xếp hạng trong từng người dùng* – đại lượng mà uAUC đo. Để bù đắp, luận văn bổ sung một mục tiêu bảo toàn thứ tự (*align-rank loss*): một tổn thất BPR theo cặp trong phạm vi từng người dùng, đóng vai trò hàm thay thế (surrogate) khả vi cho uAUC, áp trực tiếp lên *soft token CF đã căn chỉnh* (trước khi vào LLM) thông qua một đầu ra phụ (`align_rank_head`) cũng khởi tạo bằng không:

$$\mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda \sum_u \sum_{(i^+, i^-) \in \mathcal{P}_u} -\log \sigma\left(\frac{1}{\tau}(s_u(i^+) - s_u(i^-))\right), \quad (3.2)$$

trong đó $s_u(\cdot)$ là điểm xếp hạng do `align_rank_head` sinh từ soft token CF đã căn chỉnh, $\mathcal{P}_u$ là tập các cặp dương–âm của cùng người dùng u , σ là hàm sigmoid, τ là nhiệt độ và λ là trọng số. Việc áp mục tiêu này lên chính phần biểu diễn CF đã căn chỉnh (thay vì chỉ lên biên độ Yes/No của

LLM) buộc bản thân câu hỏi giữ đúng thứ tự nội-người-dùng.

Để mỗi lô có sẵn các cặp dương–âm của cùng một người dùng, tổ thất này yêu cầu chế độ lấy mẫu theo nhóm người dùng (*user-grouped batch*), và được kích hoạt ở Bước 2 của Giai đoạn 3 (nơi Q-Former và lớp chiếu được huấn luyện). Do `align_rank_head` khởi tạo bằng không, các epoch đầu gần như trung tính và tác dụng hiện dần về sau – một đặc điểm huấn luyện được phân tích ở Chương 4. Đây là một siêu tham số phụ thuộc tập dữ liệu: nó cải thiện uAUC trên tập còn nhiều dư địa xếp hạng nội-người-dùng (Amazon-Book) và gần như trung tính khi uAUC đã bão hòa (MovieLens-1M).

3.4 Các lựa chọn thiết kế

Ngoài kiến trúc cầu nối Q-Former, SigLLM kết hợp một số lựa chọn thiết kế bổ sung. Luận văn ghi nhận các lựa chọn này một cách minh bạch, nhưng chúng không phải đóng góp chính; vai trò của từng lựa chọn được đánh giá qua ablation ở Mục 4.4.

3.4.1 Biểu diễn đa token cho tín hiệu CF

Phiên bản cơ sở nén toàn bộ tín hiệu CF thành một soft token duy nhất trước khi chèn vào chỉ dẫn. Biểu diễn đa token (multi-token) giữ nguyên $Q = 8$ truy vấn đầu ra của Q-Former dưới dạng 8 soft token riêng biệt, cung cấp dải băng thông cao hơn để truyền thông tin CF vào LLM.

3.4.2 Backbone LLM đã tinh chỉnh theo chỉ dẫn

SigLLM dùng backbone Vicuna-7B-v1.5 [16] – một mô hình đã được tinh chỉnh theo chỉ dẫn (instruction-tuned) trên nền Llama-2. Việc chọn Vicuna nhằm so sánh trung thực với CoLLM [5] (vốn dùng Llama-2 cùng họ). Chỉ dẫn theo khuôn mẫu hội thoại USER/ASSISTANT của Vicuna:

phần người dùng chứa chỉ dẫn CTR cùng vị trí `<rec_soft_token>`, và phần trợ lý sinh câu trả lời “Yes/No”. Bộ tách token được mở rộng bằng một token chuyên dụng có định danh riêng cho soft token, tách khỏi từ vựng gốc để không va chạm với các token điều khiển của khuôn mẫu.

Lý do dùng backbone đã tinh chỉnh chỉ dẫn: Thực nghiệm cho thấy tăng dung lượng LoRA không cải thiện kết quả: nâng hạng LoRA lên $r = 16$ trên các lớp $[q, k, v, o]$ dẫn đến quá khớp (overfitting) – mất mát huấn luyện giảm nhanh gấp khoảng hai lần nhưng uAUC trên tập kiểm định lại thấp hơn cấu hình $r = 8$ trên $[q, v]$. Kết quả này cho thấy dung lượng LoRA không phải nút thắt; nút thắt nằm ở chất lượng căn chỉnh của Q-Former. Backbone đã tinh chỉnh chỉ dẫn cung cấp tiên nghiệm tuân theo chỉ dẫn sẵn có, giải phóng dung lượng LoRA để tập trung vào việc sử dụng tín hiệu CF.

3.4.3 Tách lớp chiếu người dùng và vật phẩm

Trong kiến trúc cơ sở, một lớp chiếu chung ánh xạ cả nhúng người dùng lẫn nhúng vật phẩm từ không gian MF sang không gian Q-Former. Tuy nhiên, đặc trưng hình học của véc-tơ người dùng (user-factor) và véc-tơ vật phẩm (item-factor) trong không gian MF khác nhau: người dùng mã hóa sở thích tổng hợp, trong khi vật phẩm mã hóa thuộc tính nội dung. Dùng chung một phép chiếu cho cả hai loại có thể gây xung đột hình học.

Lựa chọn thiết kế này tách thành hai lớp chiếu riêng: một cho nhúng người dùng e_u và một cho các nhúng vật phẩm $\{e_i, e_{i'}\}$. Để duy trì khả năng nạp từ checkpoint cũ (chỉ có một lớp chiếu chung), trọng số của lớp chiếu chung được khởi tạo đồng thời cho cả hai lớp mới.

3.5 Tăng cường Q-Former theo InstructBLIP

3.5.1 Cơ chế conditioning theo chỉ dẫn

InstructBLIP [7] mở rộng Q-Former bằng cách đưa token chỉ dẫn văn bản tham gia vào self-attention cùng với các véc-tơ truy vấn. Kết quả là đầu ra $\mathbf{Z}$ của Q-Former phụ thuộc vào nội dung chỉ dẫn: cùng một đầu vào CF nhưng với chỉ dẫn khác nhau, Q-Former trích xuất các khía cạnh khác nhau. Thiết kế này cho phép một Q-Former duy nhất xử lý nhiều tác vụ khác nhau mà không cần tinh chỉnh riêng.

3.5.2 Thích nghi cho bài toán gợi ý

Trong SigLLM, chỉ dẫn (instruction) được đưa vào self-attention của Q-Former dưới dạng tập token. Với bài toán CTR trên MovieLens-1M, chỉ dẫn mô tả tác vụ và ngữ cảnh người dùng–phim: ví dụ, “*Given the user’s watching history and preferences, predict whether the user will click on the target movie.*”

Cơ chế conditioning theo chỉ dẫn hứa hẹn cải thiện chất lượng trích xuất đặc trưng CF vì Q-Former có thể tập trung vào các khía cạnh của tín hiệu CF liên quan nhất đến tác vụ CTR cụ thể. Trong bài toán BLIP-2/InstructBLIP, conditioning theo chỉ dẫn mang lại cải thiện đáng kể trên các tác vụ zero-shot [7].

Về phạm vi của conditioning. Trong InstructBLIP, sức mạnh của cơ chế đến từ việc chỉ dẫn *thay đổi* giữa nhiều tác vụ khác nhau, khiến cùng một đầu vào cho ra biểu diễn khác nhau tùy tác vụ. Trong phiên bản hiện tại của SigLLM, chỉ dẫn CTR được giữ *cố định* cho mọi mẫu; do đó cơ chế thực chất gần với Q-Former truy vấn cố định có bổ sung ngữ cảnh tác vụ ở tầng self-attention, hơn là conditioning phụ thuộc từng mẫu theo đúng nghĩa của InstructBLIP. Việc khảo sát nhiều mẫu chỉ dẫn khác nhau (ví dụ, chỉ dẫn phụ thuộc thể loại phim hay hồ sơ người dùng) để khai

thác đầy đủ conditioning phụ thuộc mẫu được để ngỏ như một hướng thực nghiệm; luận văn không tuyên bố vượt quá những gì cấu hình chỉ dẫn cố định hỗ trợ.

3.5.3 Kết quả và vị trí trong luận văn

Thực nghiệm về hiệu quả của InstructBLIP trên bài toán gợi ý được trình bày ở Mục 4.2 và Mục 4.4 của Chương 4. Như đã lưu ý ở Mục 1.4, kết quả của hướng tăng cường này vẫn đang trong quá trình thực nghiệm; luận văn báo cáo những gì đã đo được mà không phóng đại vượt quá bằng chứng.

3.6 Quy trình huấn luyện ba giai đoạn

SigLLM được huấn luyện qua ba giai đoạn nối tiếp, theo giao thức của CoLLM [5] với điều chỉnh cho phù hợp với kiến trúc Q-Former.

3.6.1 Giai đoạn 1: Tiền huấn luyện biểu diễn

Q-Former được huấn luyện với bốn mục tiêu tương phản và căn chỉnh:

- *Căn chỉnh vật phẩm-văn bản (ITC)*: tối đa hóa độ tương đồng giữa biểu diễn Q-Former của một vật phẩm (từ nhúng MF) và biểu diễn văn bản của vật phẩm đó (tên phim, thể loại). Đây là mục tiêu căn chỉnh chính.
- *So khớp vật phẩm-văn bản (ITM)*: phân loại nhị phân cặp vật phẩm-văn bản có khớp hay không.
- *Sinh văn bản có điều kiện (ITG)*: sinh văn bản mô tả vật phẩm từ biểu diễn Q-Former.
- *Tương phản người dùng-vật phẩm*: kéo gần biểu diễn của các cặp tương tác dương và đẩy xa các cặp âm.

Vấn đề mất cân bằng dữ liệu và giải pháp. Trên MovieLens-1M, số cặp người dùng–vật phẩm dương khoảng 888 nghìn, trong khi số cặp vật phẩm–văn bản chỉ khoảng 3 nghìn – tỉ lệ khoảng 0,34%. Với lô kích thước 64, kỳ vọng số mẫu vật phẩm–văn bản mỗi lô chỉ khoảng 0,22, nên điều kiện “ít nhất hai mẫu cùng loại” để kích hoạt ITC/ITM/ITG hiếm khi được thỏa. Hệ quả là ba mục tiêu căn chỉnh chính gần như không được huấn luyện, dẫn đến Q-Former không học được căn chỉnh CF–văn bản.

Giải pháp gồm hai điều chỉnh được tổng hợp ở Bảng 3.1:

Bảng 3.1: Hai điều chỉnh cân bằng dữ liệu Giai đoạn 1

Điều chỉnh	Tầng	Tác động
Giới hạn số cặp người dùng–vật phẩm ở mức 20.000	Dữ liệu	Nâng tỉ lệ mẫu vật phẩm–văn bản lên $\approx 13\%$; kỳ vọng ≈ 8 mẫu/lô $\Rightarrow$ điều kiện “ít nhất 2 mẫu” gần như luôn thỏa
Giảm trọng số mất mát người dùng–vật phẩm từ 1,0 xuống 0,5	Mất mát	Điều hòa cường độ gradient giữa các mục tiêu

Điều chỉnh giới hạn số cặp yêu cầu dựng lại tệp dữ liệu (vì giới hạn được cố định khi dựng), trong khi trọng số mất mát được đọc lúc huấn luyện và có hiệu lực ngay. Do danh sách cặp người dùng–vật phẩm kế thừa thứ tự sắp theo thời gian của dữ liệu gốc, việc lấy phần đầu danh sách sẽ thiên lệch về các tương tác sớm (phim và người dùng thời kỳ đầu). Để loại bỏ thiên lệch này, danh sách được xáo trộn ngẫu nhiên với hạt giống cố định trước khi cắt, biến giới hạn 20.000 thành một mẫu ngẫu nhiên đồng nhất mà vẫn bảo đảm tính tái lập.

3.6.2 Giai đoạn 2: Tiền huấn luyện sinh

Q-Former và lớp chiếu được huấn luyện với mục tiêu sinh ngôn ngữ: từ biểu diễn Q-Former của tín hiệu CF, sinh văn bản mô tả vật phẩm. Giai đoạn này dạy đầu ra của cầu nối trở thành soft token mà LLM có thể diễn giải – tức căn chỉnh không gian Q-Former với không gian ngữ nghĩa của LLM đông cứng.

3.6.3 Giai đoạn 3: Tinh chỉnh CTR

Giai đoạn này theo giao thức hai bước của CoLLM [5]:

Bước 1: Huấn luyện LoRA cơ sở với chỉ dẫn chỉ gồm văn bản (tên phim, thể loại, lịch sử dưới dạng văn bản), không có tín hiệu CF. Bước này thiết lập đường cơ sở cho khả năng dự đoán chỉ từ văn bản và ổn định hóa LLM trước khi tiếp nhận soft token.

Bước 2: Huấn luyện mô hình đầy đủ với tín hiệu CF được bơm vào qua soft token. Mô hình được khởi tạo từ checkpoint của Bước 1; LoRA được *đông cứng*, chỉ Q-Former và các lớp chiếu được cập nhật – tách bạch phần “ngôn ngữ” (LoRA, học ở Bước 1) khỏi phần “cộng tác” (cầu nối căn chỉnh, học ở Bước 2). Đây cũng là bước duy nhất kích hoạt hai đòn bẩy điều kiện hóa theo người dùng (Mục 3.3.4) và mục tiêu bảo toàn thứ tự (Mục 3.3.5). Nhãn giám sát là token “Yes” hoặc “No” tương ứng với nhãn CTR. Checkpoint tốt nhất được chọn theo uAUC trên tập kiểm định.

Chi phí tính toán. So với CoLLM, SigLLM có chi phí huấn luyện cao hơn do kiến trúc Q-Former phức tạp hơn lớp chiếu tuyến tính. Vì tín hiệu CF chỉ đi qua đường soft token và không sinh trọng số theo từng mẫu, LLM được giữ nguyên hoàn toàn khi suy luận. Chi phí cụ thể (số tham số huấn luyện được, thời gian huấn luyện mỗi giai đoạn) được báo cáo ở Mục 4.1. Luận văn không tuyên bố chi phí tăng thêm là “không đáng kể”; đây là đánh đổi có chủ đích cho chất lượng căn chỉnh tốt hơn.

3.7 Kết chương

Chương này đã trình bày kiến trúc ba khối của SigLLM và lý do chọn cầu nối Q-Former thay lớp chiếu tuyến tính của CoLLM. Luận điểm cốt lõi là: cơ chế cross-attention với tập truy vấn học được cho phép căn chỉnh tín hiệu CF vào không gian ngữ nghĩa LLM có kiểm soát hơn, vượt qua giới hạn của giả thiết tuyến tính. Trên nền cầu nối soft token, hai đòn bẩy huấn luyện – điều kiện hóa truy vấn theo người dùng và mục tiêu bảo toàn thứ tự nội-người-dùng – cải thiện lần lượt AUC và uAUC. Các lựa chọn thiết kế bổ sung (đa token, backbone đã tinh chỉnh chỉ dẫn, tách projector) và hướng tăng cường InstructBLIP được trình bày như các thành phần đã khảo sát, với kết quả thực nghiệm ở Chương 4.

Chương 4

Thực nghiệm và Kết quả

Chương này trình bày thiết lập thực nghiệm, kết quả đánh giá SigLLM so với các baseline, phân tích ablation và thảo luận. Tất cả số liệu trong chương được báo cáo trên một lần chạy duy nhất (một seed); khoảng tin cậy chưa được tính – đây là một hạn chế được thừa nhận (Mục 4.7).

4.1 Thiết lập thực nghiệm

4.1.1 Tập dữ liệu

Thực nghiệm được thực hiện trên hai tập dữ liệu chuẩn theo giao thức của CoLLM [5].

MovieLens-1M [21] gồm khoảng 1 triệu đánh giá từ 6.040 người dùng cho 3.706 phim, mỗi đánh giá là số sao từ 1 đến 5. Đánh giá được nhị phân hóa thành nhãn CTR: ≥ 4 sao được coi là nhấp (click), còn lại là không nhấp.

Amazon-Book [18] là một tập dữ liệu thưa hơn nhiều so với MovieLens-1M, theo đúng phân chia dùng trong CoLLM và CoRA. Tập này có khoảng 23 nghìn người dùng và 34 nghìn vật phẩm sách, với độ thưa và tỉ lệ người dùng/vật phẩm nguội cao hơn hẳn – đây chính là điều kiện để kiểm chứng câu nói CF-LLM trên miền khó, nơi tín hiệu CF yếu và LLM/Q-Former có nhiều dư địa đóng góp. Nhãn CTR được nhị phân hóa tương tự. Việc

bổ sung Amazon-Book cho phép đánh giá khả năng tổng quát của SigLLM ngoài miền phim và làm nổi bật vai trò của mục tiêu bảo toàn thứ tự nội-người-dùng (Mục 3.3.5).

4.1.2 Phân chia dữ liệu và giao thức đánh giá

Theo giao thức của CoLLM [5], dữ liệu được sắp xếp theo thời gian và phân chia thành tập huấn luyện, kiểm định và kiểm tra theo tỉ lệ 8:1:1. Để đảm bảo so sánh công bằng, các siêu tham số được chọn dựa trên tập kiểm định và số liệu cuối cùng được báo cáo trên tập kiểm tra.

4.1.3 Các mô hình baseline

Baseline chính:

- **CoLLM** [5]: tích hợp CF vào LLM qua MLP một lớp; cùng giao thức, cùng tập dữ liệu. Đây là baseline chính để đánh giá đóng góp của cầu nối Q-Former. Trên MovieLens-1M, luận văn đối chiếu với hai biến thể CoLLM-MF và CoLLM-DIN.
- **BinLLM** [17]: mã hóa nhị phân CF vào LLM – SOTA gần nhất theo giao thức này, có mặt trên cả hai tập dữ liệu.

Baseline bổ sung:

- **CoRA** [18]: đại diện hướng *tiêm trọng số* (không soft token). Trên Amazon-Book, biến thể CoRA-MF được đưa vào bảng so sánh như một điểm tham chiếu cho hướng thiết kế khác với SigLLM (Mục 2.3.4).
- **MF** [9] và **DIN**: các mô hình CF thuần (không LLM), làm mốc sàn để đo phần đóng góp thêm của cầu nối CF-LLM.
- **SellaRec** [14]: học tương phản InfoNCE, backbone Qwen2-7B-Base; *lưu ý: SigLLM dùng Vicuna-7B-v1.5, khác họ backbone, nên so sánh*

trực tiếp về số liệu bị giới hạn – được thảo luận như baseline không đồng nhất.

- **ILM** [8]: Q-Former cho gợi ý; lưu ý: *ILM không báo cáo AUC/uAUC theo giao thức CTR, nên không thể so sánh trực tiếp về số liệu; được đề cập trong phần thảo luận.*

Giao thức lấy số liệu baseline. Trên MovieLens-1M, số liệu CoLLM/BinLLM lấy theo giao thức CoLLM-parity. Trên Amazon-Book, số liệu CoLLM-MF/BinLLM/CoRA-MF lấy từ lần chạy lại (re-run) trong CoRA [18] để đảm bảo cùng phân chia dữ liệu. Cần lưu ý một khác biệt giao thức: SigLLM chọn checkpoint tốt nhất theo **uAUC**, trong khi CoLLM/CoRA chọn theo **AUC**; điều này được ghi chú trực tiếp ở bảng kết quả.

4.1.4 Độ đo đánh giá

Luận văn dùng hai độ đo chính theo giao thức CoLLM:

- **AUC** (Area Under the ROC Curve): đánh giá khả năng phân biệt tổng thể trên toàn tập kiểm tra – xác suất để điểm dự đoán của mẫu dương cao hơn mẫu âm.
- **uAUC** (user-level AUC): AUC được tính riêng trong phạm vi từng người dùng rồi lấy trung bình. uAUC đánh giá chất lượng xếp hạng *nội-người-dùng* và bất biến với các phép biến đổi đơn điệu theo từng người dùng.

Bổ sung: Accuracy và F1 (độ đo phân loại nhị phân), Precision@K và NDCG@K (độ đo xếp hạng top-K), và cosine similarity trước/sau căn chỉnh (đo mức độ thu hẹp khoảng cách ngữ nghĩa CF-LLM).

4.1.5 Cài đặt mô hình

- **LLM backbone**: Vicuna-7B-v1.5 [16] (tinh chỉnh chỉ dẫn trên nền Llama-2), đông cứng hoàn toàn; khuôn mẫu chỉ dẫn USER/ASSISTANT.

- **MF**: phân rã ma trận BPR [9], chiều ẩn $d = 256$, được huấn luyện và đông cứng trước khi tích hợp.
- **Q-Former**: $Q = 8$ truy vấn, $d_{\text{model}} = 768$, 8 đầu attention, 4 lớp; nhánh văn bản khởi tạo từ **bert-base-uncased**.
- **LoRA** [20]: hạng $r = 8$, $\alpha = 16$, dropout 0,05, áp dụng trên các lớp $[q, v]$ của LLM.
- **Đòn bẩy SOTA**: **user_conditioned** bật trên cả hai tập dữ liệu; **align_rank_loss** ($\lambda = 0,2$, kèm **user_grouped_batch**) bật trên Amazon-Book, tắt trên MovieLens-1M.
- **Chọn checkpoint**: theo uAUC trên tập kiểm định (khác CoLLM/CoRA chọn theo AUC – xem ghi chú bảng kết quả).
- **Optimizer**: AdamW; learning rate tùy giai đoạn (Bước 2 Giai đoạn 3 dùng 3×10^{-5} , giảm theo lịch cosine về 3×10^{-6}).
- **Phần cứng**: một GPU NVIDIA A100 80GB.
- **Tham số huấn luyện được**: chỉ LoRA (khoảng vài triệu tham số trên các lớp $[q, v]$ của backbone 7 tỉ tham số), cầu nối Q-Former và các lớp chiếu được cập nhật; MF và LLM đông cứng. Không có tham số tiêm trọng số. Tổng số tham số huấn luyện được rất nhỏ so với 7 tỉ tham số đông cứng của LLM, phản ánh thiết kế tinh chỉnh hiệu quả tham số.
- **Thời gian huấn luyện**: mỗi epoch mất khoảng 4–6 phút trên phần cứng nói trên (0,65–0,84 giây/iteration tùy giai đoạn).

4.2 Kết quả chính

Bảng 4.1 và Bảng 4.2 so sánh SigLLM với CoLLM, BinLLM và các baseline trên MovieLens-1M và Amazon-Book theo AUC và uAUC.

Bảng 4.1: Kết quả trên MovieLens-1M (giao thức CoLLM-parity). SigLLM báo cáo hai cấu hình: *vanilla* (chỉ soft token) và *+ user_conditioned* (cấu hình đề xuất). SigLLM chọn checkpoint theo uAUC.

Phương pháp	AUC	uAUC
MF (chỉ CF) [9]	0,6482	0,6361
DIN (chỉ CF)	0,7166	0,6459
CoLLM-MF [5]	0,7295	0,6875
CoLLM-DIN [5]	0,7243	0,6897
BinLLM [17]	0,7425	0,6956
SigLLM (vanilla)	0,7335	0,7009
SigLLM (+ user_conditioned)	0,7475	0,6968

MovieLens-1M. Cấu hình đề xuất (+ user_conditioned) đạt AUC 0,7475 và uAUC 0,6968, vượt BinLLM trên cả hai độ đo (0,7425/0,6956) và vượt rõ CoLLM-MF/CoLLM-DIN. Đây là điểm đáng chú ý nhất: nhiều phương pháp CF-LLM chỉ thắng một trong hai độ đo. So với cấu hình vanilla, user_conditioned nâng AUC từ 0,7335 lên 0,7475 (+0,014) trong khi uAUC gần như không đổi (0,7009 $\rightarrow$ 0,6968, chênh lệch nằm trong biên độ nhiễu) – đúng như phân tích ở Mục 4.3: phân dịch theo người dùng chủ yếu nâng khả năng phân biệt giữa các người dùng (AUC), gần như trung tính với xếp hạng trong người dùng (uAUC).

Amazon-Book. Đây là miền thưa và khó hơn. Với user_conditioned (Run-1), SigLLM đạt AUC 0,8147 và uAUC 0,5958 – vượt cả CoLLM-MF và BinLLM (theo lần chạy lại của CoRA) trên cả hai độ đo. Bổ sung align_rank_loss (Run-2) nâng uAUC lên 0,6062 (+0,0104) trong khi AUC gần như đứng yên ($-0,0015$) – đúng thiết kế: tổn thất này tác động vào thứ tự nội-người-dùng chứ không ảnh hưởng đến khả năng phân biệt giữa các người dùng. Con số 0,6062 đưa SigLLM vào vùng cạnh tranh với CoRA-MF (0,6262), vốn dùng cơ chế tiêm trọng số khác hẳn.

Về giao thức so sánh. SigLLM chọn checkpoint theo **uAUC**, còn

Bảng 4.2: Kết quả trên Amazon-Book. Số liệu CoLLM-MF/BinLLM/CoRA-MF lấy từ lần chạy lại trong CoRA [18] (chọn checkpoint theo AUC); SigLLM chọn theo uAUC. uAUC tính trên 2.486 người dùng tập kiểm tra. Run-1 = + user_conditioned; Run-2 = thêm align_rank_loss.

Phương pháp	AUC	uAUC
CoLLM-MF [5] (CoRA re-run)	0,8021	0,5782
BinLLM [17] (CoRA re-run)	0,8157	0,5724
CoRA-MF [18] (tiêm trọng số)	0,8179	0,6262
SigLLM (+ user_conditioned, Run-1)	0,8147	0,5958
SigLLM (+ align_rank, Run-2)	0,8132	0,6062

CoLLM/CoRA theo **AUC**; do đó uAUC của SigLLM là uAUC-tối-ưu-trên-frontier (lợi thế nhẹ) và cần được đọc kèm khác biệt này. Trên Amazon-Book, số liệu CoLLM/BinLLM có sai khác đáng kể giữa các lần chạy lại trong tài liệu (uAUC dao động $\approx 0,57\text{--}0,63$ tùy cấu hình huấn luyện và cỡ tập người dùng nhiều); luận văn vì thế định vị kết quả là “cạnh tranh/vượt baseline dưới giao thức có kiểm soát” thay vì đuổi theo một con số tuyệt đối.

4.3 Phân tích nghịch lý AUC/uAUC

uAUC tính AUC trong phạm vi từng người dùng rồi lấy trung bình, nên bất biến với các phép biến đổi đơn điệu riêng theo người dùng. Điều này dẫn đến một đặc điểm quan trọng: tín hiệu CF nếu chỉ giúp phân biệt giữa các người dùng (thay đổi *mức nền* điểm dự đoán của mỗi người dùng)

thì cải thiện AUC nhưng không cải thiện uAUC. Mô hình cần học thứ tự xếp hạng *trong* từng người dùng – cặp vật phẩm nào người dùng này thích hơn – thay vì chỉ phân biệt người dùng với nhau.

Đặc điểm này được xác nhận trực tiếp qua phân rã warm/cold (Mục 4.5.2). Trên cả hai tập dữ liệu, uAUC ở nhóm người dùng *ấm* (warm, MF có tín hiệu) cao hơn hẳn nhóm *nguội* (cold): trên Amazon-Book, uAUC warm đạt 0,6238 – gần chạm CoRA-MF (0,6262) – trong khi uAUC cold chỉ 0,5258, tức xấp xỉ mức ngẫu nhiên. Nhóm cold kéo trung bình toàn tập xuống 0,6062. Điều này cho thấy trần của uAUC không nằm ở cầu nối Q-Former (nếu Q-Former yếu thì AUC cũng phải sập, nhưng AUC vẫn cao $\approx 0,81$) mà ở *chất lượng nhúng CF của MF cho người dùng/vật phẩm nguội*. Đây là căn cứ để định hướng cải thiện uAUC về phía MF teacher (Mục 5.4) thay vì tinh chỉnh thêm kiến trúc cầu nối.

4.4 Phân tích ablation

Bảng 4.3 trình bày phân tích ablation các thành phần của SigLLM.

Bảng 4.3 tách biệt đóng góp của hai đòn bẩy huấn luyện bằng cách bật/tắt từng cơ chế trên nền cầu nối soft token, trên cả hai tập dữ liệu.

Đọc bảng ablation. Hai đòn bẩy tác động lên hai độ đo khác nhau, đúng như thiết kế. Trên MovieLens-1M, `user_conditioned` là đòn bẩy *AUC* (+0,014), gần trung tính với uAUC. Trên Amazon-Book, `align_rank_loss` là đòn bẩy *uAUC* (+0,0104), gần trung tính với AUC. Sự phân đôi này giải thích vì sao mỗi tập dữ liệu bật cơ chế khác nhau: trên MovieLens-1M uAUC đã gần bão hòa ($\approx 0,70$) nên `align_rank_loss` không còn dư địa; trên Amazon-Book uAUC còn thấp ($\approx 0,59$) nên tồn tại xếp hạng nội-người-dùng phát huy tác dụng. Việc bật cơ chế theo từng tập dữ liệu vì thế là một *siêu tham số hợp lệ theo miền*, không phải sự bất nhất về phương pháp.

Các ablation chưa thực hiện. Do giới hạn tài nguyên, một số ablation vẫn còn để ngỏ và được ghi nhận minh bạch như hạn chế (Mục 4.7):

Bảng 4.3: Ablation hai đòn bẩy huấn luyện. Trên MovieLens-1M: bật `user_conditioned`. Trên Amazon-Book: bật `user_conditioned` (Run-1) rồi thêm `align_rank_loss` (Run-2). Tất cả trên nền soft token; chọn checkpoint theo uAUC.

Tập dữ liệu	Cấu hình	AUC	uAUC
MovieLens-1M	Soft token (vanilla)	0,7335	0,7009
MovieLens-1M	+ <code>user_conditioned</code>	0,7475	0,6968
Amazon-Book	+ <code>user_conditioned</code> (Run-1)	0,8147	0,5958
Amazon-Book	+ <code>align_rank</code> (Run-2)	0,8132	0,6062

(i) thay cầu nối Q-Former bằng một bộ chiếu *attention-MLP* (MLP có self-attention nhưng không có truy vấn học được) để cô lập đóng góp của *cấu trúc Q-Former* khỏi phần phi tuyến + attention đơn thuần; (ii) bật/tắt riêng biểu diễn đa token, tách projector, và conditioning InstructBLIP dưới cùng backbone Vicuna; (iii) ablation `align_rank_loss` trên MovieLens-1M (kỳ vọng trung tính/âm vì uAUC đã bão hòa). Luận văn không điền số ước lượng cho các hàng này.

4.5 Phân tích bổ sung

4.5.1 Đo lường khoảng cách ngữ nghĩa

Để kiểm chứng rằng cầu nối Q-Former thực sự thu hẹp khoảng cách ngữ nghĩa giữa không gian CF và không gian LLM, luận văn đo cosine similarity giữa: (i) véc-tơ CF thô (đầu ra MF) và véc-tơ nhúng token LLM tương ứng trước khi huấn luyện cầu nối; (ii) soft token đầu ra Q-Former

và véc-tơ nhúng token LLM sau khi huấn luyện. Kết quả kỳ vọng: cosine similarity tăng sau huấn luyện, cho thấy Q-Former thực sự căn chỉnh không gian CF về phía không gian ngữ nghĩa LLM.

4.5.2 Phân tích theo nhóm người dùng (warm/cold)

Để kiểm chứng động lực cold-start, luận văn phân rã tập kiểm tra thành hai nhóm: người dùng *ấm* (warm – có nhúng MF, tức MF đã “thấy” người dùng/vật phẩm trong huấn luyện) và người dùng *nguội* (cold – MF không có nhúng, phải dùng đại diện mặc định). Bảng 4.4 trình bày AUC/uAUC theo từng nhóm trên cả hai tập dữ liệu.

Bảng 4.4: Phân rã warm/cold trên tập kiểm tra (cấu hình đề xuất). Amazon-Book dùng Run-2 (+ align_rank).

Tập dữ liệu	Nhóm	#người dùng	AUC	uAUC
MovieLens-1M	toàn bộ	7.331	0,7475	0,6968
MovieLens-1M	warm	4.153	0,7787	0,7254
MovieLens-1M	cold	3.178	0,7030	0,5969
Amazon-Book	toàn bộ	2.486	0,8132	0,6062
Amazon-Book	warm	1.648	0,8190	0,6238
Amazon-Book	cold	630	0,7928	0,5258

Kết quả nhất quán trên cả hai tập dữ liệu: nhóm warm đạt uAUC cao hơn hẳn nhóm cold (0,7254 vs 0,5969 trên MovieLens-1M; 0,6238 vs 0,5258 trên Amazon-Book). Trên Amazon-Book, uAUC nhóm warm (0,6238) gần chạm CoRA-MF (0,6262), trong khi nhóm cold xấp xỉ mức ngẫu nhiên.

Điều này khẳng định uAUC bị chặn trên bởi *chất lượng nhúng CF cho người dùng/vật phẩm người* chứ không phải bởi cầu nối: ở nhóm warm – nơi MF cung cấp tín hiệu tốt – SigLLM khai thác hiệu quả và tiệm cận baseline mạnh nhất. Nhận định này khớp với phân tích nghịch lý AUC/uAUC (Mục 4.3) và chỉ ra đòn bẩy cải thiện tiếp theo nằm ở MF teacher trên nhóm cold (Mục 5.4).

4.6 Thảo luận

4.6.1 Đối chiếu với ILM về giao thức đánh giá

ILM [8] không báo cáo AUC/uAUC theo giao thức CTR, nên không thể so sánh số liệu trực tiếp. Đây là lý do chính luận văn đặt ra mục tiêu đánh giá Q-Former dưới giao thức CoLLM: cung cấp cơ sở so sánh công bằng trong cùng điều kiện thực nghiệm.

4.6.2 Điểm mạnh và hạn chế của cầu nối Q-Former

So với lớp chiếu tuyến tính của CoLLM, cầu nối Q-Former có cơ chế trích chọn đặc trưng rõ ràng hơn qua tập truy vấn học được và self-attention, và có khả năng mở rộng bằng conditioning theo chỉ dẫn (InstructBLIP). Vì tín hiệu CF chỉ đi qua đường soft token, LLM được giữ nguyên khi suy luận – không có chi phí sinh trọng số theo từng mẫu như hướng tiêu trọng số của CoRA. Đánh đổi là chi phí huấn luyện cầu nối cao hơn lớp MLP đơn giản, cần cân nhắc tùy điều kiện triển khai.

4.7 Hạn chế

Luận văn thừa nhận các hạn chế thực nghiệm sau:

1. **Một seed:** Số liệu báo cáo từ một lần chạy duy nhất; chưa có khoảng tin cậy, kết quả có thể dao động giữa các lần chạy.

2. **Thiếu ablation attention-MLP:** Chưa có hàng ablation thay cầu nối Q-Former bằng bộ chiếu attention-MLP (không truy vấn học được). Đây là đối chứng quan trọng nhất để cô lập đóng góp của *cấu trúc Q-Former* khỏi phần phi tuyến + attention đơn thuần; hiện được ghi nhận là hướng thực nghiệm còn để ngỏ.
3. **Các ablation thành phần chưa đầy đủ:** Bật/tắt riêng biểu diễn đa token, tách projector, conditioning InstructBLIP, và `align_rank_loss` trên MovieLens-1M đều chưa được chạy dưới cùng backbone Vicuna; kết luận về từng thành phần vì thế còn hạn chế.
4. **Baseline không đồng nhất:** SellaRec dùng backbone Qwen2-Base khác họ với Vicuna; so sánh với SellaRec phản ánh khác biệt cả về cơ chế lẫn backbone LLM. Trên Amazon-Book, số liệu CoLLM/BinLLM/CoRA lấy từ lần chạy lại của CoRA (chọn theo AUC), khác giao thức chọn checkpoint theo uAUC của SigLLM.
5. **Trên uAUC ở nhóm cold:** uAUC bị chặn trên bởi chất lượng nhúng MF cho người dùng/vật phẩm nguội (Mục 4.5.2), không phải bởi cầu nối; cải thiện tiếp theo cần MF teacher mạnh hơn trên nhóm cold.

Chương 5

Kết luận và Hướng phát triển

5.1 Tóm tắt đóng góp

Luận văn đặt ra câu hỏi: liệu cầu nối Q-Former – với cơ chế cross-attention có kiểm soát – có thể căn chỉnh tín hiệu CF vào không gian ngữ nghĩa của LLM hiệu quả hơn lớp chiếu tuyến tính của CoLLM hay không? Để trả lời, luận văn thiết kế, hiện thực và đánh giá mô hình SigLLM, đóng góp theo hai hướng đã phát biểu ở Mục 1.4:

Đóng góp 1: Cầu nối Q-Former được thích nghi và tăng cường cho bài toán gợi ý. SigLLM thay thế lớp MLP một lớp của CoLLM bằng kiến trúc Q-Former, trong đó tín hiệu CF (nhúng người dùng, vật phẩm mục tiêu, lịch sử) thay thế đặc trưng ảnh làm đầu vào cross-attention và được đưa vào LLM qua đường soft token. Trên nền đó, luận văn bổ sung hai đòn bẩy huấn luyện – điều kiện hóa truy vấn theo người dùng và mục tiêu bảo toàn thứ tự nội-người-dùng – cùng các lựa chọn thiết kế (biểu diễn đa token, backbone đã tinh chỉnh chỉ dẫn, tách lớp chiếu người dùng/vật phẩm) và khảo sát InstructBLIP. Kết quả chi tiết được trình bày ở Chương 4.

Đóng góp 2: Đánh giá có hệ thống dưới giao thức AUC/uAUC trên hai tập dữ liệu. Luận văn đánh giá cầu nối Q-Former dưới giao thức CTR với AUC và uAUC – cùng giao thức với CoLLM – trên MovieLens-

1M và Amazon-Book, cho phép so sánh trực tiếp với CoLLM, BinLLM và CoRA. Phân tích ablation tách biệt đóng góp của từng đòn bẩy, và phân rã warm/cold làm rõ trần uAUC nằm ở chất lượng nhúng MF.

5.2 Kết quả đạt được

Từ kết quả ở Bảng 4.1, Bảng 4.2 và Bảng 4.3, có thể rút ra các kết luận sau:

- **MovieLens-1M – vượt SOTA trên cả hai độ đo.** Cấu hình đề xuất (+ `user_conditioned`) đạt AUC 0,7475 và uAUC 0,6968, vượt BinLLM (0,7425/0,6956) trên cả AUC lẫn uAUC và vượt rõ CoLLM. Đây là điểm đáng chú ý vì nhiều phương pháp cùng dòng chỉ thắng một trong hai độ đo.
- **Amazon-Book – cạnh tranh/vượt baseline trên miền khó.** Với `user_conditioned` (Run-1), SigLLM đạt 0,8147/0,5958, vượt CoLLM-MF và BinLLM (theo lần chạy lại của CoRA) trên cả hai độ đo. Bổ sung `align_rank_loss` (Run-2) nâng uAUC lên 0,6062, tiệm cận CoRA-MF (0,6262).
- **Hai đòn bẩy tác động lên hai độ đo khác nhau.** `user_conditioned` là đòn bẩy AUC (biến thiên giữa các người dùng); `align_rank_loss` là đòn bẩy uAUC (bảo toàn thứ tự trong người dùng). Việc bật theo từng tập dữ liệu là siêu tham số hợp lệ theo miền.
- **Trần uAUC nằm ở MF teacher, không phải cầu nối.** Phân rã warm/cold cho thấy uAUC nhóm warm cao hơn hẳn nhóm cold trên cả hai tập dữ liệu (ví dụ Amazon-Book: 0,6238 vs 0,5258), cho thấy đòn bẩy cải thiện tiếp theo nằm ở chất lượng nhúng CF cho người dùng/vật phẩm nguội (cold).

5.3 Hạn chế

Luận văn nêu rõ các hạn chế sau một cách minh bạch:

1. **Thiếu khoảng tin cậy:** Kết quả từ một seed duy nhất. Biến động thống kê giữa các lần chạy chưa được đo.
2. **Thiếu ablation attention-MLP:** Chưa có hàng ablation thay Q-Former bằng bộ chiều attention-MLP (không truy vấn học được) – đối chứng quan trọng nhất để cô lập đóng góp của cấu trúc Q-Former. Cùng với các ablation thành phần khác (đa token, tách projector, InstructBLIP, `align_rank` trên MovieLens-1M), đây là phần thực nghiệm còn để ngỏ.
3. **Chi phí tính toán cao hơn CoLLM:** Cầu nối Q-Former làm tăng chi phí huấn luyện so với lớp MLP đơn giản của CoLLM (dù không sinh trọng số theo từng mẫu như CoRA).
4. **Baseline không đồng nhất:** SellaRec dùng backbone LLM khác họ, và trên Amazon-Book số liệu baseline lấy từ lần chạy lại của CoRA (chọn checkpoint theo AUC, khác SigLLM chọn theo uAUC) – giới hạn khả năng so sánh thuần về cơ chế căn chỉnh.
5. **Trên uAUC ở nhóm cold:** uAUC bị chặn trên bởi chất lượng nhúng MF cho người dùng/vật phẩm nguội, không phải bởi cầu nối.

5.4 Hướng phát triển

Từ các hạn chế và quan sát trên, luận văn đề xuất những hướng nghiên cứu tiếp theo:

Mở rộng thực nghiệm:

- Đánh giá trên Amazon Books và các tập dữ liệu ngoài miền phim để kiểm chứng khả năng tổng quát.

- Chạy nhiều seed và báo cáo mean $\pm$ std để đánh giá độ ổn định.

Ablation và phân tích sâu hơn:

- Ablation bật/tắt riêng InstructBLIP conditioning để chốt đóng góp độc lập của thành phần này.
- Phân tích attention map của Q-Former để hiểu truy vấn nào học cách trích xuất thông tin gì từ tín hiệu CF.

Cải thiện uAUC:

- Tiền huấn luyện MF trên dữ liệu dày đặc hơn (nhiều tháng hơn), đặc biệt cho nhóm người dùng/vật phẩm nguội – đôn bẫy được phân rã warm/cold chỉ ra là trần thực sự của uAUC.
- Mở rộng mục tiêu bảo toàn thứ tự (`align_rank_loss`, đã hiệu quả trên Amazon-Book) sang các miền khác và khảo sát trọng số λ tối ưu theo từng tập.

Mở rộng kiến trúc:

- Bổ sung hàng ablation attention-MLP và các ablation thành phần còn để ngỏ dưới cùng backbone Vicuna để cô lập đầy đủ đóng góp của cấu trúc Q-Former.
- Khảo sát hướng tiêm trọng số kiểu CoRA như một đường *bổ sung* cho soft token (chưa hiện thực trong luận văn này) để so sánh trực tiếp hai cơ chế đưa CF vào LLM.
- Khảo sát các backbone LLM khác (Llama-3, Mistral) để kiểm chứng tính tổng quát của cầu nối Q-Former.

Tài liệu tham khảo

- [1] S. Zhang, L. Yao, A. Sun, and Y. Tay, “Deep learning based recommender system: A survey and new perspectives,” *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019. DOI: 10.1145/3285029
- [2] Y. Koren, R. Bell, and C. Volinsky, “Matrix factorization techniques for recommender systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263
- [3] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “LightGCN: Simplifying and powering graph convolution network for recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063
- [4] L. Wu et al., “A survey on large language models for recommendation,” *arXiv preprint arXiv:2305.19860*, 2023.
- [5] Y. Zhang, F. Feng, J. Zhang, K. Lv, and X. He, “CoLLM: Integrating collaborative embeddings into large language models for recommendation,” *arXiv preprint arXiv:2310.19488*, 2023.
- [6] J. Li, D. Li, S. Savarese, and S. Hoi, “BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models,” in *Proceedings of the 40th International Conference on Machine Learning*, 2023, pp. 19 730–19 742.

- [7] W. Dai et al., “InstructBLIP: Towards general-purpose vision-language models with instruction tuning,” *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [8] L. Yang et al., “Item-language model for conversational recommendation,” *arXiv preprint arXiv:2406.02844*, 2024.
- [9] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian personalized ranking from implicit feedback,” in *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, 2009, pp. 452–461.
- [10] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T.-S. Chua, “Neural collaborative filtering,” in *Proceedings of the 26th International Conference on World Wide Web*, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569
- [11] S. Geng, S. Liu, Z. Fu, Y. Ge, and Y. Zhang, “Recommendation as language processing (RLP): A unified pretrain, personalized prompt & predict paradigm (P5),” in *Proceedings of the 16th ACM Conference on Recommender Systems*, 2022, pp. 299–315. DOI: 10.1145/3523227.3546767
- [12] K. Bao et al., “BIGRec: A generalizable and controllable large language model framework for recommendation,” *arXiv preprint arXiv:2308.12242*, 2023.
- [13] H. Touvron et al., “Llama 2: Open foundation and fine-tuned chat models,” *arXiv preprint arXiv:2307.09288*, 2023.
- [14] Z. Wang et al., “Enhancing LLM-based recommendation through semantic-aligned collaborative knowledge,” *arXiv preprint arXiv:2504.10107*, 2025.
- [15] A. Yang et al., “Qwen2 technical report,” *arXiv preprint arXiv:2407.10671*, 2024.

- [16] W.-L. Chiang et al., “Vicuna: An open-source chatbot impressing GPT-4 with 90%* ChatGPT quality,” <https://lmsys.org/blog/2023-03-30-vicuna/>, 2023.
- [17] Y. Zhang, K. Bao, M. Yan, W. Wang, F. Feng, and X. He, “Text-like encoding of collaborative information in large language models for recommendation,” in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024)*, arXiv:2406.03210; model referred to in thesis as BinLLM, 2024.
- [18] J. Zhang, K. Bao, Y. Zhang, W. Wang, F. Feng, and X. He, “CoRA: Collaborative information perception by large language model’s weights for recommendation,” *arXiv preprint arXiv:2408.10645*, 2024.
- [19] J.-B. Alayrac et al., “Flamingo: A visual language model for few-shot learning,” in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 23 716–23 736.
- [20] E. J. Hu et al., “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022.
- [21] F. M. Harper and J. A. Konstan, “The MovieLens datasets: History and context,” *ACM Transactions on Interactive Intelligent Systems*, vol. 5, no. 4, pp. 1–19, 2015. DOI: 10.1145/2827872